



UNIVERSIDAD PERUANA DE CIENCIAS APLICADAS

FACULTAD DE INGENIERÍA

PROGRAMA ACADÉMICO DE CIENCIAS DE LA COMPUTACIÓN

**Aplicación Web de Soporte Clínico basada en Redes Neuronales
Convolucionales para la Identificación Automatizada de Patologías
Retinianas en Consultorios de Lima Metropolitana**

TRABAJO DE INVESTIGACIÓN

Para optar el grado de bachiller en Ciencias de la Computación

AUTOR(ES)

Mayhua Hinostroza, José Antonio (0009-0000-0770-4973)

Manchay Paredes, Lucero Salome (0009-0003-2717-0907)

ASESOR(ES)

Castañeda Vargas, Pedro Segundo (0000-0003-1865-1293)

Lima, 7 de Julio de 2026

Dedicatoria

Dedico el presente trabajo, en primer lugar, a mi familia, en especial a mis padres, por su amor incondicional, su esfuerzo y sacrificio en cada etapa de mi vida, y por enseñarme con su ejemplo el valor de la perseverancia; a mis hermanos, por estar siempre ahí conmigo, por su compañía y apoyo constante en cada paso de este camino; y de manera especial a mi compañera de investigación, quien siempre estuvo presente brindándome su apoyo incondicional, esfuerzo, aliento y paciencia en cada momento difícil, logramos hacer llegar la meta que nos propusimos alcanzar.

José Antonio Mayhua Hinostroza

Dedico este trabajo a mis padres, por su apoyo constante, comprensión y motivación durante mis tiempos más ajetreados. Gracias por estar siempre presentes, por brindarme fuerzas en los momentos difíciles y por acompañarme en cada etapa de este proceso académico. Asimismo, dedico este trabajo a mi compañero de investigación, por su compromiso, responsabilidad y apoyo durante el desarrollo del proyecto. Gracias por estar presente en las buenas y en las malas, por trabajar en equipo y por contribuir con esfuerzo y dedicación al cumplimiento de este objetivo compartido.

Lucero Salome Manchay Paredes

Agradecimientos

De manera especial, expresamos nuestro agradecimiento a nuestro profesor metodológico, Pedro Segundo Castañeda Vargas, por su orientación, paciencia y acompañamiento durante la elaboración del trabajo. Sus indicaciones, observaciones y retroalimentaciones en cada entrega fueron esenciales para mejorar la calidad de la investigación y fortalecer el desarrollo académico del proyecto.

Resumen

El presente trabajo de investigación propone una aplicación web de soporte clínico basada en Redes Neuronales Convolucionales (CNN) para la identificación automatizada de patologías retinianas en consultorios oftalmológicos de Lima Metropolitana. La investigación parte del problema de la detección tardía de enfermedades como la retinopatía diabética y el glaucoma, debido a la saturación de servicios especializados, los tiempos prolongados de espera y la dependencia del análisis visual manual de imágenes de fondo de ojo por parte del oftalmólogo. Para abordar esta problemática, se plantea una solución tecnológica que permite cargar retinografías, aplicar preprocesamiento de imágenes, ejecutar un modelo de Deep Learning entrenado mediante Transfer Learning y clasificar los casos según el posible hallazgo clínico. El sistema propuesto funciona como una herramienta de apoyo a la decisión médica, al ofrecer resultados con porcentaje de confianza, gestionar el historial visual del paciente y facilitar la generación de informes clínicos. Asimismo, el trabajo revisa fundamentos teóricos, estándares, buenas prácticas, normativa legal y estudios recientes que respaldan el uso de inteligencia artificial en salud visual. La propuesta busca optimizar el triaje oftalmológico, reducir la carga del especialista, priorizar casos de alto riesgo y contribuir a la prevención de ceguera irreversible mediante una atención más oportuna, digital y escalable.

Palabras clave: Redes Neuronales Convolucionales; Retinopatía diabética; Glaucoma; Soporte clínico; Inteligencia artificial; Imágenes de fondo de ojo.

Clinical Support Web Application Based on Convolutional Neural Networks for the Automated Identification of Retinal Pathologies in Ophthalmological Clinics in Metropolitan Lima

Abstract

This research project proposes a clinical support web application based on Convolutional Neural Networks (CNNs) for the automated identification of retinal pathologies in ophthalmology clinics in Metropolitan Lima. The research addresses the problem of late detection of diseases such as diabetic retinopathy and glaucoma, caused by the saturation of specialized services, long waiting times, and the dependence on manual visual analysis of fundus images by ophthalmologists. To address this issue, a technological solution is proposed that allows users to upload retinal images, apply image preprocessing, execute a Deep Learning model trained through Transfer Learning, and classify cases according to the possible clinical finding. The proposed system works as a medical decision-support tool by providing results with a confidence percentage, managing the patient's visual history, and facilitating the generation of clinical reports. Likewise, the study reviews theoretical foundations, standards, best practices, legal regulations, and recent studies that support the use of artificial intelligence in visual health. The proposal seeks to optimize ophthalmological triage, reduce the specialist's workload, prioritize high-risk cases, and contribute to the prevention of irreversible blindness through more timely, digital, and scalable care.

Keywords: Convolutional Neural Networks; Diabetic Retinopathy; Glaucoma; Clinical Support; Artificial Intelligence; Fundus Images.

Tabla de contenido

1.	Definición del Problema.....	1
1.1	Antecedentes.....	1
1.2	Problema de Investigación.....	5
1.2.1	Descripción e Importancia del Problema.....	5
1.2.2	Análisis del Problema.....	15
1.2.3	Caso de Estudio	17
1.2.4	Formulación del Problema.....	19
1.3	Objetivos.....	20
1.3.1	Objetivo General.....	20
1.3.2	Objetivos Específicos	20
1.4	Propuesta de Investigación	21
1.4.1	Diseño de Solución.....	21
1.4.2	Arquitectura Lógica.....	23
1.4.3	Arquitectura Física	25
1.4.4	Arquitectura Integrada.....	27
1.5	Gestión del Proyecto.....	29
1.5.1	Alcance	29
1.5.2	Cronograma	32
1.5.3	Costos	37
1.5.4	Calidad.....	39
1.5.5	Riesgos	45
1.6	Benchmarking.....	48
2	Marco Teórico	49
2.1	Definiciones.....	49
2.1.1	Inteligencia Artificial en salud	49

2.1.2	Redes Neuronales Convolucionales (CNN)	51
2.1.3	Procesamiento de imágenes médicas.....	53
2.1.4	Sistemas CAD (Computer-Aided Diagnosis).....	56
2.1.5	Infraestructura tecnológica	57
2.1.6	Salud visual y discapacidad visual	59
2.1.7	Patologías retinianas	61
2.1.8	Diagnóstico oftalmológico tradicional	64
2.1.9	Limitaciones del sistema de salud	66
2.1.10	Limitaciones tecnológicas en el diagnóstico	67
2.2	Estándares/Buenas Prácticas/Frameworks	70
2.2.1	Estándares	70
2.2.2	Frameworks	73
2.2.3	Buenas Prácticas	76
2.3	Normativa Legal.....	80
2.3.1	Ley N° 29733 - Ley de Protección de Datos Personales.....	80
2.3.2	Decreto Supremo N° 003-2013-JUS (Reglamento de la Ley de Protección de Datos)	81
2.3.3	Ley N° 31814 - Ley que promueve el uso de la Inteligencia Artificial en favor del desarrollo económico y social del país	82
2.3.4	Ley N° 30096 - Ley de Delitos Informáticos	82
2.3.5	Ley N° 30024 - Ley que crea el Registro Nacional de Historias Clínicas Electrónicas	83
2.3.6	Ley N° 30421 - Ley Marco de Telesalud	83
3	Estado del Arte	84
3.1	Introducción.....	84
3.2	Metodología de Búsqueda	85
3.2.1	Fases o Etapas de la Búsqueda	85

3.2.2	Fase: Planificación de la Revisión.....	86
3.2.3	Fase: Conducción de la Revisión	90
3.2.4	Fase: Documentación de la Revisión	91
3.3	Análisis de Resultados.....	92
3.3.1	Matriz de Artículos Seleccionados	92
3.3.2	Resumen de Artículos Seleccionados.....	110
3.3.3	Discusión	149
3.3.4	Conclusiones.....	157
	Conclusiones.....	159
	Referencias Bibliográficas.....	161
	Anexo(s)	174

Lista de Tablas

Tabla 1. Lista de Hitos del Proyecto	33
Tabla 2. Lista Base Global de Cronograma.....	35
Tabla 3. Desarrollo de Cronograma	36
Tabla 4. Costos de Personal.....	37
Tabla 5. Costos Gastos Generales	38
Tabla 6. Costos Bienes y Subcontrata (servicios contratados a terceros)	38
Tabla 7. Resumen de Costos	39
Tabla 8. Estándares de Calidad.....	39
Tabla 9. Procedimientos de Calidad	40
Tabla 10. Métricas de Calidad.....	42
Tabla 11. Matriz de Riesgos	45
Tabla 12. Preguntas de investigación	86
Tabla 13. Palabras claves.....	87
Tabla 14. Criterios de selección	89
Tabla 15. Criterios de exclusión	90
Tabla 16. Artículos potencialmente elegibles y seleccionados	91
Tabla 17. Relación de los artículos analizados por categoría.....	92
Tabla 18. Resumen de Artículos.....	116
Tabla 19. Resumen de Artículos.....	124
Tabla 20. Resumen de Artículos.....	131
Tabla 21. Resumen de Artículos.....	138
Tabla 22. Resumen de Artículos.....	146

Lista de Figuras

Figura 1. Proyección de crecimiento del mercado global de soluciones para retinopatía diabética.....	6
Figura 2. Tiempos prolongados de espera para la atención de especialidades médicas en el Perú	7
Figura 3. Déficit y brecha de médicos especialistas en el sistema de salud público nacional	8
Figura 4. Atenciones en Consultas Externas (2019 - 2024)	9
Figura 5. Análisis de la capacidad de respuesta y gestión en el sistema de salud peruano .	10
Figura 6. Pacientes de Glaucoma no atendidos ni reprogramados debido a deficiencias en el registro (Oct. 2023 - Ene. 2024)	11
Figura 7. Árbol de problemas sobre la detección temprana de patologías retinianas en Lima Metropolitana	15
Figura 8. Diagrama de notación de modelado de procesos de negocio (BPMN).....	18
Figura 9. Modelo conceptual de la solución.....	21
Figura 10. Arquitectura Lógica de la Solución.....	23
Figura 11. Diagrama de Arquitectura Física	25
Figura 12. Diagrama de Arquitectura Integrada.....	27
Figura 13. Informe del Product Backlog	30
Figura 14. Etapas de una búsqueda	85
Figura 15. Diagrama del proceso de revisión bibliográfica	90
Figura 16. Distribución de artículos por año de publicación y base de datos	91
Figura 17. Distribución de artículos por cuartil de indexación y base de datos	92

Student Outcome (Competencia del Estudiante)

ABET - CAC - Student Outcome 5: La capacidad de funcionar efectivamente como miembro o líder en un equipo cuyos miembros juntos proporcionan liderazgo, crean un entorno de colaboración e inclusivo, establecen objetivos, planifican tareas y cumplen objetivos.

El equipo cumple con el Student Outcome 5 de ABET-CAC, ya que el desarrollo del trabajo mostró la capacidad de funcionar de forma efectiva como equipo, asumiendo responsabilidades diferenciadas, coordinando actividades y orientando el proyecto hacia objetivos comunes. En el informe se identifica una organización de trabajo donde los integrantes asumieron roles como Project Manager/Desarrollador 1 y Scrum Master/Desarrollador 2, además de considerar la participación del asesor del proyecto y de un usuario validador o representante clínico, lo que muestra una estructura colaborativa con liderazgo técnico, académico y funcional.

Asimismo, el equipo estableció objetivos claros para el proyecto, vinculados al diseño de una aplicación web de soporte clínico basada en Redes Neuronales Convolucionales para la identificación automatizada de patologías retinianas. Estos objetivos fueron organizados dentro de una propuesta que incluye diseño de solución, arquitectura lógica, arquitectura física, arquitectura integrada y gestión del proyecto, lo cual muestra planificación técnica propia de Ciencias de la Computación.

La planificación de tareas se realizó mediante un enfoque ágil, apoyado en historias de usuario, Product Backlog, criterios de aceptación y Definition of Done. Cada funcionalidad se consideró terminada solo cuando respondía al objetivo de la historia de usuario, cumplía sus criterios de aceptación y era revisada en el cierre del sprint correspondiente. Esto muestra que el equipo no solo distribuyó tareas, sino que también definió mecanismos de control para asegurar el cumplimiento de los objetivos planteados.

Además, el proyecto refleja seguimiento y cumplimiento mediante un cronograma con hitos de entregas, sustentaciones, aprobación de documentos, artículo y acta de cierre, lo que muestra una gestión ordenada del tiempo y de los compromisos académicos. También se incorporaron métricas de calidad y seguimiento por sprint para verificar historias

planificadas, pruebas internas, integración del incremento y observaciones pendientes, fortaleciendo la mejora continua del trabajo grupal.

En síntesis, el equipo demostró esta competencia al organizarse con roles definidos, asumir liderazgo compartido, colaborar con actores técnicos y clínicos, establecer objetivos comunes, planificar tareas mediante prácticas ágiles y cumplir entregables bajo criterios de calidad. Esto refleja una forma de trabajo alineada con el perfil de Ciencias de la Computación, donde la solución propuesta requiere coordinación entre investigación, desarrollo de software, inteligencia artificial, gestión de datos, validación funcional y documentación académica.

1. Definición del Problema

1.1 Antecedentes

Según Moreno et al. (2024), el objetivo principal de su estudio fue evaluar y comparar diversas arquitecturas de redes neuronales convolucionales (CNN) para la detección de pterigión en imágenes del segmento anterior del ojo. El conjunto de datos utilizado para la recopilación de datos consistió en 540 imágenes oftalmológicas proporcionadas por el Centro Peruano de Pterigión. Metodológicamente, aplicaron un proceso de descubrimiento de conocimiento (KDD) a la base de datos y evaluaron técnicas preentrenadas como ResNet101, ResNext101, Se-ResNext50, ResNext50 y MobileNet V2. Su resultado cuantitativo más importante fue que concluyeron que la arquitectura Se-ResNext50 proporcionó el mejor rendimiento general, alcanzando una precisión del 93%, una sensibilidad (recall) 92% y una exactitud (accuracy) del 92%. Este estudio es relevante para nuestra investigación porque demuestra la efectividad de un método estructurado KDD para la evaluación rigurosa de modelos CNN. Si bien su aplicación clínica se limitaba al análisis del segmento anterior del ojo (pterigión), su marco metodológico puede aplicarse directamente al desarrollo de modelos predictivos para enfermedades retinianas profundas, lo que permite una predicción más precisa de la exactitud diagnóstica en los consultorios de Lima Metropolitana.

De manera similar, Ejaz et al. (2024) se centraron principalmente en el desarrollo de un marco de aprendizaje profundo para la detección temprana de múltiples enfermedades de la retina. Como herramienta de adquisición de datos, utilizaron el conjunto de datos ODIR (Ocular Disease Intelligent Recognition), una base de datos que contiene imágenes del fondo de ojo de 5000 pacientes clasificados en ocho clases distintas. Metodológicamente, evaluaron y compararon el rendimiento de varias arquitecturas de redes neuronales convolucionales (CNN), incluidas ResNet50, InceptionV3, MobileNetV2 y DenseNet121, y propusieron un marco de detección de enfermedades multirretinianas (MRDD) que aplica técnicas de aumento de datos para mejorar el rendimiento de generalización. Sus resultados cuantitativos más importantes concluyeron que un modelo basado en DenseNet121 logró el mejor rendimiento, alcanzando una precisión del 96,12 %, una precisión del 95,80 % y un puntaje F1 del 95,96 %. Este estudio es muy importante ya que demuestra cómo una arquitectura robusta puede facilitar la detección simultánea de múltiples enfermedades. Pese

a que el entorno de validación se limitó a una base de datos estandarizada a nivel mundial, eso no reduce su utilidad. La estrategia de clasificación que propone es aplicable al desarrollo de un sistema CAD web escalable, y su eficiencia puede adaptarse sin mayores complicaciones a las condiciones reales de los centros oftalmológicos en Lima Metropolitana.

Asimismo, Shamrat et al. (2024) se propusieron mejorar la precisión en la detección de la retinopatía diabética mediante el análisis de imágenes del fondo de ojo. Para ello, utilizaron conjuntos de datos públicos como APTOS 2019, IDRiD y EyePACS. Metodológicamente, evaluaron varias configuraciones de redes preentrenadas y desarrollaron DRNet13, una arquitectura de 13 capas diseñada para extraer características críticas de la retina. Los resultados mostraron que DRNet13 alcanzó una precisión del 97,45%, superando a modelos como ResNet50, InceptionV3 y VGG16. Esto demuestra que diseñar una arquitectura especializada marca una diferencia real frente a los enfoques convencionales de transfer learning. Ahora bien, los autores no profundizan en la implementación operativa dentro de un sistema de salud, pero su fundamento es directamente aplicable al desarrollo de una infraestructura web interoperable. En ese sentido, sus hallazgos respaldan la viabilidad de mejorar la precisión algorítmica como apoyo a los profesionales en el entorno clínico de Lima.

Por su parte, Mamyrbayev et al. (2025) plantearon desarrollar una arquitectura neuronal híbrida para la detección temprana de enfermedades de la retina. Para ello, utilizaron los conjuntos de datos DIARETDB0 y DIARETDB1, procesados junto con otros repositorios clínicos. En cuanto a la metodología, diseñaron un modelo que fusiona CNN con redes recurrentes (RNN) para identificar patrones continuos y variaciones espaciales en los vasos sanguíneos de la retina. Sus resultados mostraron que el enfoque híbrido alcanzó una precisión del 97,2%, superando el 93,4% logrado por las CNN convencionales. Ahora bien, si bien su estudio se centró en el análisis detallado de redes vasculares, su justificación técnica puede aplicarse directamente a la fase de entrenamiento de nuestra arquitectura. Dicho esto, sus hallazgos nos permiten proyectar el nivel de precisión requerido para el triaje oftalmológico en Lima Metropolitana.

De manera similar, Infante Cueva & Cruzado Benites (2024) se centraron en el desarrollo de un sistema de diagnóstico automatizado para la detección temprana de cataratas mediante redes neuronales convolucionales. Como herramienta de adquisición de datos utilizaron el

repositorio ODIR, que integra 10,000 imágenes clínicas. En cuanto a la metodología, el estudio incluye preprocesamiento, aumento de datos y evaluación comparativa de diversas arquitecturas en Python. Sus resultados mostraron que VGG19 preentrenada alcanzó el mejor rendimiento, con una exactitud del 98,67% en la fase de validación. Ahora bien, si bien su aplicabilidad clínica se limitó a la detección de cataratas, su método de evaluación de arquitecturas es directamente aplicable al desarrollo de modelos predictivos para glaucoma y retinopatía diabética. Dicho esto, sus hallazgos permiten proyectar la precisión esperada del sistema en los consultorios de Lima Metropolitana.

Además, Altuve et al. (2025) se propusieron detectar y clasificar enfermedades retinianas como la neovascularización coroidea, el edema macular diabético y las drusas mediante imágenes OCT. Para ello, procesaron conjuntos de datos OCT estandarizados y de acceso público, validados con expertos, usando transfer learning con VGG16. Sus resultados, evaluados mediante matrices de confusión en Python, mostraron una precisión del 97,47% y un F1-score promedio superior al 94% para patologías específicas. Dicho esto, su principal aporte es confirmar la efectividad del Transfer Learning en oftalmología, técnica que se utilizará directamente para entrenar y mejorar la sensibilidad del algoritmo predictivo de este trabajo. Con ello, se busca reducir la brecha de eficiencia operativa y aliviar la saturación que enfrentan actualmente los consultorios oftalmológicos de Lima Metropolitana.

Desde otra perspectiva, Tielavilca et al. (2024) se centraron en el diseño de una aplicación móvil basada en CNN para la detección de pterigión en un centro oftalmológico. Los datos consistieron en imágenes del segmento anterior del ojo proporcionadas por expertos y procesadas mediante el método KDD. En cuanto a las tecnologías, implementaron una arquitectura integrada con Amazon Web Services, desarrollaron el modelo en TensorFlow y lo desplegaron mediante una interfaz móvil en Flutter. Sus resultados mostraron que ResNext50 alcanzó un F1-score del 88%, superando a otras arquitecturas evaluadas. Ahora bien, su principal aporte es proporcionar un marco de arquitectura en la nube para el despliegue de modelos de Deep Learning. Sin embargo, ese vacío podría cubrirse desarrollando un sistema basado en una plataforma web integral diseñada específicamente para la detección de retinopatía.

Por otro lado, Rahim et al. (2026) plantearon desarrollar un nuevo método de clasificación inteligente basado en redes neuronales convolucionales (CNN) para la detección y clasificación del glaucoma. Utilizaron el conjunto de datos ACRIMA, disponible

públicamente, que consta de 705 imágenes de fondo de ojo clasificadas como normales o patológicas, como herramienta de adquisición de datos, y lo procesaron mediante una arquitectura multicapa profunda programada en MATLAB. Metodológicamente, evaluaron los efectos de las variaciones en el número de filtros y épocas de entrenamiento, y encontraron que la adición de una capa de abandono (dropout) permitía un aprendizaje más robusto y eficiente. Lo más importante es que el modelo demostró un rendimiento excelente, alcanzando una sensibilidad del 99,63 %, una especificidad del 98,53 % y una precisión del 99,11 % con una configuración de 100 épocas. Este estudio proporciona una justificación técnica para la configuración de hiperparámetros, incluido el uso de filtros y capas de regularización, que se puede aplicar a la estructuración y el entrenamiento del propio algoritmo. De esta forma, el objetivo es cerrar la brecha tecnológica en la región mediante la construcción de un sistema web de apoyo al diagnóstico (CAD) de alta precisión que alivie la carga de trabajo en los consultorios de Lima Metropolitana.

Además, Moreno y Ticlavilca (2025) establecieron el objetivo general de implementar una solución móvil para la detección de pterigión utilizando la arquitectura ResNext50 aplicada al Centro Peruano de Pterigión. Su herramienta de adquisición de datos consistió en un conjunto estructurado de 534 imágenes oftálmicas etiquetadas clínicamente, procesadas mediante marcos de trabajo como Scrum y KDD. A nivel técnico, el estudio implementó la inferencia del modelo utilizando Flask, un backend desarrollado con Spring Boot y una base de datos PostgreSQL que alojaba toda la infraestructura en Amazon Web Services (AWS). Cabe destacar que los resultados muestran que ResNext50 alcanzó una sensibilidad del 90%, una especificidad del 95% y una exactitud general del 89% en el entorno de prueba. Este estudio contribuye al proyecto actual al proporcionar la estructura básica para un servicio API REST para la comunicación del modelo. Sin embargo, el presente estudio aborda una brecha en el tema existente al orientar el sistema hacia enfermedades de la retina bajo una implementación totalmente web y escalable.

Finalmente, Kumar et al. (2026) introdujeron un enfoque de gestión sensible a la incertidumbre diagnóstica, con el objetivo principal de mejorar la detección automatizada de la retinopatía diabética. Se utilizaron grandes bases de datos oftalmológicas estandarizadas internacionalmente, como APTOS 2019 y Messidor, como herramientas de adquisición de datos, y se aplicó un método basado en una arquitectura de red neuronal convolucional híbrida con aprendizaje autosupervisado en dos etapas y validación ética para

la incertidumbre predictiva. Los resultados cuantitativos concluyeron que este modelo alcanzó un excelente área bajo la curva (AUC) del 99,2 %, demostrando una fiabilidad clínica superior en la clasificación patológica. Este estudio contribuye a este trabajo al proporcionar justificación y evidencia técnica para el uso de repositorios estandarizados como APTOS 2019. Este conocimiento se aplica como base para la recopilación, estructuración y entrenamiento de la red neuronal convolucional (CNN) propuesta. Por lo tanto, el objetivo de este estudio es cerrar las brechas éticas y clínicas en el contexto peruano al proporcionar a los pacientes un sistema de diagnóstico temprano de alta precisión.

1.2 Problema de Investigación

1.2.1 Descripción e Importancia del Problema


La salud visual representa un desafío crítico y creciente para los sistemas de salud pública del siglo XXI. A nivel global, la incidencia de enfermedades oculares degenerativas es alarmantemente alta debido al envejecimiento de la población y al aumento constante de las enfermedades crónicas no transmisibles. Según las proyecciones de la Organización Mundial de la Salud (WHO, de las siglas World Health Organization, 2024), al menos 2.200 millones de personas padecen algún tipo de discapacidad visual. Un indicador alarmante de esta crisis es la actual epidemia mundial de diabetes. Más de 460 millones de adultos tienen diabetes, y se prevé que esta cifra alcance los 700 millones para 2045 (International Agency for the Prevention of Blindness [IAPB], 2026).

Dentro de este espectro, las enfermedades de la retina y la neuropatía óptica destacan por su alta gravedad. Según WHO (2024), el glaucoma y la retinopatía diabética afectan a 7,7 y 3,9 millones de personas en todo el mundo, respectivamente. La causa principal de esta pérdida generalizada de visión radica en que aproximadamente una de cada tres personas con diabetes desarrolla algún tipo de retinopatía diabética (IAPB, 2026). Ambas enfermedades comparten una característica clínica de alto riesgo ya que suelen ser asintomáticas en sus etapas iniciales. Por lo tanto, si los sistemas de salud no implementan la detección temprana en la atención primaria, se pierden oportunidades de intervención y aumenta significativamente la probabilidad de ceguera irreversible (WHO, 2024). Como consecuencia económica, se estima que esta ineficiencia global genera una pérdida anual de productividad de 173 mil millones de dólares.

Frente a esta cantidad de pacientes, la comunidad médica internacional se enfrenta a una escasez estructural de especialistas. Dependrer exclusivamente del análisis visual humano es un modelo operativo insostenible debido al tiempo y la fatiga ocular que implica la evaluación. Esta limitación ha provocado un cambio de paradigma en la industria tecnológica. Desde 2018, los primeros sistemas autónomos de inteligencia artificial han recibido la aprobación regulatoria, demostrando que el diagnóstico automatizado puede igualar o incluso superar las capacidades humanas en la detección de patologías retinianas (IAPB, 2026). Además, se proyecta que el mercado global de estas soluciones tecnológicas crezca de forma constante hasta 2033 (Nova One Advisor, 2024).

Figura 1

Proyección de crecimiento del mercado global de soluciones para retinopatía diabética



Nota. Tomado de “Global Diabetic Retinopathy Market Size, Share, Forecast Report, 2024-2033”, por Nova One Advisor, 2024.

Como se muestra en la Figura 1, el mercado global, para el tratamiento y diagnóstico de la retinopatía diabética, se expande rápidamente, con una proyección de crecimiento de 9,100 millones de dólares en 2023 a 17,000 millones de dólares en 2033. Esta tendencia alcista refleja directamente la creciente prevalencia de la diabetes y la urgente necesidad de un diagnóstico precoz. Por lo tanto, el principal motor de este crecimiento es la adopción urgente de tecnologías de visión artificial e inteligencia artificial (IA), que permitirán la automatización del prediagnóstico, la superación de las limitaciones de recursos y la

democratización del acceso a la atención oftalmológica a escala global (Arias-Serrano et al., 2024; Henge et al., 2025; Nova One Advisor, 2024).

Esta crisis médica mundial y las consiguientes deficiencias operativas están teniendo un impacto directo y grave en el territorio nacional. En el Perú, la creciente demanda de servicios médicos oftalmológicos se ha convertido en una prioridad de salud pública. Un indicador alarmante de esta crisis es que el 30% de las personas con diabetes corren un riesgo inminente de ceguera irreversible debido a la falta de detección temprana (Glaucoma Lima Center, 2025). Esta situación se debe a deficiencias críticas en la infraestructura de salud y a la escasez de especialistas en las zonas rurales, como señaló la Defensoría del Pueblo (2025) en un informe sobre las vulnerabilidades del sistema de salud peruano.

Figura 2

Tiempos prolongados de espera para la atención de especialidades médicas en el Perú


Institutos Especializados en Salud	Especialidad con mayor lista de espera	Nº de días de espera
IRO JSU	Retina	120
INSM HD-HN	Adultos y adultos mayores	93
INEN	Dermatología	68
INCOR	Cirugía cardiovascular pediátrica	34
INO	Glaucoma y retina	30
IPO	Anestesiología	29
IREN - SUR	Cabeza y cuello - urología	25
INSN	Genética, traumatología, medicina física y rehabilitación y oftalmología	21
INR	Unidad motora y dolor	21
INSN - SB	Cardiología	17
IREN - NORTE	Ginecología	15
IREN - CENTRO	Ginecología - cirugía de abdomen y medicina oncológica	2
INCN	Neurocirugía	1
INMP	Rehabilitación, obstetricia y ginecología.	1

Nota. Tomado del “Informe Defensorial N° 243 (p. 80)”, por la Defensoría del Pueblo, 2025.

Como se muestra en la Figura 2, el sistema de salud pública presenta graves retrasos en el acceso a especialistas médicas, con tiempos de espera que alcanzan hasta 120 días. Esta lentitud es una manifestación de ineficiencia y dificulta el diagnóstico precoz de patologías retinianas que requieren intervención inmediata para prevenir daños irreversibles.

Figura 3

Déficit y brecha de médicos especialistas en el sistema de salud público nacional



Nota. Tomado del “Informe Defensorial N° 243 (p. 53)”, por la Defensoría del Pueblo, 2025.


Como se muestra en la Figura 3, ilustra una paradoja significativa en el sistema de salud: la extrema centralización. En el área metropolitana de Lima concentra mucho mayor de médicos especialistas (6978) en comparación con regiones como Madre de Dios (39), y esta clara ventaja numérica es causa directa de la saturación hospitalaria. Debido a la escasez de especialistas en las zonas del interior del país, Lima funciona como un "embudo" médico, recibiendo derivaciones no solo para la demanda local, sino también para casos complejos de todas las regiones. Este desequilibrio confirma que, incluso en la región con más recursos humanos, los modelos manuales de diagnóstico oftalmológico no pueden hacer frente a la enorme demanda, lo que resalta la necesidad urgente de introducir herramientas de inteligencia artificial para optimizar la eficiencia del triaje clínico.

Una prueba de ello es el aumento exponencial de la carga de trabajo en el Instituto Nacional de Oftalmología (INO), principal centro de referencia a nivel nacional. Según la Memoria

Institucional (2024), la demanda de atenciones en consultas externas ha aumentado de forma significativa y continua en los últimos años, alcanzando los 169.293 casos en 2024, como se muestra en la Figura 4 (INO, 2025).

Figura 4

Atenciones en Consultas Externas (2019 - 2024)



Nota. Tomado de “Memoria Institucional 2024 (p. 9)”, por el Instituto Nacional de Oftalmología, 2025.


Dentro de este extenso sistema de atención hospitalaria, las patologías degenerativas destacan críticamente que aborda el presente estudio. En 2024, se registraron más de 20 000 casos relacionados con diversos tipos de glaucoma y 2404 casos de retinopatía diabética. La principal consecuencia de no resolver esta brecha es el incremento del índice de discapacidad visual permanente en la población productiva del país, lo que generará una mayor carga económica para la nación en términos de pensiones y servicios de asistencia social. El factor más determinante para definir el alcance de este estudio es que el 73,5 % de esta demanda nacional (124 357 consultas) proviene únicamente de la región de Lima, evidenciando las graves presiones operativas que enfrentan las clínicas especializadas en la capital (INO, 2025).

El sistema de salud especializado enfrenta serios desafíos operativos y tecnológicos. Según el documento de política “Primer nivel de atención para lograr acceso oportuno” (Seinfeld et al., 2026), el sistema peruano está cada vez más fragmentado, lo que dificulta una atención

integral. Como resultado, los Institutos Nacionales en Lima soportan una carga desproporcionada de pacientes que podrían haber sido diagnosticados de forma preventiva si existieran herramientas tecnológicas adecuadas en los niveles de atención primaria.

Figura 5

Análisis de la capacidad de respuesta y gestión en el sistema de salud peruano



Nota. Tomado de “Primer nivel de atención para lograr acceso oportuno y efectivo a los servicios de salud en el Perú (2026-2031) (p.17)”, por Videnza Consultores, 2026.

Como se muestra en la Figura 5, existen importantes deficiencias en la gestión de los sistemas de salud y en la eficiencia de la atención. La falta de optimización en el triaje y los procesos de diagnóstico especializado subraya la necesidad urgente de desplazarse a un modelo de salud digital, donde el uso de algoritmos de inteligencia artificial permita reducir las dificultades en instituciones como el Instituto Nacional de Oftalmología (INO, 2025) y garantizando que los pacientes reciban diagnósticos temprano antes de que el daño ocular sea irreversible.

Una evaluación simultánea realizada por la Contraloría General de la República (CGR, 2024) reveló esta crisis al detectar deficiencias críticas en la programación y el seguimiento de pacientes en el Departamento de Atención Especializada en Glaucoma. Las estadísticas oficiales revelan una alarmante ineficiencia generada por la gestión analógica y los retrasos en el registro dentro del sistema hospitalario (SISGALEN PLUS). En un periodo de apenas cuatro meses (de octubre de 2023 a enero de 2024), solo 118 de los 316 pacientes que tenían citas programadas para tratamiento láser recibieron el tratamiento, lo que resultó en una tasa de eficiencia de tan solo el 37,3 % (CGR, 2024).

Este fallo en los procesos provocó que las visitas de 121 pacientes no se registraran en la plataforma, dejando la información clínica desprotegida e inaccesible, lo que generó graves retrasos administrativos y vulnerabilidad de los datos. Además, un fallo crítico del sistema impidió que 77 pacientes derivados recibieran tratamiento o reprogramaran sus citas (CGR, 2024). Como consecuencia directa de estas limitaciones operativas, se genera una pérdida de continuidad en la atención médica, tal como se muestra en la Figura 6.

Figura 6

Pacientes de Glaucoma no atendidos ni reprogramados debido a deficiencias en el registro (Oct. 2023 - Ene. 2024)

Meedico	Citados	Atendidos	NO Atendidos ni Reprogramados	No Registrados en Sistema SIGALEN PLUS	Meedico	Citados	Atendidos	NO Atendidos ni Reprogramados	No Registrados en Sistema SIGALEN PLUS
Bohorquez Tueros Rafael Antonio	25	4	5	16	Bohorquez Tueros Rafael Antonio	2	0	1	1
Alarcón Samane Flor de Maria	44	27	12	5	Chavez Vallejos Jennifer	19	12	3	4
Chavez Vallejos Jennifer	28	6	6	16	Loayza Gamboa Waldo	9	0	4	5
Loayza Gamboa Waldo	27	0	12	15	Sanchez Espinoza Javier Omar	14	0	2	12
Sanchez Espinoza Javier Omar	58	13	20	25	Trujillo Cadillo Dannyza Vilma	20	18	2	0
Trujillo Cadillo Dannyza Vilma	15	9	5	1	Vasquez Alania Patzy Yulissa	9	7	2	0
Vasquez Alania Patzy Yulissa	42	22	3	17	Perez GrossmannRodolfo Alfredo	4	0	0	4
Total	239	81	63	95	Total	77	37	14	26

Nota. Adaptado del “Informe de Control Concurrente N° 017-2024-OCI/3759-SCC (p. 4)”, por la Contraloría General de la República, 2024.

Esta deficiencia demuestra que, a pesar de la existencia de centros equipados con retinógrafos digitales para la captura de imágenes, los diagnósticos se retrasan debido a la dependencia del análisis humano y la gestión analógica, lo que pone en riesgo irreversiblemente la visión de los ciudadanos en condiciones de alta demanda (INO, 2025). La falta de algoritmos predictivos y sistemas CAD interoperables es la causa principal que impide que Instituto Nacional de Oftalmología (INO, 2025) pueda ampliar su capacidad de servicio. Reconociendo esta deficiencia en la innovación clínica y operativa, el gobierno peruano se unió recientemente a una red global para la regulación de la inteligencia artificial en la salud, priorizando el desarrollo de modelos tecnológicos seguros que respondan a las necesidades locales (RPP Noticias, 2026). Sin la implementación de esta solución tecnológica, la insatisfacción de los pacientes y el colapso de los servicios ambulatorios seguirán aumentando, lo que inevitablemente resultará en un incremento de los casos de ceguera prevenible en Lima Metropolitana.

El estado actual del diagnóstico oftalmológico, específicamente en Lima, se ve afectado por una grave saturación y deficiencias en la gestión. A pesar de contar con 6,978 médicos especialistas en el área metropolitana de Lima (Defensoría del Pueblo, 2025), se ha convertido en un obstáculo para el sistema de salud, absorbiendo el 73.5% de la demanda nacional de atención oftalmológica, con más de 124,000 citas en 2024 (INO, 2025). Además de esta sobrecarga, la gestión obsoleta y las deficiencias en sistemas como SISGALEN PLUS han reducido la eficiencia médica del INO a un crítico 37.3% (CGR, 2024). Como advierte el informe del Defensor del Pueblo mencionado anteriormente, los tiempos de espera para especialistas en retina pueden llegar hasta los 120 días, y para especialistas en glaucoma hasta los 30 días. Además, el 76% de los centros de atención primaria carecen de capacidad de diagnóstico, lo que les obliga a derivar un gran número de casos a otros hospitales (Videnza Consultores, 2026).

Frente a esta problemática, la situación deseable es la transición a un modelo de prediagnóstico descentralizado y automatizado en los consultorios de Lima Metropolitana. El escenario ideal contempla la implementación de una aplicación web de apoyo clínico que gestione el triaje primario mediante el análisis rápido de imágenes del fondo de ojo. Para lograr este objetivo, buscamos integrar algoritmos de Deep Learning, en particular Redes Neuronales Convolucionales (CNN), ya que la investigación médica ha demostrado que estos modelos pueden alcanzar simultáneamente una precisión superior al 98,1 % y una sensibilidad del 99,3 % en la identificación automatizada de patologías retinianas como la retinopatía diabética y el glaucoma (Arias-Serrano et al., 2024; Henge et al., 2025). Implementar esta capacidad en los centros de atención primaria optimizará el registro y monitoreo continuo de la información clínica, reduciendo el riesgo de abandono del paciente. Así, solo los casos de alto riesgo serán derivados a instituciones especializadas, antes de que el daño ocular sea irreversible.

En la actualidad, resolver esta problemática es urgente por varias razones: las amenazas para la salud pública, las vulnerabilidades operativas en la seguridad de la información y el impacto económico de una demanda que no para de crecer.

En primer lugar, en cuanto a las repercusiones en salud y costos, el 30% de los pacientes con diabetes en Perú enfrentan riesgo de ceguera irreversible por falta de un diagnóstico adecuado (Glaucoma Lima Center, 2025). A nivel global, la discapacidad visual genera

pérdidas anuales de productividad estimadas en 411 mil millones de dólares (WHO, 2024). Sin intervención oportuna, estas cifras seguirán creciendo, incrementando tanto los costos asistenciales para el Estado como los gastos de bolsillo de las familias.

En segundo lugar, en cuanto a la eficiencia operativa y seguridad de la información, el modelo analógico actual perjudica la trazabilidad clínica. Debido a las limitaciones de las plataformas informáticas, más de 100 consultas no se registran y los datos clínicos quedan desprotegidos e inaccesibles, dejando a decenas de pacientes derivados sin posibilidad de reprogramar sus citas (CGR, 2024). Ante eso, implementar una aplicación web resulta clave para garantizar la integridad de los datos, mantener la continuidad del tratamiento y prevenir errores administrativos.

Finalmente, desde una perspectiva estratégica tecnológica, la situación actual es ideal para la innovación. El Estado peruano se unió recientemente a una red global sobre regulación de la IA en el sector salud y se comprometió a priorizar la introducción de herramientas seguras basadas en IA y adaptadas a las necesidades locales (RPP Noticias, 2026). Aprovechar este apoyo institucional es fundamental para modernizar la atención oftalmológica y se alinea con la tendencia que prevé un crecimiento sostenido del mercado de soluciones tecnológicas para la retinopatía diabética hasta 2033 (Nova One Advisor, 2024).

Con base en lo anterior, en la presente tesis se propone una aplicación web de apoyo clínico basada en Redes Neuronales Convolucionales (CNN) que identifica automáticamente patologías retinianas a partir de imágenes del fondo de ojo, con el objetivo de optimizar la clasificación inicial, prevenir la ceguera irreversible y reducir la grave saturación sobre la atención oftalmológica en los consultorios de Lima Metropolitana.

El proyecto planteado es un reto tecnológico que se justifica de acuerdo a:

Este proyecto aporta una importante innovación tecnológica mediante la implementación de una arquitectura de vanguardia basada en inteligencia artificial y visión computacional en un entorno web. A diferencia de los métodos de diagnóstico tradicionales que dependen del análisis visual humano y la segmentación manual para características complejas como la relación copa-disco (CDR), esta investigación propone el uso de modelos de Deep Learning mediante aprendizaje por transferencia (transfer learning). Al integrar CNN como AlexNet y ResNet50, se posibilita la extracción automatizada de características con una precisión diagnóstica superior al 98,1% (Arias-Serrano et al., 2024; Henge et al., 2025). Esto permite

implementar soluciones de alta complejidad y baja latencia dentro de una aplicación web interoperable, facilitando un triaje automatizado de alta precisión sin necesidad de infraestructuras informáticas imposibles de implementar en consultorios locales.

Con este sistema, responde directamente la disfunción y saturación del sistema de atención oftalmológica en la capital. Actualmente, Lima Metropolitana actúa como un embudo, absorbiendo el 73.5% de la demanda nacional y experimentando severas listas de espera de hasta 120 días en campos especializados como retina (Defensoría del Pueblo, 2025; INO, 2025). Como beneficio visible e inmediato, la aplicación web reducirá significativamente los tiempos de triaje al distribuir la capacidad diagnóstica al nivel de atención primaria. En términos de seguridad y gestión, mitigará el riesgo de pérdida de información clínica y superará las deficiencias de sistemas obsoletos como SISGALEN PLUS, donde decenas de pacientes quedaron completamente desatendidos debido a fallas en el registro (CGR, 2024). Financieramente, a nivel financiero evitará el gasto hospitalario ineficiente al optimizar el flujo de derivaciones y reducirá significativamente los altos gastos de bolsillo que soportan las familias peruanas que se ven obligadas a depender de la atención médica privada debido a las demoras en las instituciones de salud pública.

Los beneficios sociales de esta investigación están directamente relacionados con la mejora de la calidad de vida de los ciudadanos y la democratización del acceso a la atención oftalmológica integral. Dado que el 30 % de las personas con diabetes en Perú corren un riesgo inminente de ceguera irreversible debido a la retinopatía diabética (Glaucoma Lima Center, 2025), el proyecto garantiza un tamizaje temprano e indispensable, ya que estas patologías suelen ser asintomáticas en sus etapas iniciales (WHO, 2024). Al filtrar de manera eficiente y oportuna los casos graves, se prevendrá la discapacidad visual y se protegerá a la población de la discapacidad permanente. Esto no solo protegerá la salud de los pacientes, sino que también prevendrá el empobrecimiento del núcleo familiar y promoverá comunidades económicamente activas y saludables.

En cuanto a la metodología, la investigación propone un framework escalable y reproducible para introducir herramientas de Deep Learning en sistemas de soporte clínico. El estudio establece un procedimiento que va desde el preprocesamiento automatizado de imágenes de fondo de ojo hasta el entrenamiento de un modelo multicatenario capaz de detectar simultáneamente retinopatía diabética y glaucoma (Arias-Serrano et al., 2024; Henge et al., 2025). Dicho esto, la validación del Transfer Learning mediante una base de datos

estandarizada establece una base metodológica para futuras validaciones clínicas asistidas por computadora. De replicar este modelo procedimental, permitiría integrar soluciones de inteligencia artificial en el diagnóstico de otros niveles de atención sanitaria y especialidades médicas del país.


Finalmente, esta propuesta se alinea con el Objetivo de Desarrollo Sostenible (ODS) 3 Salud y Bienestar, en particular con sus objetivos de asegurar la cobertura sanitaria universal y reducir la carga de las enfermedades no transmisibles. Esto deja en evidencia cuán importante es la prevención en las propuestas que buscan mejorar la calidad de vida de la ciudadanía, y las soluciones tecnológicas planteadas son un ejemplo concreto de ello. Al democratizar el acceso a diagnósticos automatizados y oportunos mediante inteligencia artificial, este proyecto desempeñará un papel crucial en la reducción de la ceguera prevenible y en la promoción de la salud visual de la población, dada la actual saturación hospitalaria en Lima Metropolitana.

1.2.2 Análisis del Problema

La figura 7 que aparece a continuación muestra un análisis de las causas y los efectos de las deficiencias en la detección temprana de patologías retinianas en los consultorios oftalmológicos de Lima Metropolitana, haciendo uso de la técnica del árbol de problemas.

Figura 7

Árbol de problemas sobre la detección temprana de patologías retinianas en Lima Metropolitana



Nota. Información obtenida de Arias-Serrano et al. (2024), (CGR, 2024), Henge et al. (2025), Instituto Nacional de Oftalmología (2025) y World Health Organization (2024).

Como se muestra en la Figura 7, el problema principal de las deficiencias en la detección temprana de patologías retinianas se relaciona directamente de dos causas principales: en primer lugar, la dependencia clínica de procesos analógicos convencionales sin innovación operativa; y segundo lugar, la falta de herramientas tecnológicas de alta precisión (sistemas CAD) para apoyar a los oftalmólogos. Según los autores, estas deficiencias son consecuencia de la tardía adopción de estrategias de inteligencia artificial en el sector local. La parte superior de la figura muestra el impacto directo de este modelo defectuoso. Sin intervención técnica, existe una alta tasa de progresión silenciosa de la enfermedad que conduce a la ceguera irreversible. Asimismo, a nivel operativo, esto genera una carga excesiva para los servicios quirúrgicos, provocando retrasos y reprogramaciones significativas y pone en grave riesgo la salud visual de los pacientes.

1.2.3 Caso de Estudio

1.2.3.1 Datos Generales

Como caso de estudio, proponemos a V.E.R. Centro Oftalmológico durante la etapa de validación de esta investigación. Esta organización posee las características operativas y clínicas necesarias para la implementación de una aplicación web. Pertenece a una institución privada de salud que ofrece servicios médicos oftalmológicos especializados. Sus actividades abarcan desde la atención médica completa y el diagnóstico clínico mediante procedimientos especializados hasta la realización de intervenciones de alta complejidad como microcirugía, terapia con láser de argón y terapia con láser YAG. Las áreas de especialización del centro incluyen la atención de la mácula, el desprendimiento de retina, el glaucoma y la retinopatía diabética.

Con respecto a la ubicación y alcance de la organización, sus actividades se centran en la comunidad local, especialmente en las necesidades del área de Lima Metropolitana. Su sede se ubica en la calle Aldavas 559, Santiago de Surco, Lima, Oficina 402. En términos tecnológicos, la visión de la organización es convertirse en un modelo en Perú, dedicada a mejorar la calidad de vida de las personas mediante la innovación quirúrgica, el tratamiento integral y los servicios sociales. Asimismo, la organización otorga gran importancia a la innovación y la investigación clínica en sus operaciones diarias. Este firme compromiso con la adopción de soluciones tecnológicas avanzadas crea un entorno ideal y favorable para validar la implementación de sistemas de inteligencia artificial basados en redes neuronales convolucionales (CNN) en el apoyo clínico, aportando un valor significativo a la resolución de desafíos de la organización.


1.2.3.2 Datos Específicos

Este estudio tiene como objetivo validar soluciones de diagnóstico y consultorios externos, bajo las características específicas del entorno clínico. Esta unidad organizativa realiza exámenes iniciales, la obtención de imágenes del fondo de ojo y la evaluación clínica de patologías degenerativas como el glaucoma y la retinopatía diabética. Con respecto a la implementación de estas actividades, los flujos de trabajos existentes presentan limitaciones operativas en la etapa de despistaje. Como se muestra en la Figura 8, al llegar el paciente al consultorio, el personal administrativo registra sus datos e historial médico en el sistema SISGALEN. A continuación, el personal técnico o un optometrista llama al paciente a la sala

de triaje, donde se toman imágenes del fondo de ojo con un retinómetro digital y se almacenan en la red local. Tras esperar a que un especialista esté disponible, el oftalmólogo debe realizar un análisis visual y manual de las imágenes. Este proceso analógico y subjetivo es una de las principales causas de la congestión diagnóstica, lo que provoca fatiga visual y sobrecarga cognitiva en los especialistas y limita la capacidad diagnóstica del centro. Finalmente, el médico concluye la consulta evaluando si se identificó alguna anomalía patológica, realizando un diagnóstico clínico y prescribiendo el tratamiento.

Figura 8

Diagrama de notación de modelado de procesos de negocio (BPMN)



Nota. Información obtenida de la CGR (2024).

Para respaldar este proceso, la infraestructura tecnológica actual del consultorio se basa en componentes básicos. A nivel de software, se utiliza el sistema SISGALEN para el registro de pacientes y los historiales médicos, así como un visor de imágenes estándar en la red local. Actualmente, se carece de sistemas de diagnóstico asistido por computadora (CAD) y herramientas de inteligencia artificial para los flujos de trabajo de clasificación de imágenes. A nivel de hardware, el consultorio cuenta con equipos de diagnóstico por imagen (retinógrafos digitales) y computadoras personales (PC) asignadas a las salas de examen y áreas de recepción, que operan en una red de área local (LAN) con acceso a internet. Dentro

de este ecosistema, interactúan diversos actores y roles: pacientes o usuarios finales que acuden para revisiones rutinarias o por complicaciones diabéticas, personal administrativo responsable del registro en el sistema, personal técnico u optometristas responsables de la captura de imágenes, y oftalmólogos que analizan visualmente las imágenes para realizar diagnósticos definitivos.

Finalmente, en cuanto al volumen de datos, como centro especializado que atiende directamente la alta demanda en Lima Metropolitana, el departamento de diagnóstico recibe un número constante y considerable de pacientes. Debido a este flujo, se espera que la solución tecnológica gestione varios cientos de transacciones mensuales, principalmente enfocadas en el triaje automatizado. El nuevo sistema requerirá la recepción, el procesamiento y la clasificación continuos de imágenes de fondo de ojo, y este requisito operativo futuro justifica plenamente la necesidad de diseñar una arquitectura web altamente escalable que pueda soportar la carga de evaluación simultánea en la nube sin degradar el rendimiento de la red local del consultorio.

1.2.4 Formulación del Problema

En base a los sustentos redactados en las secciones anteriores, se plantea la siguiente pregunta de investigación: ¿De qué manera una aplicación web de soporte clínico basada en Redes Neuronales Convolucionales permite reducir las deficiencias en la detección temprana de patologías retinianas en los consultorios oftalmológicos de Lima Metropolitana?

En este sentido, se ha propuesto el uso de redes neuronales convolucionales (CNN) como una alternativa tecnológica para abordar el problema de las deficiencias en la detección temprana en los consultorios oftalmológicos. Esto se debe a que, tras revisar la literatura, varios autores (Arias-Serrano et al., 2024; Henge et al., 2025) han propuesto el uso de modelos de Deep Learning, específicamente arquitecturas CNN mediante transferencia de aprendizaje y modelos híbridos, para la extracción y el procesamiento autónomo de características y el procesamiento de imágenes de fondo de ojo, demostrando que afecciones asintomáticas como el glaucoma y la retinopatía diabética pueden identificarse con una precisión diagnóstica superior al 93 % y al 98 %, respectivamente.

La discapacidad visual es uno de los principales factores de retraso en este estudio y, sumada a las largas listas de espera en el sistema de salud pública, que pueden extenderse hasta 120

días para obtener una cita con un especialista en retina, representa un problema significativo (Defensoria de Pueblo, 2025). Se considera que este tipo de tecnología basada en IA es directamente aplicable en el problema descrito y podría automatizar la clasificación inicial de pacientes, prevenir la ceguera irreversible y mejorar la calidad de vida de los ciudadanos de la capital.

1.3 Objetivos

1.3.1 Objetivo General

Implementar una aplicación web de soporte clínico basada en Redes Neuronales Convolucionales (CNN) para automatizar la detección y clasificación temprana de patologías retinianas, específicamente la Retinopatía Diabética y el Glaucoma, con el fin de optimizar la precisión diagnóstica y reducir la severa ineficiencia operativa en los consultorios oftalmológicos de Lima Metropolitana.

1.3.2 Objetivos Específicos

- Identificar los requerimientos del sistema a partir del análisis del flujo de atención clínica actual, y recopilar, preprocesar y balancear un dataset de retinografías validadas clínicamente mediante técnicas de Data Augmentation, evidenciado mediante un documento de especificación de requerimientos y un repositorio de datos optimizado para modelos de aprendizaje profundo.
- Diseñar, entrenar y evaluar la arquitectura del modelo de Red Neuronal Convolutiva (aplicando transferencia de aprendizaje o modelos híbridos) para la clasificación de Retinopatía Diabética y Glaucoma, evidenciado mediante un reporte técnico de métricas de rendimiento donde el algoritmo alcance niveles óptimos de exactitud (Accuracy) y sensibilidad (Recall).
- Construir una arquitectura de software web escalable e interoperable que permita al especialista médico gestionar el historial visual de los pacientes y ejecutar el modelo de forma asíncrona, evidenciado mediante un prototipo funcional desplegado en un entorno de pruebas con interfaces de usuario (Frontend) y servicios de inferencia (Backend) operativos.

- Validar la precisión diagnóstica de la herramienta y su impacto en la reducción de tiempos de triaje visual, evidenciado mediante un informe de pruebas de aceptación, rendimiento (stress testing) y usabilidad técnica documentada en un escenario clínico simulado.

1.4 Propuesta de Investigación

1.4.1 Diseño de Solución

La solución propuesta es una aplicación web de soporte clínico basada en Redes Neuronales Convolucionales (CNN) que automatiza la clasificación inicial de patologías retinianas en los consultorios oftalmológicos de Lima Metropolitana. El sistema actúa como una capa de inteligencia artificial integrada al flujo de atención existente, permitiendo que el personal técnico cargue imágenes de fondo de ojo directamente desde el navegador, sin necesidad de instalar servidores locales adicionales en el consultorio.


Una vez recibida la imagen, el sistema la pre-procesa automáticamente aplicando técnicas de normalización de iluminación, redimensionamiento y recorte de la región de interés. Posteriormente, ejecuta de forma asíncrona un modelo de Deep Learning entrenado con Transfer Learning sobre una arquitectura CNN DenseNet121. El modelo clasifica la imagen en tres categorías: retinopatía diabética, glaucoma o sin hallazgos patológicos, y retorna al especialista un resultado con su respectivo porcentaje de confianza en cuestión de segundos.

El oftalmólogo visualiza la alerta diagnóstica en su interfaz, revisa el resultado como una segunda opinión objetiva y puede generar un informe clínico estandarizado en formato PDF para adjuntarlo al expediente del paciente. Adicionalmente, el sistema gestiona el historial visual de cada paciente, registrando cada análisis con su fecha, imagen y resultado, lo que permite realizar un seguimiento longitudinal de la evolución de la patología.

De esta manera, el software transforma el proceso de triaje manual y analógico en un flujo digital asistido por IA, reduciendo la carga cognitiva del especialista, disminuyendo los tiempos de clasificación inicial y permitiendo priorizar los casos de alto riesgo para revisión especializada.

Figura 9

Modelo conceptual de la solución



Nota. Adaptado a partir de los enfoques de clasificación de enfermedades retinianas mediante redes neuronales convolucionales y Transfer Learning descritos por Ejaz et al. (2024), Shamrat et al. (2024), Mamyrbayev et al. (2025) y Rahim et al. (2024).

Como se muestra en la Figura 9, el modelo conceptual de la solución propuesta se estructura en cuatro capas funcionales que describen el flujo completo del sistema CAD web. El proceso se inicia con el personal técnico, quien carga la imagen de retinografía a través de la capa web o frontend, donde el sistema recibe el archivo en formato JPG. Posteriormente, la imagen es enviada a la capa de preprocesamiento del backend, donde se aplican técnicas de aislamiento de la región de interés (ROI), normalización de iluminación,

redimensionamiento y ajuste de contraste, generando un tensor normalizado listo para su análisis.


Dicho tensor es procesado por el motor de inferencia de inteligencia artificial, compuesto por el modelo CNN DenseNet121 con Transfer Learning. Este modelo extrae características visuales de la retinografía y produce una clasificación en tres categorías: glaucoma, retinopatía diabética o sano, acompañada de su respectivo porcentaje de confianza. El resultado es presentado al médico oftalmólogo mediante un panel de alertas diagnósticas, quien revisa y valida clínicamente la predicción generada por el sistema. Finalmente, el caso se deriva hacia la capa de persistencia y reportes, donde se genera un informe clínico en formato PDF descargable y se registra el análisis en el historial longitudinal del paciente, permitiendo el seguimiento de la evolución de la patología a lo largo del tiempo.

1.4.2 Arquitectura Lógica

A continuación, se presenta la arquitectura lógica del sistema, organizada en cuatro capas que definen la separación de responsabilidades y el flujo de datos entre los actores, los módulos de software, los servicios de inteligencia artificial y los componentes de almacenamiento en la nube.

Figura 10

Arquitectura Lógica de la Solución



Nota. Adaptado a partir de la arquitectura web propuesta para sistemas de inferencia clínica con FastAPI, Angular, TensorFlow/Keras, OpenCV, PostgreSQL y Amazon Web Services, según tiangolo (2026), TensorFlow (2021), Ticlavilca et al. (2024) y Moreno y Ticlavilca (2025).

Como se muestra en la Figura 10, la arquitectura lógica de la solución se organiza en cuatro capas funcionales que estructuran la comunicación entre los actores del sistema y los componentes tecnológicos que lo conforman. El flujo se inicia con los dos actores principales: el personal médico y el personal técnico, quienes acceden al sistema a través de un navegador web.

La capa de presentación aloja el frontend desarrollado en Angular, que actúa como interfaz de gestión clínica y punto de interacción del usuario con el sistema. Esta capa se comunica con la capa de aplicación mediante el envío de peticiones JSON sobre HTTPS y recibe respuestas JSON con los resultados procesados. La capa de aplicación está compuesta por el backend desarrollado en FastAPI, el cual gestiona la autenticación mediante tokens JWT y orquesta las comunicaciones hacia las capas inferiores.


Desde este componente central se establecen canales de comunicación hacia la capa de datos y cloud, donde PostgreSQL sobre Amazon RDS gestiona la persistencia de registros clínicos, mientras que Amazon S3 actúa como repositorio de retinografías y reportes PDF. Asimismo, el backend se comunica con la capa de inteligencia artificial, donde OpenCV ejecuta el preprocesamiento y aislamiento de la región de interés (ROI), generando un tensor normalizado que posteriormente es procesado por el modelo CNN DenseNet121 implementado en TensorFlow/Keras. La predicción diagnóstica resultante es devuelta al backend para su presentación al especialista a través de la interfaz web.

1.4.3 Arquitectura Física

A continuación, se presenta la arquitectura física del sistema, la cual describe la infraestructura de despliegue propuesta en la nube sobre Amazon Web Services. Esta arquitectura detalla los nodos físicos, las subredes de procesamiento y persistencia dentro de una VPC aislada, así como los protocolos de comunicación entre cada componente. La configuración específica de recursos computacionales podrá ajustarse posteriormente en la sección de costos, de acuerdo con el volumen estimado de usuarios, imágenes procesadas y presupuesto disponible.

Figura 11

Diagrama de Arquitectura Física



Nota. Adaptado a partir de los componentes de despliegue cloud y almacenamiento clínico descritos para soluciones web con inteligencia artificial en Amazon Web Services, TensorFlow/Keras y OpenCV, según TensorFlow (2021), Ticlavilca et al. (2024) y Moreno y Ticlavilca (2025).

Como se muestra en la Figura 11, la arquitectura física de despliegue del sistema se estructura sobre la infraestructura cloud de Amazon Web Services. El flujo se inicia desde el nodo cliente, ubicado en el Consultorio V.E.R., que accede al sistema mediante un navegador web bajo el protocolo HTTPS/TLS 1.3. El tráfico entrante es interceptado por la capa de seguridad perimetral y CDN, compuesta por AWS WAF para el filtrado de amenazas y CloudFront para la distribución segura de contenido. Luego, las peticiones son derivadas al Elastic Load Balancer, que distribuye el tráfico hacia los nodos internos de procesamiento.

Dentro de la Virtual Private Cloud (VPC) aislada, la subred privada de procesamiento aloja dos componentes principales: el servidor de aplicación, encargado de ejecutar el backend FastAPI como API REST del sistema, y el servidor de inferencia IA, encargado de ejecutar

TensorFlow/Keras y OpenCV para el procesamiento de imágenes retinianas y la ejecución del modelo CNN DenseNet121. Ambos componentes se comunican mediante una API REST interna sobre TCP.


Estos servidores se conectan con la subred privada de persistencia, compuesta por Amazon RDS con PostgreSQL, que almacena usuarios, registros clínicos, resultados diagnósticos y metadatos del análisis; y Amazon S3, que funciona como almacenamiento de objetos para retinografías y reportes PDF. Este diseño permite separar la lógica de aplicación, el procesamiento de inteligencia artificial y la persistencia de datos, fortaleciendo la seguridad, escalabilidad y mantenibilidad del sistema.

1.4.4 Arquitectura Integrada

A continuación, se presenta la arquitectura integrada del sistema mediante un diagrama de flujo de datos, el cual describe cómo viaja la información desde el actor externo hasta los almacenes de persistencia y el sistema clínico existente, mostrando los puntos de integración entre la solución propuesta y el ecosistema tecnológico del Consultorio V.E.R.

Figura 12

Diagrama de Arquitectura Integrada



Nota. Adaptado a partir del flujo de procesamiento de imágenes oftalmológicas, preprocesamiento, inferencia CNN, almacenamiento de resultados y generación de reportes clínicos descritos por Ejaz et al. (2024), Shamrat et al. (2024), Ticlavilca et al. (2024) y Moreno y Ticlavilca (2025).

Como se muestra en la Figura 12, la arquitectura integrada del sistema se representa mediante un diagrama de flujo de datos (DFD), mostrando la visión holística de la solución y su interacción con los componentes externos. El flujo se inicia con el personal técnico, quien carga la imagen JPG capturada con el retinógrafo hacia el proceso P1, denominado ingesta y validación. Desde este proceso, la imagen cruda es almacenada en Amazon S3 como repositorio de retinografías, mientras que la matriz de píxeles resultante es enviada al proceso P2, correspondiente al preprocesamiento y extracción de ROI.

En el proceso P2 se aplican las transformaciones necesarias para generar un tensor normalizado, el cual alimenta al proceso P3, correspondiente a la inferencia con el modelo

CNN DenseNet121. Este proceso produce un vector de probabilidades con la clasificación de la patología detectada. Dicho vector es recibido por el proceso P4, denominado consolidación y reporte, que simultáneamente envía la alerta diagnóstica con su porcentaje de confianza al médico oftalmólogo, registra y consulta los metadatos clínicos en la base de datos clínica sobre Amazon RDS, genera el documento PDF del informe y guarda una copia del mismo en Amazon S3.

Finalmente, el médico oftalmólogo revisa y valida el resultado, descarga el informe PDF y lo adjunta al sistema clínico existente del consultorio como respaldo del análisis realizado. De esta forma, la arquitectura integrada permite conectar la captura de retinografías, el procesamiento automatizado con inteligencia artificial, la validación médica y el registro documental dentro de un flujo clínico trazable y digitalizado.

1.5 Gestión del Proyecto

1.5.1 Alcance

El alcance del proyecto se manejará con un enfoque ágil basado en Scrum, usando el Product Backlog como artefacto principal para organizar, priorizar y dar seguimiento a los requerimientos funcionales y no funcionales de la solución. Este enfoque permitirá que el desarrollo de la aplicación web se haga de forma iterativa e incremental, asegurando que cada funcionalidad responda a las necesidades identificadas en el contexto del Centro Oftalmológico V.E.R. y se mantenga alineada con los objetivos específicos del proyecto.

El alcance funcional incluye el levantamiento de información sobre el flujo de atención oftalmológica, la preparación de retinografías para el entrenamiento y evaluación del modelo, el diseño e implementación de una aplicación web de soporte clínico, la integración de un modelo de Red Neuronal Convolucional para la clasificación de patologías retinianas y la validación técnica del prototipo mediante pruebas funcionales, de rendimiento y usabilidad.

Pila de Producto (Product Backlog):

El Product Backlog del proyecto estará organizado en épicas que agrupan las principales funcionalidades del sistema. Cada épica representa un componente de valor para los usuarios finales y se dividirá en historias de usuario durante la planificación de los sprints. La lista

detallada de épicas, historias de usuario, criterios de aceptación y prioridad se presentará en el Anexo 01.

Las épicas principales del proyecto son las siguientes:

- **EP01 - Gestión de acceso y roles de usuario:** Agrupa las funcionalidades relacionadas con el registro de usuarios, asignación de roles, inicio de sesión y cierre de sesión de los usuarios autorizados del sistema.
- **EP02 - Gestión de pacientes:** Agrupa las funcionalidades relacionadas con el registro, búsqueda, actualización y consulta de datos básicos del paciente dentro de la aplicación web.
- **EP03 - Registro de evaluación y carga de retinografías:** Agrupa las funcionalidades que permiten registrar una nueva evaluación retiniana, cargar imágenes de fondo de ojo y validar que los archivos sean adecuados para el análisis.
- **EP04 - Preprocesamiento de imágenes retinianas:** Agrupa las funcionalidades automáticas que preparan la retinografía antes de ser enviada al modelo CNN, incluyendo preprocesamiento, redimensionamiento, normalización de iluminación y ajuste de contraste.
- **EP05 - Inferencia con modelo CNN y resultados diagnósticos:** Agrupa las funcionalidades relacionadas con la ejecución del modelo CNN, la clasificación de la retinografía y el cálculo del porcentaje de confianza del resultado generado.
- **EP06 - Soporte al triaje visual, historial y reportes:** Agrupa las funcionalidades que permiten al médico revisar alertas, registrar observaciones, guardar resultados, consultar el historial visual del paciente y generar reportes clínicos en PDF.
- **EP07 - Administración y supervisión del prototipo:** Agrupa las funcionalidades relacionadas con la consulta general de análisis realizados y la revisión del estado de los registros almacenados en el sistema.

Historias de Usuario Representativas

El alcance funcional se detalla mediante historias de usuario, las cuales expresan las necesidades de los actores involucrados en el sistema. A continuación, se presentan historias de usuario representativas del proyecto:

Figura 13

Informe del Product Backlog

PLANTILLA DE TAREAS PENDIENTES DE PRODUCTOS

INFORME DE TAREAS PENDIENTES DE PRODUCTOS

ID	COMO ...	QUIERO ...	PARA ...	PRIORIDAD	SPRINT	ESTADO
HU01	Administrador o responsable del sistema	registrar usuarios del sistema	permitir el acceso controlado del personal autorizado	Alta	1	No se ha iniciado
HU02	Administrador o responsable del sistema	asignar roles básicos a los usuarios	limitar el acceso a funcionalidades según el perfil correspondiente	Media	1	No se ha iniciado
HU03	Personal técnico del consultorio	iniciar sesión con mis credenciales	acceder de forma segura a las funcionalidades operativas de la aplicación web	Alta	1	No se ha iniciado
HU04	Médico oftalmólogo	iniciar sesión con mis credenciales	acceder de forma segura a los resultados, historial visual y reportes clínicos	Alta	1	No se ha iniciado
HU05	Personal técnico del consultorio	cerrar sesión desde la plataforma	proteger la información clínica cuando termine de usar el sistema	Media	1	No se ha iniciado
HU06	Médico oftalmólogo	cerrar sesión desde la plataforma	proteger el acceso a la información de los pacientes al finalizar mi revisión	Media	1	No se ha iniciado
HU07	Personal técnico del consultorio	registrar los datos básicos del paciente	asociar cada retinografía a un caso clínico específico	Alta	1	No se ha iniciado
HU08	Personal técnico del consultorio	buscar pacientes registradas	ubicar rápidamente la información del paciente antes de cargar una nueva retinografía	Alta	1	No se ha iniciado
HU09	Personal técnico del consultorio	actualizar los datos básicos del paciente	mantener correcta la información asociada al caso clínico	Media	1	No se ha iniciado
HU10	Médico oftalmólogo	consultar la información básica del paciente	revisar el contexto del caso antes de evaluar los resultados generados	Media	1	No se ha iniciado
HU11	Personal técnico del consultorio	registrar una nueva evaluación retiniana	asociar la retinografía cargada con el paciente correspondiente	Alta	1	No se ha iniciado
HU12	Personal técnico del consultorio	cargar una retinografía desde la aplicación web	enviar la imagen al sistema para su análisis automatizado	Alta	1	No se ha iniciado
HU13	Personal técnico del consultorio	que el sistema valide el formato de la imagen cargada	evitar que archivos no permitidos sean procesados por el modelo	Alta	2	No se ha iniciado
HU14	Personal técnico del consultorio	que el sistema muestre un mensaje cuando la imagen cargada no sea válida	saber que debo corregir o reemplazar el archivo	Media	2	No se ha iniciado
HU15	Personal técnico del consultorio	que el sistema verifique la calidad mínima de la retinografía cargada	reducir errores durante el procesamiento e inferencia del modelo CNN	Alta	2	No se ha iniciado
HU16	Personal técnico del consultorio	que el sistema preprocese la retinografía cargada	preparar la imagen antes de enviarla al modelo CNN	Alta	2	No se ha iniciado
HU17	Personal técnico del consultorio	que el sistema redimensione la imagen de fondo de ojo	estandarizar la entrada requerida por el modelo de clasificación	Alta	2	No se ha iniciado
HU18	Personal técnico del consultorio	que el sistema normalice la iluminación y contraste de la imagen	mejorar la calidad visual de la retinografía antes del análisis	Media	2	No se ha iniciado
HU19	Médico oftalmólogo	que el sistema ejecute el modelo CNN sobre la retinografía preprocesada	obtener una clasificación automatizada de la imagen	Alta	2	No se ha iniciado
HU20	Médico oftalmólogo	que el sistema clasifique la retinografía como Retinopatía Diabética, Glaucoma o sin hallazgos patológicos	apoyar la identificación temprana de posibles patologías retinianas	Alta	2	No se ha iniciado
HU21	Médico oftalmólogo	que el sistema calcule el porcentaje de confianza de la clasificación generada	contar con una referencia sobre la seguridad del resultado obtenido	Alta	2	No se ha iniciado
HU22	Médico oftalmólogo	visualizar la clasificación generada por el modelo CNN	contar con una segunda opinión para apoyar el diagnóstico visual	Alta	2	No se ha iniciado
HU23	Médico oftalmólogo	visualizar el porcentaje de confianza del resultado	interpretar mejor el nivel de certeza de la predicción generada	Alta	2	No se ha iniciado
HU24	Médico oftalmólogo	revisar una alerta visual según el resultado obtenido	priorizar casos sospechosos que requieren mayor atención	Media	3	No se ha iniciado
HU25	Médico oftalmólogo	registrar una observación sobre el resultado generado	complementar el análisis automatizado con criterio médico	Media	3	No se ha iniciado
HU26	Médico oftalmólogo	que el sistema guarde el resultado del análisis en el historial del paciente	mantener trazabilidad de las evaluaciones realizadas	Alta	3	No se ha iniciado
HU27	Médico oftalmólogo	consultar el historial visual del paciente	revisar análisis anteriores y dar seguimiento a su evolución	Alta	3	No se ha iniciado
HU28	Médico oftalmólogo	generar y descargar un reporte clínico en formato PDF	contar con un documento de respaldo del análisis realizado	Alta	3	No se ha iniciado
HU29	Administrador o responsable del sistema	consultar el listado de análisis realizados	supervisar el uso general del prototipo en el entorno de pruebas	Baja	3	No se ha iniciado
HU30	Administrador o responsable del sistema	revisar el estado general de los registros del sistema	identificar posibles inconsistencias en pacientes, imágenes o resultados almacenados	Media	3	No se ha iniciado
				TOTAL	55	

Nota. Adaptado a partir de los stakeholders del Acta de Constitución del Proyecto

Criterios de Aceptación

Cada historia de usuario se dará por terminada cuando cumpla con los criterios de aceptación del Product Backlog y haya sido revisada al cierre del sprint correspondiente. Para asegurar la calidad de los incrementos entregados, se establecerá una Definition of Done para las funcionalidades desarrolladas.

Una funcionalidad será considerada finalizada cuando cumpla con las siguientes condiciones:

- La funcionalidad responde al objetivo de la historia de usuario y cumple sus criterios de aceptación.
- La implementación fue revisada por el equipo de desarrollo.
- Se ejecutaron pruebas funcionales básicas con resultados satisfactorios.
- No existen errores críticos pendientes asociados a la funcionalidad.
- La funcionalidad se encuentra integrada con los componentes correspondientes del sistema, cuando aplique.
- La documentación técnica o funcional relacionada fue actualizada.

- La funcionalidad fue revisada en el entorno de pruebas por el equipo del proyecto y, de ser posible, por un usuario validador o asesor.
- La funcionalidad respeta las restricciones de seguridad, privacidad y manejo de datos definidas para el proyecto.

Exclusiones del Proyecto

- Con el fin de delimitar el alcance y evitar el crecimiento descontrolado del proyecto, se establecen las siguientes exclusiones:
- El sistema no reemplaza el diagnóstico médico definitivo del oftalmólogo.
- El prototipo no será certificado como dispositivo médico ni como herramienta clínica regulada.
- No se contempla la implementación definitiva del sistema como herramienta productiva de uso clínico en el Centro Oftalmológico V.E.R. ni en otra institución médica.
- No se incluye una validación clínica formal con pacientes en atención real; la evaluación se limitará a pruebas técnicas, funcionales, de rendimiento y usabilidad en un entorno simulado o controlado.
- No se incluye la adquisición de retinógrafos ni equipamiento oftalmológico.
- No se contempla el mantenimiento físico de servidores locales en las instalaciones del consultorio.
- No se desarrollará una aplicación móvil nativa para Android o iOS.
- No se hará una integración completa con sistemas hospitalarios nacionales, plataformas del Ministerio de Salud o historias clínicas electrónicas externas.
- No se contempla una integración bidireccional completa con sistemas clínicos existentes del consultorio.
- El modelo no clasificará patologías oftalmológicas distintas a las contempladas en el proyecto, como degeneración macular, cataratas, desprendimiento de retina u otras enfermedades no definidas en el alcance.
- No se implementarán funcionalidades de telemedicina, videoconferencia o consulta remota con pacientes.

1.5.2 Cronograma

La gestión del cronograma permite organizar en el tiempo las actividades necesarias para el desarrollo del proyecto durante el periodo académico de TP1. Para ello, se toma como base

la Estructura de Desglose del Trabajo (EDT), a partir de la cual se identifican las actividades, entregables, aprobaciones y sustentaciones requeridas.

En esta sección se presentan tres elementos: la lista de hitos del proyecto, la escala de tiempo y el cronograma detallado. Estos elementos permiten ver los principales puntos de cumplimiento, la distribución general de las fases y la planificación específica de las actividades del proyecto.

Tabla 1

Lista de Hitos del Proyecto

Hito	Descripción del Hito	Fecha
H1: Entrega del Documento	Entrega del documento correspondiente al Acta de Constitución del Proyecto.	06/09/2026
H2: Aprobación del Documento	Aprobación del documento correspondiente al Acta de Constitución del Proyecto.	06/09/2026
H3: Entrega del Documento	Entrega del documento correspondiente al Product Backlog.	06/09/2026
H4: Aprobación del Documento	Aprobación del documento correspondiente al Product Backlog.	06/09/2026
H5: Entrega del Documento	Entrega del documento correspondiente al Plan de Gestión del Proyecto.	06/09/2026
H6: Aprobación del Documento	Aprobación del documento correspondiente al Plan de Gestión del Proyecto.	06/09/2026
H7: Sustentación Parcial (Metodológico)	Presentación parcial del proyecto ante el profesor metodológico.	20/09/2026

H8: Presentación de Producto (Build)	Presentación del incremento desarrollado durante el Sprint 1.	04/10/2026
H9: Aprobación del Producto (Build)	Aprobación del incremento desarrollado durante el Sprint 1.	04/10/2026
H10: Sustentación Parcial (Comité de Proyectos)	Presentación parcial del proyecto ante el Comité de Proyectos.	11/10/2026
H11: Presentación de Producto (Build)	Presentación del incremento desarrollado durante el Sprint 2.	25/10/2026
H12: Aprobación del Producto (Build)	Aprobación del incremento desarrollado durante el Sprint 2.	25/10/2026
H13: Presentación de Producto (Build)	Presentación del incremento desarrollado durante el Sprint 3.	15/11/2026
H14: Aprobación del Producto (Build)	Aprobación del incremento desarrollado durante el Sprint 3.	15/11/2026
H15: Sustentación Final (Metodológico)	Presentación final del proyecto ante el profesor metodológico.	29/11/2026
H16: Entrega del Documento	Entrega del documento correspondiente a la Memoria Final del Proyecto.	04/12/2026
H17: Entrega de Artículo	Entrega del Artículo Short Paper.	04/12/2026

H18: Aprobación del Documento	Aprobación del documento correspondiente a la Memoria Final del Proyecto.	05/12/2026
H19: Aprobación de Artículo (Coautor)	Aprobación del Artículo Short Paper por parte del coautor.	05/12/2026
H20: Sustentación Final (Comité de Proyectos)	Presentación final del proyecto ante el Comité de Proyectos.	05/12/2026
H21: Entrega de Acta de Cierre	Entrega del acta de cierre del proyecto.	05/12/2026
H22: Validación de Documentos en Carpetas	Validación final de los documentos cargados en la estructura de carpetas del proyecto.	05/12/2026

Tabla 2

Lista Base Global de Cronograma

La escala de tiempo muestra una vista resumida y visual de las principales fases, sprints e hitos del proyecto durante el periodo de TP1. Con ella se puede identificar rápido la duración de cada fase, la secuencia de los sprints, las actividades de memoria final, artículo short paper, seguimiento y control, cierre, y las fechas clave de sustentación. Asimismo, la escala de tiempo facilita el seguimiento general del avance del proyecto y la identificación de los principales entregables dentro del calendario académico.




Tabla 3*Desarrollo de Cronograma*

El cronograma del proyecto presenta la planificación detallada de las actividades definidas en la Estructura de Desglose del Trabajo (EDT) para el periodo de TP1, comprendido entre el 24 de agosto y el 05 de diciembre. Este cronograma organiza las tareas por fases: inicio, planificación, ejecución, seguimiento y control, y cierre. Asimismo, distribuye el desarrollo del proyecto en Sprint 0, Sprint 1, Sprint 2 y Sprint 3, incorporando las historias de usuario, actividades de análisis, implementación, pruebas internas, entregables principales y sustentaciones correspondientes.

Modo de tarea ▼	Nombre de tarea ▼	Duración ▼	Comienzo ▼	Fin ▼
	1 INICIO	14 días	lun 24/08/26	dom 6/09/26
	1.1 Acta de Constitución del Proyecto	14 días	lun 24/08/26	dom 6/09/26
	1.1.1 Ajustes del Documento	7 días	lun 24/08/26	dom 30/08/26
	1.1.2 Entrega del Documento	7 días	lun 31/08/26	dom 6/09/26
	1.1.3 Aprobación del Documento	7 días	lun 31/08/26	dom 6/09/26
	2 PLANIFICACIÓN	14 días	lun 24/08/26	dom 6/09/26
	2.1 Product Backlog	14 días	lun 24/08/26	dom 6/09/26
	2.1.1 Definición de Historias de Usuario	7 días	lun 24/08/26	dom 30/08/26
	2.1.2 Definición de Criterios de	7 días	lun 24/08/26	dom 30/08/26
	2.1.3 Priorización de Historias de Usuario	7 días	lun 24/08/26	dom 30/08/26
	2.1.4 Entrega del Documento	7 días	lun 31/08/26	dom 6/09/26
	2.1.5 Aprobación del Documento	7 días	lun 31/08/26	dom 6/09/26
	2.2 Plan de Gestión del Proyecto	14 días	lun 24/08/26	dom 6/09/26
	2.2.1 Definición de Gestión del Alcance	7 días	lun 24/08/26	dom 30/08/26
	2.2.2 Definición de la Gestión de Tiempo	7 días	lun 24/08/26	dom 30/08/26
	2.2.3 Definición de la Gestión de Recursos	7 días	lun 24/08/26	dom 30/08/26
	2.2.4 Definición de la Gestión de Riesgos	7 días	lun 31/08/26	dom 6/09/26
	2.2.5 Definición de la Gestión de Costos	7 días	lun 31/08/26	dom 6/09/26
	2.2.6 Definición de la Gestión de Calidad	7 días	lun 31/08/26	dom 6/09/26
	2.2.7 Entrega del	7 días	lun 31/08/26	dom 6/09/26

1.5.3 Costos

La gestión de costos del proyecto permite estimar el presupuesto necesario para ejecutar las actividades planificadas durante el periodo de TP1. Para ello, se consideran los recursos humanos, gastos generales, bienes, herramientas tecnológicas, infraestructura y servicios necesarios para el desarrollo de la aplicación web de soporte clínico basada en Redes Neuronales Convolucionales.

Los montos presentados son estimaciones referenciales en soles peruanos (S/.), considerando que todo recurso usado en el proyecto representa un costo, incluso cuando sea proporcionado por los integrantes del equipo, la universidad o herramientas de uso académico. El objetivo de esta estimación es identificar el costo real del proyecto y contar con una referencia presupuestal para su planificación.

Tabla 4

Costos de Personal

N ^o	Rol	Participación (%)	Unidad	Cantidad	Sueldo (S/.)	Total (S/.)
1	Project Manager / Desarrollador 1	100%	Mes	4	1,500	6,000
2	Scrum Master / Desarrollador 2	100%	Mes	4	1,500	6,000
3	Asesor del Proyecto	100%	Hora	16	50	800
4	Usuario validador / Representante clínico	100%	Hora	8	80	640
Total Personal						13,440

Nota. Los costos de personal se estiman considerando la participación de los integrantes del equipo, el asesor y un usuario validador o representante clínico. Aunque los integrantes del proyecto desarrollen las actividades con fines académicos, su dedicación representa un costo de mano de obra que debe ser valorizado.

Tabla 5*Costos Gastos Generales*

Nº	Descripción	Unidad	Cantidad	Costo (S/.)	Total (S/.)
1	Transporte para reuniones, visitas o validaciones del cliente.	Mes	4	160	640
2	Servicio de internet	Mes	4	180	720
3	Energía eléctrica	Mes	4	300	1,200
4	Agua y servicios básicos proporcionales	Mes	4	250	1,000
5	Impresiones y material de escritorio	Mes	4	80	320
Total Gastos Generales					3880

Nota. Los gastos generales consideran recursos operativos necesarios para el desarrollo del proyecto. Aunque algunos servicios sean utilizados desde el hogar o la universidad, se valorizan como costos proporcionales asociados a la ejecución del trabajo.

Tabla 6*Costos Bienes y Subcontrata (servicios contratados a terceros)*

Nº	Descripción	Unidad	Cantidad	Costo (S/.)	Total (S/.)
1	Uso/depreciación de laptop del integrante 1	Mes	4	150	600
2	Uso/depreciación de laptop del integrante 2	Mes	4	150	600
3	Licencias ofimáticas, herramientas de gestión y documentación.	Mes	4	300	1,200
4	Servicios cloud para pruebas de backend, base de datos y almacenamiento	Mes	4	150	600

5	Recursos computacionales para entrenamiento o evaluación del modelo CNN	Mes	4	250	1,000
6	Dominio web o configuración de entorno de pruebas	Mes	4	70	280
7	Almacenamiento y respaldo documental en la nube	Mes	4	100	400
Total Bienes y Subcontrata					4,680

Nota. Los costos de bienes y subcontrata incluyen el uso proporcional de equipos personales, herramientas tecnológicas, servicios cloud y recursos computacionales necesarios para el desarrollo y validación técnica del prototipo. Los valores son referenciales y pueden variar según la disponibilidad de recursos académicos o servicios gratuitos

Tabla 7

Resumen de Costos

Nº	Descripción	Total (S/.)
1	Personal	13,440
2	Gastos Generales	3,880
3	Bienes y Subcontrata	4,680
Total		22,000

Nota. El costo total estimado del proyecto para el periodo de TP1 asciende a S/. 22,000. El componente más representativo corresponde al costo de personal, debido a la dedicación requerida para la planificación, análisis, diseño, implementación, pruebas y documentación del proyecto.

1.5.4 Calidad

La gestión de calidad del proyecto busca que los entregables desarrollados cumplan con los requisitos funcionales, técnicos, documentales y de validación definidos para la aplicación web de soporte clínico basada en Redes Neuronales Convolucionales. Para ello, se consideran estándares de calidad aplicables al desarrollo de software, seguridad de la información, gestión de requisitos, documentación, pruebas y evaluación del modelo predictivo.

Además, se establecen procedimientos de control de calidad orientados a revisar el cumplimiento de las historias de usuario, validar la calidad del código, verificar la correcta ejecución de pruebas internas, controlar la calidad de las retinografías usadas y evaluar el desempeño del modelo CNN mediante métricas de ingeniería. Finalmente, se definen métricas de gestión del proyecto y métricas de ingeniería que permitirán medir el avance, la calidad del producto y el rendimiento técnico de la solución.

Tabla 8

Estándares de Calidad

Nº	Nombre del Estándar	Breve descripción del Estándar
1	ISO/IEC 25010 - Calidad de Software	Se usará como referencia para evaluar atributos de calidad del sistema, como adecuación funcional, usabilidad, seguridad, eficiencia de rendimiento, mantenibilidad y fiabilidad.
2	ISO/IEC/IEEE 12207 - Ciclo de Vida del Software	Permitirá organizar las actividades del ciclo de vida del desarrollo de software, considerando planificación, análisis, diseño, implementación, pruebas, mantenimiento y documentación.
3	ISO/IEC/IEEE 29148 - Ingeniería de Requisitos	Servirá como referencia para la definición, documentación y validación de requerimientos funcionales y no funcionales mediante historias de usuario, criterios de aceptación y Product Backlog.
4	ISO/IEC 27001 - Seguridad de la Información	Se usará como referencia para aplicar controles relacionados con confidencialidad, integridad y disponibilidad de la información, especialmente por el manejo de imágenes médicas y datos sensibles.
5	Ley N.º 29733 - Ley de Protección de Datos Personales	Se considerará como marco normativo para el manejo responsable de datos personales y clínicos, promoviendo la anonimización, el control de acceso y el uso autorizado de la información.
6	Guía de estilo APA 7. ^a edición	Se usará para asegurar la calidad formal del informe académico, la correcta citación de fuentes y la presentación de tablas, figuras y referencias bibliográficas.

Tabla 9

Procedimientos de Calidad

Nº	Nombre del Procedimiento	Breve descripción del Procedimiento
----	--------------------------	-------------------------------------

1	Revisión y validación de requerimientos	Se verificará que las historias de usuario, criterios de aceptación y requerimientos no funcionales estén alineados con el alcance del proyecto y con las necesidades de los usuarios directos del sistema, tomando como referencia la ingeniería de requisitos.
2	Control del Product Backlog	Se revisará periódicamente la claridad, prioridad, sprint asignado y estado de las historias de usuario, asegurando la trazabilidad entre épicas, requerimientos, entregables y objetivos del proyecto.
3	Revisión de código y buenas prácticas de programación	Se revisará que el código desarrollado mantenga una estructura clara, modular y comprensible, aplicando buenas prácticas de Clean Code para reducir duplicidad, errores y dificultad de mantenimiento.
4	Control de versiones del software	Se gestionarán los cambios del código fuente, documentación y componentes del prototipo mediante un repositorio de versiones, con el fin de mantener trazabilidad de los avances y evitar pérdida de información.
5	Pruebas funcionales internas	Se ejecutarán pruebas sobre las funcionalidades principales del sistema, incluyendo acceso, gestión de pacientes, carga de retinografías, visualización de resultados, historial visual y generación de reportes.
6	Pruebas de integración	Se verificará la comunicación entre los componentes principales de la solución, como frontend, backend, base de datos y servicio de inferencia del modelo CNN, para asegurar su funcionamiento conjunto.
7	Control de calidad de datos e imágenes	Se revisará que las retinografías usadas cumplan condiciones mínimas de formato, legibilidad, calidad visual y organización antes de emplearlas en el entrenamiento, prueba o validación técnica del modelo.
8	Evaluación del modelo CNN	Se evaluará el desempeño del modelo mediante métricas de clasificación como Accuracy, Precision, Recall, F1-Score y AUC-ROC, con el fin de verificar su capacidad para diferenciar entre Retinopatía Diabética, Glaucoma o ausencia de hallazgos patológicos.
9	Procedimiento de seguridad y privacidad de datos	Se aplicarán controles básicos de acceso, anonimización de datos y manejo responsable de imágenes médicas, considerando principios de seguridad, privacidad por diseño y protección de datos personales.

10	Pruebas de rendimiento	Se evaluará el comportamiento del sistema frente a escenarios de carga o uso concurrente, verificando tiempos de respuesta, estabilidad del prototipo y capacidad de procesamiento de retinografías.
11	Pruebas de usabilidad	Se revisará la facilidad de uso de la interfaz web con usuarios validadores, considerando claridad de navegación, comprensión de resultados, carga de imágenes y generación de reportes.
12	Gestión de no conformidades y acciones correctivas	Se registrarán errores, observaciones o incumplimientos detectados durante revisiones, pruebas o validaciones, definiendo acciones correctivas antes de la entrega final del proyecto.
13	Control documental del informe académico	Se revisará la estructura del documento, redacción, coherencia, numeración de tablas y figuras, citas, referencias bibliográficas y cumplimiento del formato académico establecido.
14	Seguimiento de calidad por sprint	Al cierre de cada sprint se verificará el cumplimiento de las historias de usuario planificadas, pruebas internas, integración del incremento y observaciones pendientes para el siguiente ciclo.

Tabla 10

Métricas de Calidad

Tipo [Gestión/Ingeniería]	Nombre de la Métrica	Descripción de la Métrica	Fórmula de Cálculo
Gestión	Cumplimiento del cronograma	Mide el porcentaje de actividades completadas dentro de las fechas planificadas en el cronograma del proyecto.	$(\text{Actividades completadas a tiempo} / \text{Total de actividades planificadas}) \times 100$
Gestión	Avance de historias de usuario	Mide el porcentaje de historias de usuario completadas respecto al total planificado en el Product Backlog.	$(\text{HU completadas} / \text{Total de HU planificadas}) \times 100$

Gestión	Cumplimiento de entregables	Mide el porcentaje de entregables aprobados respecto al total de entregables definidos para el proyecto.	$(\text{Entregables aprobados} / \text{Total de entregables planificados}) \times 100$
Gestión	Cierre de observaciones	Mide el porcentaje de observaciones corregidas después de revisiones del asesor, comité o equipo del proyecto.	$(\text{Observaciones corregidas} / \text{Total de observaciones registradas}) \times 100$
Gestión	Cumplimiento del presupuesto	Mide la relación entre el costo ejecutado y el costo estimado del proyecto.	$(\text{Costo ejecutado} / \text{Costo presupuestado}) \times 100$
Ingeniería	Accuracy / Exactitud	Mide el porcentaje de clasificaciones correctas hechas por el modelo CNN sobre el total de retinografías evaluadas.	$(VP + VN) / (VP + VN + FP + FN)$
Ingeniería	Precisión / Precisión	Mide la proporción de predicciones positivas correctas respecto al total de predicciones positivas del modelo.	$VP / (VP + FP)$
Ingeniería	Recall / Sensibilidad	Mide la capacidad del modelo para detectar correctamente los casos positivos de Retinopatía Diabética o Glaucoma.	$VP / (VP + FN)$
Ingeniería	Specificity / Especificidad	Mide la capacidad del modelo para	$VN / (VN + FP)$

		identificar correctamente los casos negativos o sin presencia de la patología evaluada.	
Ingeniería	F1-Score	Mide el equilibrio entre Precisión y Recall, especialmente útil cuando hay desbalance entre clases.	$2 \times (\text{Precision} \times \text{Recall}) / (\text{Precision} + \text{Recall})$
Ingeniería	AUC-ROC	Mide la capacidad del modelo para distinguir entre clases mediante el área bajo la curva ROC.	Área bajo la curva ROC calculada a partir de TPR y FPR
Ingeniería	Tiempo de inferencia	Mide el tiempo que tarda el modelo CNN en generar una clasificación a partir de una retinografía preprocesada.	Σ tiempos de inferencia / Número de imágenes evaluadas
Ingeniería	Tiempo promedio de respuesta del sistema	Mide el tiempo desde la carga de la retinografía hasta la visualización del resultado en la aplicación web.	Σ tiempos de respuesta / Número de pruebas ejecutadas
Ingeniería	Tasa de errores funcionales	Mide el porcentaje de pruebas funcionales que presentan errores durante la ejecución del prototipo.	$(\text{Pruebas con error} / \text{Total de pruebas ejecutadas}) \times 100$
Ingeniería	Tasa de imágenes rechazadas	Mide el porcentaje de retinografías rechazadas por no cumplir con los criterios mínimos de	$(\text{Imágenes rechazadas} / \text{Total de imágenes cargadas}) \times 100$

		formato o calidad visual.	
Ingeniería	Usabilidad del sistema	Mide el nivel de facilidad de uso de la interfaz web por parte de usuarios validadores.	Evaluación mediante cuestionario de usabilidad o escala SUS
Ingeniería	Cobertura de pruebas funcionales	Mide el porcentaje de funcionalidades principales evaluadas mediante pruebas internas o de integración.	$(\text{Funcionalidades probadas} / \text{Total de funcionalidades desarrolladas}) \times 100$

1.5.5 Riesgos

La gestión de riesgos del proyecto permite identificar eventos inciertos que podrían afectar el cumplimiento del alcance, cronograma, presupuesto o calidad de la solución propuesta. Para ello, se presenta una matriz de riesgos donde se describe cada posible evento, su nivel de impacto, su probabilidad de ocurrencia y las acciones de respuesta planteadas para reducir o controlar sus efectos durante el desarrollo del proyecto.

Tabla 11

Matriz de Riesgos

ID	Descripción del Riesgo	Impacto	Probabilidad de Ocurrencia (Alto, Medio, Bajo)	Acciones de Respuesta
1	Baja calidad del modelo CNN debido a una precisión insuficiente en la clasificación de Retinopatía	Mayor (4)	Media	Mitigar: Aplicar Transfer Learning, Data Augmentation, balanceo de datos y evaluación con métricas como Accuracy, Recall y F1-Score.

	Diabética y Glaucoma.			
2	Baja calidad del modelo CNN debido al uso de retinografías insuficientes, desbalanceadas o con baja calidad visual.	Mayor (4)	Media	Mitigar: Utilizar datasets públicos y/o retinografías autorizadas y anonimizadas del Centro Oftalmológico V.E.R.; aplicar preprocesamiento y control de calidad de imágenes.
3	Retraso en el cronograma del proyecto debido a demoras en el acceso a información del flujo oftalmológico o a retinografías proporcionadas por el centro.	Mayor (4)	Media	Mitigar: Solicitar la información con anticipación y considerar datasets públicos como alternativa para continuar el desarrollo sin detener el avance.
4	Retraso en el cronograma del proyecto debido a la complejidad técnica de integrar el frontend, backend, base de datos y modelo CNN.	Moderado (3)	Media	Mitigar: Definir endpoints desde etapas tempranas, documentar la API, realizar pruebas de integración progresivas y desarrollar el sistema por módulos.
5	Incremento del presupuesto del proyecto debido a la	Moderado (3)	Media	Mitigar: Utilizar modelos preentrenados, optimizar el tamaño de las

	necesidad de recursos computacionales adicionales para entrenamiento o inferencia del modelo CNN.			imágenes y emplear recursos académicos, locales o cloud de bajo costo.
6	Incremento del presupuesto y riesgo legal debido al manejo inadecuado de imágenes médicas o datos sensibles.	Crítico (5)	Baja	Evitar: Usar únicamente datos autorizados y anonimizados, evitar información identificable de pacientes y considerar la Ley N.º 29733 para el tratamiento de datos personales.
7	Baja calidad de la experiencia de usuario debido a que la interfaz no se adapte al flujo de trabajo del personal técnico y médico.	Moderado (3)	Media	Mitigar: Diseñar mockups previos, recoger retroalimentación de usuarios y ajustar la interfaz antes de la validación final.
8	Incremento del plazo del proyecto debido a cambios en el alcance o retroalimentación tardía del asesor o comité.	Moderado (3)	Media	Mitigar: Mantener actualizado el Product Backlog, priorizar funcionalidades del MVP y registrar formalmente los cambios de alcance.
9	Baja calidad del sistema debido a	Mayor (4)	Media	Mitigar: Elaborar un plan de pruebas, ejecutar casos

pruebas funcionales, de rendimiento o usabilidad insuficientes.		funcionales, documentar evidencias y corregir incidencias antes de la sustentación final.
---	--	---

1.6 Benchmarking

El Informe de Benchmarking se encuentra en el Anexo 04, el cual presenta un análisis comparativo orientado a evaluar la propuesta técnica frente a las mejores prácticas del mercado, los estándares de la industria y las soluciones de la competencia.

2 Marco Teórico

2.1 Definiciones

2.1.1 *Inteligencia Artificial en salud*

La integración de la inteligencia artificial (IA) en el sector salud representa un cambio tecnológico sin precedentes, impulsado por la necesidad de optimizar los recursos médicos y mejorar la detección temprana de enfermedades crónicas. Este campo de la informática permite procesar y analizar grandes volúmenes de datos clínicos e imágenes diagnósticas con mayor rapidez y precisión que los métodos manuales tradicionales (Orlova, 2024). Al imitar el razonamiento cognitivo mediante algoritmos, la IA no solo reduce los errores causados por la fatiga visual de los especialistas, sino que además facilita el acceso a evaluaciones de calidad en la atención primaria. A continuación se abordan los conceptos teóricos fundamentales: qué es la IA, en qué se diferencia estructuralmente del aprendizaje profundo y cuáles son sus aplicaciones clínicas actuales.

2.1.1.1 *Definición de Inteligencia Artificial (IA)*

Según IBM (s.f.), la Inteligencia Artificial (IA) es una rama de la informática orientada a crear sistemas capaces de realizar tareas que normalmente requieren inteligencia humana, como el aprendizaje y el reconocimiento visual. A diferencia de los métodos manuales, arquitecturas como el aprendizaje profundo facilitan la interpretación de datos complejos en el ámbito médico, permitiendo intervenciones clínicas más exactas.

Por lo tanto, en el presente proyecto, la IA actuará como el motor central de una aplicación web de soporte clínico (CAD), superando ampliamente las limitaciones de una simple base de datos estática. Debido a esta integración, el sistema podrá evaluar de manera autónoma las retinografías capturadas en clínicas oftalmológicas, generando una comparación analítica que brindará a los especialistas una segunda opción algorítmica para acelerar el proceso de triaje inicial en el área metropolitana de Lima.

2.1.1.2 Machine Learning vs Deep Learning

De acuerdo con IBM (s.f.), el Machine Learning (Aprendizaje Automático) es una rama de la IA donde el analista debe extraer manualmente los atributos para que el algoritmo logre aprender y predecir. Por otro lado, el Deep Learning (Aprendizaje Profundo) utiliza redes neuronales de múltiples capas que automatizan por completo la extracción jerárquica desde datos no estructurados, como es el caso del audio o las imágenes. Debido a esta diferencia técnica fundamental, para nuestra propuesta se descartó el aprendizaje automático tradicional y se adoptó un método riguroso de aprendizaje profundo mediante redes neuronales convolucionales (CNN). La implementación de este método resulta necesario para el desarrollo del sistema, ya que evita la tarea de que médicos o programadores segmenten a mano elementos como los vasos sanguíneos o el nervio óptico. De este modo, el modelo procesará directamente los píxeles de las retinografías desde su estado bruto y detecta las anomalías visuales con la alta precisión que exige la visión artificial.

2.1.1.3 Aplicaciones en medicina

Respecto a la integración clínica, Faiyazuddin et al. (2024) y Parmar et al. (2024) exponen que la adopción de la IA abarca áreas desde el desarrollo de fármacos y registros electrónicos hasta la medicina personalizada. Sin embargo, si analizamos su impacto directo, el procesamiento de imágenes médicas es donde ocurre el mayor avance. A diferencia de las evaluaciones tradicionales, los actuales algoritmos logran igualar o incluso superar el rendimiento de un experto humano cuando detectan anomalías en radiografías, resonancias y tomografías. En consecuencia, la implementación de este soporte técnico reduce de forma notable los errores diagnósticos y acorta los tiempos de respuesta dentro de la gestión hospitalaria.

De acuerdo con lo anterior, la aplicación web utilizará el procesamiento de imágenes asistido por IA para mitigar la severa saturación que enfrenta el Instituto Nacional de Oftalmología (INO). Al distribuir las funciones de diagnóstico a los consultorios de atención primaria, el sistema permitirá identificar signos de glaucoma y retinopatía diabética de forma temprana y rápida, previniendo la ceguera irreversible en la población al garantizar que solo los pacientes de alto riesgo reciban tratamiento avanzado.

2.1.2 *Redes Neuronales Convolucionales (CNN)*

Las Redes Neuronales Convolucionales (CNN) operan bajo principios matemáticos que emulan la corteza visual humana, optimizando el procesamiento de datos espaciales. A diferencia de los algoritmos tradicionales, donde el programador extraía las características de forma manual, las CNN identifican patrones jerárquicos de manera autónoma (Shamrat et al., 2024). Este proceso va desde detectar bordes geométricos simples hasta reconocer estructuras anatómicas complejas en el fondo del ojo. En el entorno clínico, procesar estas matrices visuales de alta dimensión permite localizar alteraciones sutiles a nivel de píxel que una evaluación manual rápida pasaría por alto (Shamrat et al., 2024). A continuación se detallan los fundamentos estructurales del modelo: su definición, la arquitectura de convolución y el uso del aprendizaje por transferencia.

2.1.2.1 *Definición de Redes Neuronales Convolucionales (CNN)*

Las Redes Neuronales Convolucionales (CNN) son parte del aprendizaje profundo y fueron diseñadas para procesar datos en cuadrícula, como las matrices de píxeles de imágenes digitales. A diferencia de las redes convencionales, no trabajan con reglas fijas sino con operaciones convolucionales que identifican características espaciales y locales. De esta manera, preservan las relaciones estructurales y la forma original de la imagen durante el análisis (Latif et al., 2024).

De este modo, las CNN son un componente crítico en el razonamiento clínico. En lugar de programar reglas estrictas o extraer manualmente mediciones de los globos oculares, el modelo procesará de forma autónoma las matrices de píxeles de las imágenes retinianas. Así, identifica patrones invisibles para el ojo humano y clasifica a las personas según su riesgo de padecer glaucoma o retinopatía diabética.

2.1.2.2 *Arquitectura (capas, convolución, pooling)*

Las CNN están compuestas por tres capas principales. La capa convolucional aplica filtros matemáticos para extraer características, generando mapas de bordes y texturas anatómicas. La capa de agrupación o pooling, por su parte, realiza un submuestreo que reduce la dimensión espacial de los datos y disminuye la carga computacional. Finalmente, la capa totalmente conectada o fully connected es la

responsable de generar los resultados para la clasificación probabilística de la patología (Mamyrbayev et al., 2025).

En el desarrollo de esta aplicación web, esta arquitectura permite un procesamiento eficiente de las imágenes del fondo de ojo. Las capas convolucionales y de agrupación segmentan automáticamente las características oftálmicas importantes (como las redes vasculares y las cabezas del nervio óptico) mediante la compresión de la imagen original. Finalmente, la capa conectada generará resultados binarios o multiclase, que el servidor enviará a la pantalla del médico, lo que resultará en una respuesta de baja latencia.

2.1.2.3 Aplicación en imágenes médicas

En el campo biomédico, las redes neuronales convolucionales (CNN) han demostrado una eficacia excepcional en los Sistemas de Soporte al Diagnóstico (CAD). Su aplicación a la retinografías ha permitido la detección temprana y simultánea de afecciones complejas como el glaucoma y la retinopatía diabética, alcanzando una precisión superior al 98%, comparable a la evaluación visual realizada por expertos clínicos, a la vez que reduce significativamente la tasa de falsos negativos (Arias-Serrano et al., 2024; Henge et al., 2025).

Dentro del flujo de atención propuesto para los consultorios en Lima Metropolitana, la aplicación de esta tecnología reducirá directamente la fatiga visual de los oftalmólogos. Al confiar la evaluación inicial de las imágenes retinianas a un algoritmo, los profesionales médicos solo necesitarán verificar las predicciones del sistema en lugar de examinar cada imagen desde cero, lo que mejorará significativamente la capacidad de triaje de la clínica.

2.1.2.4 Transfer Learning en CNN

El Transfer Learning es una técnica que permite adaptar un modelo preentrenado en un conjunto de datos extenso, como ImageNet, a una tarea nueva y específica. Sus ventajas son claras: reduce la necesidad de grandes volúmenes de datos, acelera la convergencia computacional durante el entrenamiento y mejora la precisión final al reutilizar pesos sinápticos que ya identifican patrones visuales comunes (TensorFlow, 2022).

Por ende, recopilar localmente decenas de miles de imágenes retinianas etiquetadas es una dificultad logística real, por eso este proyecto empleará Transfer Learning con arquitecturas como ResNet50 y VGG16. Se aprovecharán los filtros visuales del modelo base y se aplicará un ajuste fino solo a la capa final, usando el conjunto de datos oftálmicos del proyecto. Con eso, se espera lograr una alta eficiencia en su implementación en la nube.

2.1.3 *Procesamiento de imágenes médicas*

El procesamiento digital de imágenes médicas agrupa técnicas computacionales para adquirir, mejorar, analizar y extraer información cuantitativa de representaciones visuales anatómicas. Las capturas clínicas suelen presentar dificultades como ruido del sensor, variaciones de iluminación y diferencias de resolución según el equipo utilizado. Por esa razón, analizar directamente los datos brutos suele degradar el rendimiento de los modelos predictivos (Infante & Cruzado, 2024).

En el aprendizaje profundo, esta fase de ajuste computacional es entonces clave. Funciona como un puente que transforma y normaliza las matrices de datos espaciales antes de ingresarlas a la red neuronal, lo que reduce el sesgo matemático, fortalece la robustez del modelo y asegura la viabilidad clínica del sistema. A continuación, se detallan las etapas de ese flujo de trabajo, desde los conceptos matemáticos de las figuras retinianas y el filtrado de ruido, hasta el aumento de datos y la clasificación automatizada.

2.1.3.1 *Imágenes de fondo de ojo*

Las retinografías, también conocidas como imágenes del fondo de ojo, son fotografías bidimensionales no invasivas que registran la superficie interna del globo ocular. Capturan estructuras como la retina, la mácula, la cabeza del nervio óptico y la red vascular. En el campo de la visión artificial aplicada a la medicina, estas imágenes se convierten en la materia prima, es decir, en la matriz de píxeles a partir de la cual los algoritmos de inteligencia artificial extraen características, realizan análisis clínicos y diagnostican retinopatía (Shamrat et al., 2024).

Dentro de la arquitectura de la solución, estas imágenes constituyen el tensor de entrada del sistema. Las retinografías capturadas por el personal técnico se cargarán en una plataforma web, donde se transforman en una matriz numérica que luego se

procesa y envía a un modelo de Deep Learning en la nube. De esa forma, es posible evaluar la salud ocular del paciente sin depender exclusivamente de la inspección visual de un médico.

2.1.3.2 Preprocesamiento

El preprocesamiento consiste en la aplicación de transformaciones algorítmicas iniciales para eliminar el ruido, normalizar la iluminación y estandarizar la resolución espacial de las imágenes. Según Infante y Cruzado (2024), la implementación rigurosa de etapas de preprocesamiento es esencial para la automatización del diagnóstico visual, ya que garantiza que el modelo se centre en las características patológicas relevantes y no en los artefactos o reflejos generados por la cámara.

En el desarrollo de este sistema CAD, la región de interés (el globo ocular) se aislará en la etapa de preprocesamiento eliminando los bordes oscuros irrelevantes de la imagen retiniana. Además, mediante la aplicación de técnicas de redimensionamiento uniforme y ecualización de contraste, las imágenes del V.E.R. Centro Oftalmológico se vuelven compatibles matemática y visualmente con la arquitectura de red neuronal elegida.

2.1.3.3 Clasificación automatizada

La clasificación automatizada en el procesamiento de imágenes médicas es un procedimiento en el que un modelo algorítmico extrae y procesa las características espaciales de la entrada visual y luego asigna etiquetas diagnósticas discretas. En arquitecturas de Redes Neuronales Convolucionales (CNN), este proceso se realiza en capas totalmente conectadas, que evalúan los patrones anómalos detectados y calculan probabilidades matemáticas para clasificar la imagen en clases específicas, como tejido sano o patológico (Rahim et al., 2024).

En la etapa final del proceso del proyecto, el modelo realizará esta clasificación automatizada y proporcionará un diagnóstico estimado en tiempo real. La plataforma web recibirá los resultados de la clasificación de este algoritmo y la presentará en la interfaz del oftalmólogo como alertas visuales claras (por ejemplo, "Sospecha de glaucoma" con su respectivo porcentaje de confianza). Con esta

automatización de resultados, se reduce el tiempo de triaje y se puede priorizar la atención de los pacientes con mayor riesgo de ceguera en el área metropolitana de Lima.

2.1.3.4 Data Augmentation

El Data Augmentation es una técnica del aprendizaje profundo que busca mejorar el rendimiento del modelo incrementando artificialmente el tamaño del conjunto de entrenamiento. Además, genera nuevas muestras a partir de las imágenes originales (Chandola et al., 2024). Los autores señalan que esta estrategia es especialmente relevante en el procesamiento de imágenes biomédicas, donde obtener grandes conjuntos de datos es difícil debido a los altos costos operativos, el trabajo manual de anotación y las estrictas regulaciones de privacidad del paciente (Chandola et al., 2024).

En este estudio, su aplicación responde directamente al desafío de no poder obtener localmente una gran base de datos de imágenes de retina. Al aumentar artificialmente el conjunto de imágenes de fondo de ojo, se garantiza que la CNN cuente con suficientes muestras para aprender patrones patológicos. Así se evita el sobreajuste y se asegura que la aplicación web pueda realizar diagnósticos precisos en clínicas del área metropolitana de Lima.

2.1.3.4.1 Técnicas aplicadas (rotación, volteo y zoom)

Dentro de las técnicas de aumento de datos, las transformaciones afines o geométricas figuran entre los enfoques más empleados y efectivos para el procesamiento de imágenes médicas (Chandola et al., 2024). Entre las más relevantes se encuentran la rotación, que gira la imagen preservando la integridad anatómica; el volteo o reflejo, que invierte la imagen sobre sus ejes vertical u horizontal; y el zoom o escalado, que amplía una porción de la imagen para que el modelo pueda adaptarse a distintos tamaños y resoluciones de los elementos de interés (Chandola et al., 2024).

Durante el entrenamiento del modelo, estas transformaciones geométricas se aplicarán de manera sistemática sobre las imágenes del conjunto de datos. Rotar, voltear y ampliar las imágenes de la retina permite simular las variaciones naturales de posición y enfoque que ocurren durante la captura por parte del

personal técnico. Esto favorece la detección de glaucoma y retinopatía diabética sin depender de las condiciones en que se tomó la imagen.

2.1.4 *Sistemas CAD (Computer-Aided Diagnosis)*

La creciente demanda de servicios médicos especializados, sumada a la escasez de personal sanitario, ha impulsado la incorporación de soluciones tecnológicas en los flujos de trabajo clínicos. Ante ese escenario, los Sistemas de Diagnóstico Asistido por Computadora (CAD) han surgido desde la ingeniería de software y las ciencias de la computación como respuesta a la saturación hospitalaria y la necesidad de optimizar los procesos de tamizaje visual (Infante & Cruzado, 2024). A diferencia de los registros médicos electrónicos tradicionales, que funcionan como repositorios pasivos de información, los sistemas CAD modernos operan como ecosistemas analíticos activos. Procesan grandes volúmenes de datos e imágenes médicas, generan evaluaciones cuantitativas y reducen la subjetividad del criterio humano (Ejaz et al., 2024). A continuación se abordan los fundamentos conceptuales de estos sistemas, su rol en la toma de decisiones clínicas y los avances que ha traído su integración con algoritmos de inteligencia artificial.

2.1.4.1 *Definición y rol en apoyo al diagnóstico*

Los Sistemas de Diagnóstico Asistido por Computadora (CAD) son herramientas informáticas que apoyan a los profesionales de la salud en la interpretación de imágenes médicas. No buscan reemplazar el juicio clínico del especialista, sino funcionar como una segunda opinión objetiva que señala áreas de interés, reduce los errores por fatiga visual y disminuye la variabilidad entre observadores durante el despistaje (Infante & Cruzado, 2024).

En este contexto, el sistema CAD se implementará en la aplicación web. Su función en el Centro de Oftalmología V.E.R. será transformar los flujos de trabajo analógicos existentes en un sistema de triaje asistido digitalmente. Cuando los oftalmólogos examinen a los pacientes, el sistema ya habrá analizado las imágenes de la retina y presentará los resultados del diagnóstico visual, lo que permite una evaluación mucho más rápida del estado de la retina y reduce la carga de trabajo en la clínica.

2.1.4.2 Integración con IA

Tradicionalmente, los sistemas CAD dependían de algoritmos matemáticos, lo que requería que los programadores definieran manualmente las características (como bordes y contraste) de las imágenes. La integración del aprendizaje profundo ha permitido que los sistemas CAD actuales identifiquen biomarcadores complejos de forma autónoma. Esto les permite procesar múltiples afecciones simultáneamente y mejorar su precisión al trabajar con grandes volúmenes de datos clínicos (Ejaz et al., 2024).

A partir de ello, la integración propuesta conecta una interfaz web con un servidor que aloja una CNN. Con eso, el sistema CAD deja de ser un simple repositorio de registros médicos y se convierte en un entorno interoperable e inteligente, capaz de ejecutar inferencias en la nube y brindar soporte diagnóstico de alta precisión para afecciones asintomáticas como el glaucoma y la retinopatía diabética.

2.1.5 Infraestructura tecnológica

La digitalización progresiva de los centros médicos ha convertido la infraestructura tecnológica en un componente central de la modernización del sector salud. Incorporar soluciones de computación distribuida permite superar las restricciones de los sistemas locales cerrados, habilitando un acceso seguro y en tiempo real a la información clínica desde distintos puntos de atención. Este entorno digital sostiene la disponibilidad continua de los servicios de apoyo diagnóstico mediante aplicaciones web modernas, respaldadas por arquitecturas de red eficientes y computación en la nube. Además, esta descentralización tecnológica reduce los costos operativos de hardware y sienta las bases para implementaciones a mayor escala (MarketsandMarkets, 2025). A partir de eso, se describen los componentes informáticos de dicha infraestructura: las aplicaciones web en salud, el paradigma cliente-servidor, los sistemas clínicos en línea y la computación en la nube.

2.1.5.1 Aplicaciones web en salud

Las aplicaciones web en entornos sanitarios son herramientas de software alojadas en servidores remotos y accesibles desde cualquier navegador, sin necesidad de instalar nada en los equipos del centro de salud. Su relevancia en la gestión médica

moderna radica en que centralizan el manejo de historiales clínicos, facilitan la visualización de resultados y permiten ejecutar herramientas de inteligencia artificial de forma remota, asegurando que el personal sanitario opere siempre con las versiones más recientes del sistema bajo estrictos protocolos de ciberseguridad (Cao et al., 2024).

En el desarrollo de este proyecto, la aplicación web actúa como punto de interacción directa entre los oftalmólogos y los algoritmos de inteligencia artificial. Al ser una herramienta web, el personal del Centro Oftalmológico V.E.R. no necesita equipos de alto rendimiento ni instalar programas adicionales. Solo acceden desde su navegador habitual, suben las imágenes de retina y obtienen los resultados diagnósticos en una interfaz sencilla e intuitiva.

2.1.5.2 Arquitectura cliente-servidor

La arquitectura cliente/servidor constituye un modelo de diseño de software distribuido en el que las tareas computacionales se distribuyen entre proveedores de recursos (servidores) y solicitantes de servicios (clientes). Bajo este esquema, los nodos cliente se encargan de renderizar las interfaces gráficas y recopilar los datos de entrada del usuario, mientras que el servidor centraliza la lógica de negocio, el procesamiento computacional y el acceso a la base de datos. Esta separación favorece un flujo de información ordenado y escalable, condición especialmente relevante para resguardar la integridad de los datos médicos frente a vulnerabilidades locales (Cao et al., 2024; Kamani, 2024).

En la arquitectura del sistema propuesto, este modelo se logra mediante una clara separación de las responsabilidades técnicas. El cliente (frontend), desarrollado con tecnologías web modernas, gestiona la experiencia visual del oftalmólogo y la carga de imágenes en la consulta. Por su parte, el servidor (backend) recibe las imágenes de la retina, invoca un modelo de Deep Learning alojado en la nube para realizar inferencias matemáticas y devuelve los resultados de diagnóstico probabilísticos al navegador del especialista en cuestión de milisegundos.

2.1.5.3 Sistemas web clínicos

Los sistemas web clínicos son una subcategoría especializada de software médico diseñada específicamente para gestionar flujos de trabajo médicos, automatizar el triaje y almacenar datos médicos protegidos (PHI). A diferencia de los sitios web

tradicionales, los sistemas clínicos deben integrar herramientas de apoyo a la toma de decisiones médicas (como sistemas CAD) y garantizar la interoperabilidad con los estándares del sector. Esto garantiza la trazabilidad de todas las acciones que los médicos realizan sobre los expedientes de los pacientes (Microsoft, s.f.).

La plataforma que se está desarrollando para Lima Metropolitana funcionará como un sistema web clínico completo, específicamente para oftalmología. Este software no solo realizará predicciones, sino que también gestionará de forma estructurada los perfiles de los pacientes, registrará las fechas de los exámenes de fondo de ojo, almacenará probabilidades de glaucoma o retinopatía diabética calculadas algorítmicamente y permitirá a los oftalmólogos generar y descargar informes estandarizados para adjuntarlos a los expedientes médicos de los pacientes.

2.1.5.4 Cloud Computing

La computación en la nube se define como la prestación de servicios informáticos (capacidad de procesamiento, almacenamiento, bases de datos, etc.) bajo demanda a través de internet. En el ámbito médico, la nube es un factor clave en la integración de la inteligencia artificial. Esto se debe a que permite a las clínicas disponer de la enorme capacidad de procesamiento necesaria para ejecutar redes neuronales complejas sin tener que invertir grandes sumas en servidores físicos e infraestructura de refrigeración local (Kamani, 2024; Microsoft, s.f.).

Dado que las redes neuronales convolucionales (CNN) requieren una alta capacidad de procesamiento para evaluar secuencias de imágenes en tiempo real, el motor de inferencia de este proyecto se implementará en la nube. Al utilizar una plataforma en la nube, el sistema contará con una alta escalabilidad, esto significa que, incluso si la aplicación web se expande en el futuro para dar servicio a varios departamentos de oftalmología simultáneamente, la infraestructura en la nube asignará dinámicamente más recursos informáticos, evitando fallos del sistema y garantizando un servicio continuo y fiable.

2.1.6 Salud visual y discapacidad visual

La salud visual es un pilar fundamental del bienestar general y la calidad de vida de las personas, ya que influye directamente en el desarrollo cognitivo, académico y vocacional en cada etapa de la vida. El incremento sostenido de las enfermedades

oculares, impulsado por el envejecimiento poblacional y la creciente prevalencia de enfermedades sistémicas crónicas, ha posicionado la pérdida de visión como uno de los desafíos más urgentes para los sistemas de salud a nivel mundial (WHO, 2024). Esta situación es aún más evidente en zonas urbanas densamente pobladas, donde la infraestructura sanitaria especializada opera con recursos insuficientes y el acceso oportuno a especialistas es limitado, lo que genera retrasos diagnósticos y un pronóstico menos favorable. Ante eso, se examinan los conceptos clínicos clave que sustentan la validez médica de esta investigación: parte de la definición formal de salud visual establecida por organismos internacionales, caracteriza los distintos niveles y causas de la discapacidad visual y analiza su impacto en la salud pública.

2.1.6.1 Definición de salud visual

La Organización Mundial de la Salud (2024) concibe la salud visual no solo como la ausencia de enfermedad ocular, sino como un estado de bienestar físico, mental y social en el que la persona puede aprovechar plenamente su función visual y desenvolverse con autonomía (WHO, 2024). Esto deja claro que una visión funcional óptima es un derecho fundamental para la independencia, la movilidad y la participación equitativa en la vida social y productiva.

Partiendo de eso, el sistema propuesto va más allá de clasificar imágenes y se configura como una herramienta activa a favor de la salud visual comunitaria. Al facilitar exámenes oftalmológicos rápidos, accesibles y de alta precisión, la plataforma contribuye a preservar la visión de los pacientes, permitiendo detectar anomalías anatómicas en etapas asintomáticas, antes de que deriven en daños irreversibles que comprometan su autonomía.

2.1.6.2 Definición de discapacidad visual

La discapacidad visual es la reducción de la agudeza visual o del campo visual por alteraciones funcionales o estructurales en el sistema visual que no responden a la corrección óptica, el tratamiento farmacológico ni las intervenciones quirúrgicas estándar. Su espectro clínico va desde deterioros leves o moderados hasta la ceguera total, y tiene como causa frecuente enfermedades degenerativas crónicas de

evolución asintomática, entre las que destacan el glaucoma, las cataratas y la retinopatía diabética (WHO, 2024).

El sistema de análisis desarrollado en este estudio fue concebido para intervenir directamente sobre las principales causas de discapacidad visual. Al entrenar una red neuronal convolucional (CNN) para identificar de forma autónoma biomarcadores tempranos de glaucoma y retinopatía a partir de imágenes del fondo de ojo, es posible intervenir antes de que los pacientes alcancen el umbral de discapacidad visual moderada o grave, reduciendo significativamente la incidencia de ceguera evitable.

2.1.6.3 *Impacto en salud pública*

Las enfermedades oculares y las deficiencias visuales constituyen un problema de salud pública de alcance mundial. Sus consecuencias van más allá del ámbito clínico, pues repercuten directamente en la esfera socioeconómica: generan exclusión social, reducen la productividad laboral, incrementan los costos asociados a tratamientos prolongados y contribuyen a la saturación de los centros de salud especializados, factores que en conjunto perpetúan las desigualdades en el acceso a una atención médica oportuna (WHO, 2024).

Para abordar esta crisis de salud pública, la implementación de este sistema CAD ofrece una solución tecnológica altamente escalable para aliviar la carga que pesa sobre las comunidades. Al descentralizar la capacidad de diagnóstico y proporcionar evaluaciones preliminares precisas a los centros de atención primaria u ópticas, la plataforma reduce directamente la carga de trabajo de los centros oftalmológicos de Lima, que se encuentran saturados.

2.1.7 *Patologías retinianas*

Las enfermedades de la retina son un grupo de afecciones oculares que afectan directamente las complejas capas de tejido fotosensible en la parte posterior del globo ocular, lo que perjudica significativamente la capacidad del paciente para procesar estímulos visuales. Debido a que esta estructura anatómica está compuesta por una compleja red de microvasos y nervios, incluso cambios patológicos menores pueden provocar una pérdida irreversible de la visión si no se trata a tiempo. En el panorama

clínico actual, enfermedades como la retinopatía diabética y el glaucoma destacan como las principales causas de ceguera en todo el mundo debido a sus características degenerativas (National Eye Institute [NEI], 2024). La creciente incidencia de estas enfermedades pone de manifiesto la baja eficacia de los modelos de atención puramente reactivos y la urgencia clínica de implementar estrategias de detección proactivas en los centros sanitarios. Esta sección describe la base anatómica de la retina y las características fisiopatológicas de las principales enfermedades oculares incluidas en este estudio, estableciendo el marco clínico y los biomarcadores precisos que los algoritmos de inteligencia artificial deben aprender para realizar diagnósticos automatizados de alta precisión en una plataforma web.

2.1.7.1 Definición de retina

Anatómicamente, la retina es una membrana delgada compuesta por fotorreceptores y células nerviosas que recubre la pared posterior del globo ocular. Su función fisiológica es similar a la de la película en una cámara convencional: recibe los rayos de luz enfocados por el objetivo, los convierte en señales eléctricas y los transmite al cerebro a través del nervio óptico para su reconocimiento como información visual (NEI, 2024).

En el desarrollo del procesamiento computacional de este proyecto, la retina es la única región de interés (ROI) objeto de análisis algorítmico. Las imágenes del fondo de ojo tomadas en la consulta proporcionan un mapa visual de esta membrana, y una red neuronal convolucional (CNN) aplica filtros matemáticos a este mapa para segmentar el disco óptico, la mácula y los vasos sanguíneos, separando las estructuras normales de las posibles anomalías estructurales.

2.1.7.2 Retinopatía diabética

La retinopatía diabética se origina como una complicación microvascular de la diabetes, manifestándose específicamente en los vasos sanguíneos de la retina. Al respecto, el INE (2024) señala que la exposición prolongada a niveles elevados de glucosa en sangre deteriora progresivamente las paredes de los capilares retinianos, lo que deriva en hinchazón, filtración de líquido y episodios de sangrado. En la fase progresiva o proliferativa, la retina forma vasos sanguíneos nuevos, anormales y extremadamente frágiles para compensar la falta de flujo sanguíneo, lo que conduce al desprendimiento de retina y a una pérdida grave de la visión.

En el caso del Centro Oftalmológico V.E.R., la plataforma web desarrollada incorpora modelos de aprendizaje profundo entrenados específicamente para identificar microhemorragias y exudados lipídicos en imágenes retinianas. Al identificar estos patrones, el sistema CAD puede clasificar la gravedad del daño diabético en el ojo del paciente, proporcionando alertas tempranas a los oftalmólogos, incluso si la visión del paciente es buena.

2.1.7.3 Glaucoma

El glaucoma agrupa diversas enfermedades oculares de carácter progresivo, cuyo rasgo común es el daño irreversible que generan sobre el nervio óptico, estructura encargada de transmitir la información visual desde el ojo hasta el cerebro. Según el NEI (2024), este daño suele asociarse a una presión intraocular (PIO) anormalmente alta debido a una alteración en el drenaje del humor acuoso. El daño afecta inicialmente la visión periférica del paciente, creando un "punto ciego", que luego progresa hacia el centro del campo visual, hasta llegar a la ceguera total.

Dado que el daño glaucomatoso se manifiesta físicamente como cambios en la morfología de la retina, en particular en la relación de la excavación del disco óptico, este sistema incorpora esta evaluación en su procesamiento automatizado. La red neuronal convolucional (CNN) mide estas relaciones topográficas a partir de imágenes 2D, proporcionando a los especialistas cálculos probabilísticos del riesgo de glaucoma simultáneamente con el análisis de la retinopatía.

2.1.7.4 Características (asintomáticas, progresivas)

El glaucoma y la retinopatía diabética son enfermedades progresivas que comparten dos características clínicas extremadamente peligrosas: no presentan síntomas en sus etapas iniciales (NEI, 2024). Los pacientes no experimentan dolor, enrojecimiento ni cambios en la visión hasta que el daño estructural al nervio óptico y la mácula se generaliza y se vuelve irreversible.

Esta progresión silenciosa es la razón principal para implementar esta solución tecnológica en el área metropolitana de Lima. Al incorporar un sistema asistido por IA capaz de procesar imágenes retinianas de forma rápida, el objetivo es detectar señales patológicas antes de que los pacientes presenten sus primeros síntomas, convirtiendo la aplicación web en una herramienta preventiva que permita una intervención médica a tiempo.

2.1.8 Diagnóstico oftalmológico tradicional

Durante décadas, el diagnóstico oftalmológico tradicional ha sido la base sobre la que se apoya la evaluación y el tratamiento de las enfermedades oculares. Este modelo parte de la interacción directa entre el paciente y el especialista, quien examina físicamente la estructura interna del globo ocular mediante instrumentos como el oftalmoscopio y la lámpara de hendidura. Si bien esta metodología permite evaluaciones detalladas e individualizadas, hoy enfrenta dificultades operativas debido al aumento de pacientes con enfermedades crónicas como la diabetes y la hipertensión (Arias-Serrano et al., 2024). Examinar el fondo de ojo de cada paciente genera presión en la dinámica clínica, lo que deriva en consultas apresuradas y largos tiempos de espera. A esto se suma que el modelo analógico es propenso a errores vinculados al cansancio visual y cognitivo que el proceso genera en el especialista (Arias-Serrano et al., 2024). Ante este panorama, la presente sección examina la metodología que sustenta la evaluación oftalmológica manual, su dependencia del criterio visual humano y las limitaciones de este enfoque, con el fin de identificar los factores que justifican la transición hacia un sistema de diagnóstico digital asistido por computadora.

2.1.8.1 Evaluación manual por especialista

La evaluación manual en oftalmología consiste en la observación directa que realiza el especialista sobre la morfología del nervio óptico, la mácula y la red vascular, apoyándose en su formación académica y trayectoria clínica. Durante este proceso, el médico debe identificar anomalías sutiles, como pequeños exudados o variaciones leves en la presión del disco óptico, y relacionarlas entre sí para llegar a un diagnóstico fundamentado (Arias-Serrano et al., 2024).

En el contexto actual del Centro Oftalmológico V.E.R., este tipo de evaluación manual toma un tiempo considerable por paciente, ya que el especialista debe analizar cada imagen retiniana desde cero, sin ningún apoyo previo, basándose únicamente en su capacidad para reconocer y comparar los hallazgos con patrones clínicos aprendidos. Este modelo completamente manual es precisamente lo que la aplicación web busca mejorar, trasladando la primera etapa del examen a un entorno digital.

2.1.8.2 *Dependencia del análisis visual humano*

Los diagnósticos tradicionales de enfermedades de la retina son principalmente cualitativos y observacionales, ya que dependen por completo de la agudeza visual y el criterio del médico. Esto hace que la precisión en el diagnóstico de enfermedades asintomáticas, como el glaucoma incipiente, esté muy condicionada por la experiencia del especialista. Como resultado, dos médicos pueden interpretar la misma imagen del fondo de ojo de forma distinta, generando variabilidad en los diagnósticos (Arias-Serrano et al., 2024).

La introducción de una plataforma web reduce esta dependencia cualitativa. Mediante el uso de una red neuronal convolucional (CNN), el sistema evalúa cada píxel de una imagen de la retina utilizando cálculos matemáticos objetivos y probabilísticos, estandarizando los criterios de evaluación y proporcionando a los médicos una segunda opinión basada en datos cuantitativos, además de la percepción visual.

2.1.8.3 *Limitaciones (fatiga, tiempo, subjetividad)*

Los modelos de tamizaje basados únicamente en la intervención humana tienen limitaciones operativas inevitables. Revisar decenas de imágenes retinianas durante largas jornadas de trabajo genera fatiga visual y cognitiva en los profesionales de salud, lo que aumenta la tasa de falsos negativos (el porcentaje de lesiones no detectadas). Además, el tiempo que toma cada evaluación manual reduce el número de pacientes que se pueden atender al día, lo que agrava el problema del diagnóstico tardío en poblaciones vulnerables (Arias-Serrano et al., 2024; Henge et al., 2025).

El objetivo principal del desarrollo de este ecosistema tecnológico es superar estas limitaciones. Una arquitectura de software basada en la nube y el procesamiento mediante IA permitirán clasificar las imágenes retinianas en milisegundos con una precisión inquebrantable, independientemente del volumen de imágenes procesadas. Esto eliminará el sesgo inducido por la fatiga, reducirá el tiempo de triaje y proporcionará diagnósticos más objetivos y equitativos a los pacientes atendidos en el área metropolitana de Lima.

2.1.9 Limitaciones del sistema de salud

Los sistemas de salud modernos enfrentan una crisis estructural agravada por los cambios demográficos y el aumento sostenido de las enfermedades crónicas no transmisibles. Si bien el equipamiento clínico ha mejorado considerablemente en los últimos años, la infraestructura destinada a la atención primaria y especializada no ha crecido al mismo ritmo que la demanda. Esta diferencia ha generado limitaciones que afectan tanto la oportunidad como la calidad de los diagnósticos médicos. En el campo de la oftalmología, las consecuencias son especialmente serias: la falta de detección temprana ha permitido que condiciones prevenibles lleguen a convertirse en casos de ceguera irreversible. A esto se suma que el sistema sanitario actual presenta serias ineficiencias en la distribución de recursos humanos y logísticos, lo que termina por levantar barreras difíciles de superar para los sectores más vulnerables de la población (WHO, 2024). Esta sección analiza las principales limitaciones operativas a las que se enfrenta el sistema sanitario oftalmológico actual (saturación de clínicas, largos tiempos de espera, extrema concentración de especialistas, etc.) y destaca los problemas subyacentes que esta plataforma web y el desarrollo de su modelo de inteligencia artificial pretenden abordar.

2.1.9.1 Saturación de consultorios oftalmológicos

La saturación hospitalaria se produce cuando la demanda constante de atención médica supera crónicamente la capacidad física y humana de los centros sanitarios. En el campo de la oftalmología, esta saturación se debe principalmente a la necesidad ineludible de realizar exámenes masivos periódicos, como los exámenes de fondo de ojo, dado el aumento de la población de pacientes con riesgo de glaucoma y diabetes. Esto sobrecarga rápidamente las agendas del reducido número de especialistas que trabajan en los centros médicos (WHO, 2024).

En el entorno de aplicación del Centro Oftalmológico V.E.R., la implementación de una plataforma web con inteligencia artificial funciona como un filtro primario altamente eficiente. El sistema CAD automatiza el análisis de imágenes de retina, gestionando la mayoría de los exámenes rutinarios, lo que permite a los especialistas dedicar el tiempo de consulta presencial únicamente a los casos clasificados como patológicos o de alto riesgo por el algoritmo, aliviando directamente la saturación de la clínica.

2.1.9.2 Tiempos de espera prolongados

La saturación del sistema es la causa directa de los tiempos de espera excesivamente largos para las citas con el oftalmólogo. Este retraso en el diagnóstico es extremadamente perjudicial, ya que afecciones asintomáticas como la retinopatía diabética progresan mientras los pacientes esperan meses para una evaluación clínica, lo que continúa destruyendo el tejido microvascular de la retina (Arias-Serrano et al., 2024).

La arquitectura de la solución propuesta aborda directamente este retraso operativo. Al alojar un motor de inferencia de red neuronal convolucional (CNN) en un servidor en la nube, se elimina la espera de semanas para obtener un diagnóstico estimado. La aplicación web devuelve resultados probabilísticos al médico en cuestión de milisegundos tras la carga de la imagen. Esto permite tomar decisiones clínicas e iniciar el tratamiento durante la consulta del paciente.

2.1.9.3 Centralización de especialistas en Lima

La concentración de profesionales de la salud es un factor determinante en las desigualdades en la atención médica. La gran mayoría de los especialistas y técnicos superiores se concentran en las grandes ciudades y áreas urbanas densamente pobladas, lo que dificulta el acceso a servicios médicos especializados en las regiones circundantes y en los centros de atención primaria. En consecuencia, los pacientes se ven obligados a recorrer largas distancias incluso para realizarse pruebas de visión básicas (WHO, 2024).

La implementación de este sistema web descentralizará por completo las capacidades de diagnóstico. Al ser una plataforma accesible desde cualquier navegador de internet, el oftalmólogo no necesita estar presente físicamente para realizar la evaluación inicial. Los optometristas de los centros de optometría locales pueden tomar imágenes de la retina y subirlas al sistema, aprovechando la inteligencia artificial en la nube para brindar el mismo nivel de experiencia clínica que en Lima Metropolitana, desde cualquier lugar con conexión a internet.

2.1.10 Limitaciones tecnológicas en el diagnóstico

Si bien los avances en informática han aportado herramientas innovadoras al campo de la medicina, la adopción de estas tecnologías en clínicas oftalmológicas

especializadas en regiones en desarrollo sigue estando muy rezagada (Arias-Serrano et al., 2024). Actualmente, la práctica clínica rutinaria se ve gravemente afectada por limitaciones tecnológicas estructurales que dificultan la optimización del flujo de trabajo del médico tratante. A pesar de las mejoras en la resolución óptica de las imágenes retinianas, la infraestructura de software que gestiona estas imágenes se adhiere a paradigmas operativos obsoletos y cerrados (Infante & Cruzado, 2024). Está grave brecha digital impide a los especialistas aprovechar la verdadera predictibilidad de los datos visuales adquiridos, obligándolos a depender exclusivamente de su capacidad de procesamiento humano en un entorno con un número de pacientes que aumenta exponencialmente (Ejaz et al., 2024). Esta sección examina en detalle las principales deficiencias de software y hardware que dificultan la detección oftalmológica moderna. Analizamos los impactos significativos de la falta de sistemas de apoyo al diagnóstico, la prevalencia de procesos puramente analógicos en el procesamiento de imágenes y la marcada ausencia de automatización algorítmica.

2.1.10.1 Ausencia de sistemas CAD

A pesar de la enorme carga que suponen las enfermedades de la retina para los pacientes, la gran mayoría de los centros sanitarios operan sin herramientas informáticas avanzadas. La falta de sistemas CAD en las clínicas impide que los especialistas obtengan segundas opiniones objetivas, automatizadas y en tiempo real. Esta deficiencia técnica perpetúa la ausencia de filtros precalculados que resalten las áreas sospechosas en las imágenes, dejando toda la responsabilidad analítica en manos de la evaluación visual directa del especialista (Ejaz et al., 2024). El objetivo principal de esta tesis, dentro del ecosistema del Centro Oftalmológico V.E.R., es abordar precisamente esta limitación. La aplicación web en desarrollo funciona como un sistema CAD pensado para especialistas clínicos. Al incorporar un motor de inteligencia artificial en la plataforma, los médicos pueden recibir apoyo diagnóstico para evaluar imágenes de retina de forma rápida, lo que le da a la clínica una herramienta de respaldo para reducir el error humano.

2.1.10.2 Procesos analógicos

Otra limitación relevante es la dependencia de procesos fragmentados, ya sean analógicos o digitales. En la práctica, muchos centros de salud aún capturan imágenes de la retina y las analizan en etapas completamente separadas: primero se obtiene la imagen, y luego, muchas veces con un intervalo de tiempo considerable, se traslada a otro entorno para su evaluación. Este traslado suele hacerse mediante unidades USB o, en casos más precarios, imprimiendo las imágenes en papel fotográfico de baja resolución, lo que termina afectando la calidad diagnóstica. La falta de conexión entre estos procesos y una infraestructura en la nube insuficiente generan menor fidelidad de los datos visuales, retrasos en el acceso a los historiales médicos y riesgos para la seguridad de la información del paciente (Infante & Cruzado, 2024).

La arquitectura cliente-servidor de la plataforma propuesta elimina esta separación de etapas. Al funcionar como una aplicación web centralizada en la nube, el sistema permite un flujo de trabajo digital y continuo. Las imágenes de la retina adquiridas se cargan directamente al servidor a través de un navegador web, eliminando la necesidad de transferencia física y permitiendo a los especialistas evaluar las imágenes con su resolución anatómica original en un monitor.

2.1.10.3 Falta de automatización

La falta de automatización en la oftalmología tradicional se hace especialmente evidente en la extracción manual de características clínicas. Debido a la ausencia de algoritmos de visión computacional, los especialistas deben realizar laboriosas mediciones visuales o mediciones con software de imagen básico que carece de capacidades analíticas. Tareas importantes como el cálculo de la relación de la excavación del disco óptico en el glaucoma y el recuento de microaneurismas en la retinopatía diabética no están automatizadas, lo que supone una pérdida de valioso tiempo de consulta (Mamyrbayev et al., 2025).

Al integrar las redes neuronales convolucionales (CNN) en el sistema de procesamiento de datos para la investigación, podemos alcanzar un nivel de automatización algorítmica del que actualmente carecen los entornos clínicos. Cuando se introducen imágenes del fondo de ojo en la red, los filtros matemáticos

extraen y procesan automáticamente los patrones patológicos. Como resultado, se generan diagnósticos estimados y evaluaciones de riesgo automatizados en milisegundos, lo que mejora drásticamente las capacidades diagnósticas de los oftalmólogos.

2.2 Estándares/Buenas Prácticas/Frameworks

2.2.1 Estándares

2.2.1.1 ISO/IEC/IEEE 12207 (*Ciclo de Vida del Software*)

La norma ISO/IEC/IEEE 12207 establece un marco común para los procesos del ciclo de vida del software, promoviendo un enfoque estandarizado para la ingeniería de sistemas. Esta norma define de forma directa y precisa los procesos, actividades y tareas aplicables en cada etapa de la adquisición, entrega, desarrollo, operación, mantenimiento y eventual desmantelamiento de productos y servicios de software. El marco no impone metodologías de desarrollo restrictivas. Su flexibilidad arquitectónica permite la iteración concurrente y se acopla de manera natural a cualquier metodología de trabajo ágil. Mediante la adopción de estos protocolos, los equipos de ingeniería logran construir una base técnica sólida para estructurar, auditar y mejorar la calidad a lo largo de todo el proceso operativo del software.

2.2.1.2 ISO/IEC 25010 (*Calidad de Software*)

La norma ISO/IEC 25010 regulariza la evaluación cualitativa de cualquier arquitectura de software o infraestructura tecnológica. Para lograrlo, la norma define nueve características principales que se dividen en criterios de verificación más detallados (ISO/IEC, 2023). Su uso es amplio, ya que tanto los ingenieros de desarrollo como los auditores independientes la aplican durante todas las fases de construcción del sistema. En la práctica, estas métricas ayudan a definir cómo recopilar los requisitos iniciales, establecer las condiciones de aceptación y controlar la calidad, lo que resulta especialmente útil en proyectos donde múltiples equipos trabajan en paralelo y necesitan criterios comunes para evaluar el avance. De esta forma, la norma ofrece un enfoque estructurado que no solo asegura que los sistemas desarrollados cumplan con lo esperado, sino que también

facilita la detección temprana de desviaciones antes de que se conviertan en problemas mayores durante las etapas finales del desarrollo.

2.2.1.3 GDPR (Protección de datos, referencia internacional)

El Reglamento General de Protección de Datos (RGPD) regula la privacidad digital dentro de la Unión Europea, obligando a las organizaciones a manejar la información personal bajo criterios estrictos de seguridad y transparencia. Al ser tecnológicamente neutro, centra sus exigencias en la evaluación del riesgo operativo en lugar de auditar herramientas informáticas específicas. Forzando a las empresas a operar en un ecosistema donde la ética en la gestión de la información resulta obligatoria (Comisión Europea, 2024). Como referente mundial, regula estrictamente las transferencias de datos fuera de la UE, asegurando que los niveles de protección se mantengan elevados incluso en dichas transferencias, el estricto cumplimiento es supervisado por autoridades independientes de protección de datos mediante un marco de colaboración centralizado y eficiente.

2.2.1.4 HL7 FHIR (Fast Healthcare Interoperability Resources)

La organización Health Level 7 desarrolló la arquitectura HL7 FHIR para resolver las deficiencias de interoperabilidad en el sector médico. Este modelo asegura que las instituciones de salud intercambian grandes volúmenes de datos sin generar cuellos de botella estructurales. Al adoptar un enfoque de API RESTful y tecnologías web modernas (JSON, XML, OAuth, etc.), reduce la curva de aprendizaje del desarrollador y simplifica el desarrollo de aplicaciones (Office of the National Coordinator for Health Information Technology [CNO], s.f.). Su arquitectura modular basada en recursos, permite la recuperación de datos granular y específica al transmitir solo la información necesaria, en lugar de historiales médicos completos. Además, la estricta adhesión al código y vocabulario médico garantiza la interoperabilidad semántica, lo que permite que tanto los sistemas emisores como los receptores comprendan los datos de la misma manera, también es compatible con los sistemas de salud existentes y protege la información sensible al incorporar los protocolos de seguridad, cifrado y privacidad más recientes.

2.2.1.5 DICOM (*Digital Imaging and Communications in Medicine*)

DICOM es un estándar internacional diseñado para la gestión, transmisión y almacenamiento de información de imágenes médicas en entornos sanitarios (Gim et al., 2025). Su principio fundamental consiste en integrar en un único archivo los datos de imagen generados por exámenes clínicos con metadatos completos sobre su contexto, desde la información demográfica del paciente hasta los parámetros técnicos del equipo y sus características precisas en el momento de la adquisición, este estándar no solo organiza la información mediante objetos de definición de información (IOD) adaptados a cada modalidad médica, sino que también establece un protocolo de comunicación en red riguroso que garantiza una interoperabilidad perfecta entre los sistemas de archivo y comunicación de imágenes (PACS) y los equipos de diferentes fabricantes.

2.2.1.6 ISO/IEC 27001 (*Seguridad de la Información*)

La norma ISO/IEC 27001 establece la arquitectura de los sistemas de gestión de seguridad de la información a nivel internacional. Esta norma va más allá de simples sugerencias, ya que exige a las organizaciones estructurar y mejorar de forma continua sus protocolos para el control de riesgos. Lograrlo requiere alinear tres elementos clave: el talento humano, los procesos internos y la infraestructura tecnológica (ISO/IEC, 2022). Al trabajar estas tres dimensiones en conjunto, las empresas pueden anticiparse a sus propias vulnerabilidades y reducir el riesgo de que una amenaza comprometa sus registros críticos. Su adopción asegura la confidencialidad, la integridad y la disponibilidad de la información en todos sus formatos, ya sea en papel, digital o en la nube, y además mejora la capacidad de respuesta frente a ciberataques y reduce el gasto en tecnologías defensivas que no funcionan.

2.2.1.7 ISO/IEC/IEEE 29148 (*Ingeniería de Requisitos*)

La norma ISO/IEC/IEEE 29148 define la ingeniería de requisitos para la construcción de software y servicios. Su aplicación busca alinear a quienes solicitan el sistema con los encargados de desarrollarlo, lo que requiere que los analistas extraigan, evalúen y definan cada necesidad operativa antes de escribir una sola línea de código. Al seguir esta metodología, las organizaciones logran

una documentación precisa que define la arquitectura y las funcionalidades del producto. Además, la norma detalla las condiciones para que una petición sea considerada un requerimiento válido y establece qué entregables son obligatorios a lo largo del ciclo (ISO/IEC/IEEE, 2018), orientando también la ejecución de los procedimientos descritos en los estándares ISO/IEC/IEEE 15288 y 12207. Su campo de aplicación es amplio, ya que puede adoptarse sin importar la escala del proyecto, la complejidad del sistema o la metodología de trabajo elegida por el equipo.

2.2.2 Frameworks

2.2.2.1 TensorFlow / Keras

TensorFlow es un entorno de código abierto y altamente escalable para el desarrollo de Machine Learning. Su arquitectura va más allá de los servidores tradicionales, permitiendo desplegar algoritmos en hardware con recursos limitados mediante su versión Lite, o gestionar ciclos de producción más completos con su variante Extended. Para llevar a cabo toda esta infraestructura computacional, el sistema adopta a Keras como su interfaz principal de programación (TensorFlow, 2021). Esta interfaz de programación técnica agiliza el diseño flexible de las redes neuronales y hace mucho más simple la administración operativa de los datos. Como resultado, los programadores logran de forma paralela el entrenamiento y exprimir al máximo la aceleración física que brindan las unidades de procesamiento gráfico y tensorial.

2.2.2.2 FastAPI

FastAPI estructura el desarrollo de interfaces de programación en Python aprovechando la inferencia de tipos nativa. Su arquitectura delega la gestión de peticiones web a Starlette y se apoya en Pydantic para validar de forma rigurosa los esquemas de información (tiangolo, 2026). Esta combinación técnica elimina por completo los cuellos de botella habituales del lenguaje. Dando como resultado, que la herramienta alcance métricas de ejecución y latencia que compiten directamente con ecosistemas altamente concurridos como Go o NodeJS. Su diseño intuitivo permite un aumento del 200-300% en la velocidad de desarrollo de nuevas funcionalidades, a la vez que reduce los errores humanos

hasta en un 40%, además, ofrece compatibilidad total con estándares abiertos como OpenAPI y JSON Schema, lo que garantiza la generación automática de documentación interactiva y código robusto y listo para producción.

2.2.2.3 *Angular*

Angular es un framework web de código abierto mantenido por Google, diseñado para proporcionar a los desarrolladores las herramientas, API y bibliotecas necesarias para crear aplicaciones rápidas, fiables y escalables. Su arquitectura principal se basa en el uso de componentes, que dividen el código en partes encapsuladas, y se complementa con Angular Signals, que permite un modelo de reactividad optimizado, inyección de dependencias y un sistema de enrutamiento avanzado (Angular, s.f.). Además, admite de forma nativa la renderización del lado del servidor (SSR) y la generación de sitios estáticos (SSG), y facilita el desarrollo mediante su propia interfaz de línea de comandos (Angular CLI), que utiliza herramientas de compilación modernas como Vite y esbuild. También incluye funciones de seguridad integradas, como la sanitización de HTML para prevenir ataques de secuencias de comandos entre sitios (XSS), y garantiza una estabilidad rigurosa a nivel empresarial mediante la validación de cada actualización con cientos de miles de pruebas en el repositorio interno de Google.

2.2.2.4 *OpenCV (Open Source Computer Vision Library)*

OpenCV es la mayor biblioteca de código abierto dedicada a la visión artificial y Machine Learning. Distribuida bajo la licencia Apache 2, ofrece más de 2500 algoritmos optimizados para que las empresas integren rápidamente la percepción automática en sus productos (OpenCV team, 2026). Especializada en aplicaciones de visión en tiempo real, se ejecuta en múltiples plataformas (Windows, Linux, Android, macOS) mediante interfaces nativas para C++, Python, Java y MATLAB. Esto le permite realizar operaciones complejas de visión computacional como la identificación de rostros, el reconocimiento de objetos y la reconstrucción de entornos tridimensionales. Para manejar esta carga de procesamiento, el sistema aprovecha la aceleración por hardware mediante su integración con CUDA y OpenCL, lo que ha consolidado su uso en escenarios de gran complejidad y la ha convertido en una herramienta clave tanto para el sector

corporativo como para proyectos de investigación gubernamentales como los de la NASA.

2.2.2.5 *Scikit-learn*

Scikit-learn es una de las bibliotecas más usadas para el desarrollo de modelos predictivos de aprendizaje automático en Python. Al apoyarse en la capacidad de cálculo de NumPy y SciPy, resuelve problemas de clasificación o agrupamiento sin que el programador tenga que escribir operaciones matemáticas complejas desde cero (Clark, s.f.). Su diseño simple y consistente facilita todo el flujo de trabajo, permitiendo pasar de forma ágil desde el preprocesamiento de datos hasta la evaluación de resultados con métricas como el AUC-ROC, lo que reduce considerablemente el tiempo que normalmente tomaría implementar estos procesos manualmente. Esta versatilidad permite aplicarla en retos industriales complejos como la evaluación de riesgos financieros, e incluso conectarla directamente con modelos de lenguaje a gran escala mediante su API, lo que la convierte en una herramienta útil tanto para proyectos de investigación como para soluciones en entornos de producción reales.

2.2.2.6 *Amazon Web Services (AWS)*

Amazon Web Services (AWS) es el líder en computación en la nube, ofreciendo a las empresas una infraestructura que las libera de la carga de gestionar centros de datos físicos locales. Para apoyar esta transición, la plataforma pone a disposición un catálogo global con más de doscientas herramientas bajo demanda (Amazon Web Services [AWS], 2026). Sus opciones van desde servicios básicos como almacenamiento, administración de redes y bases de datos, hasta la implementación de arquitecturas complejas impulsadas por inteligencia artificial e internet de las cosas. Todo esto opera en una red global de 120 zonas de disponibilidad distribuidas en 38 regiones geográficas, protegida por más de 300 herramientas nativas que cumplen con los estándares de seguridad de organizaciones militares y bancarias a nivel mundial. Además, su modelo de precios de pago por uso permite a AWS reducir significativamente los costos operativos de TI para startups, grandes empresas y agencias gubernamentales,

brindando la agilidad para escalar dinámicamente el desarrollo e impulsar la innovación sin las limitaciones de la infraestructura tradicional.

2.2.3 Buenas Prácticas

2.2.3.1 Desarrollo ágil (SCRUM)

Scrum es un marco de trabajo ligero diseñado para ayudar a individuos, equipos y organizaciones a crear valor mediante el desarrollo de soluciones altamente adaptables a problemas complejos. El marco de trabajo Scrum fusiona el empirismo con la filosofía lean para gestionar la incertidumbre de los proyectos a través de las iteraciones predecibles que tienen de nombre sprints. Su forma de operar es mediante un equipo horizontal y autogestionado donde los desarrolladores colaboran a la par con el Product Owner y el Scrum Master (Schwaber & Sutherland, 2020). Al no existir una estructura jerárquica tradicional dentro del proceso, este núcleo asume la responsabilidad de tomar los requisitos del Product Backlog y convertirlos en incrementos funcionales al cierre de cada uno de los sprints. Todo esto se apoya en la necesidad de mantener la transparencia de los procesos, revisar los resultados y ajustar la estrategia. En la práctica, estas tres acciones guían las reuniones de planificación y las retrospectivas del Scrum. Esta estructura de evaluación continua permite a los involucrados corregir el rumbo en tiempo real, asegurando que el producto siga evolucionando frente a cualquier imprevisto.

2.2.3.2 Privacidad por diseño (Privacy by Design)

La filosofía de privacidad por diseño, desarrollada por Ann Cavoukian, plantea que la protección de datos debe integrarse desde el origen mismo de la arquitectura de software. Cuyo objetivo es desterrar la práctica común de añadir la seguridad como un simple complemento o añadido final. Para lograrlo, los desarrolladores deben establecer la máxima confidencialidad como la configuración por defecto a través de todo el ciclo de vida del sistema. Si bien la autora propone múltiples fundamentos, el enfoque en la seguridad de extremo a extremo es el más importante (Obiokafor et al., 2025). Esta directriz exige desplegar controles técnicos que escolten la información desde su captura inicial hasta su borrado definitivo salvaguardando su integridad para así proteger la

información hasta sus últimos momentos. Adoptar este rigor desde la fase de planificación demuestra que blindar los registros sensibles es totalmente compatible con mantener un alto rendimiento operativo del aplicativo evitando así comprometer el rendimiento del sistema.

2.2.3.3 *Seguridad por diseño (Security by Design)*

La seguridad por diseño descarta por completo el modelo tradicional de reaccionar frente a las vulnerabilidades, teniendo como objetivo garantizar el correcto funcionamiento de la tecnología incluso en caso de ataques maliciosos. En lugar de parchar las vulnerabilidades una vez hallan sido explotadas, este enfoque integra la protección desde la conceptualización del sistema hasta el final de su vida útil. Alcanzar este nivel de resiliencia exige aplicar controles extremadamente estrictos en múltiples capas del sistema (Raso et al., 2025). A nivel de software, este enfoque requiere el modelado continuo de amenazas y prácticas de codificación segura; a nivel de hardware, implica aplicar defensas físicas contra manipulaciones. Anticipar los riesgos de esta forma reduce de manera importante la superficie de ataque y las interrupciones del sistema. Por ello, construir la defensa desde el inicio es clave al desarrollar tecnología para entornos críticos, como los dispositivos médicos interconectados, donde mantener la integridad de los datos es fundamental.

2.2.3.4 *Clean Code*

El código limpio es software diseñado para manejar la complejidad a través de la modularidad, la extensibilidad y, sobre todo, la legibilidad, la verificación y el mantenimiento. Va más allá de un simple estilo de programación, ya que su correcta aplicación depende de cumplir métricas de calidad objetivas y medibles. Debe tener una complejidad ciclomática inferior a 10 para garantizar rutas lógicas sencillas, lograr una cobertura de pruebas automatizadas cercana al 100 % y obtener una puntuación óptima cercana a 10,0 con herramientas de análisis estático como Pylint (Gift, 2025). En esencia, el código limpio abandona la programación reactiva y engorrosa, dando como resultado un sistema transparente cuya funcionalidad se demuestra mediante la automatización de pruebas, lo que

permite a cualquier desarrollador comprender y modificar el sistema en el futuro sin riesgo de dañar su estructura.

2.2.3.5 *Arquitectura basada en microservicios*

La arquitectura de microservicios es una metodología de desarrollo que estructura aplicaciones como una colección de servicios modulares, débilmente acoplados e independientes. A diferencia de los sistemas monolíticos, que dependen de un único código fuente, este modelo divide el software, de modo que cada microservicio realiza una tarea independiente y se comunica ágilmente con el resto del ecosistema mediante protocolos estándar (como HTTP/REST) y colas de mensajes a través de API, esta separación estructural rigurosa permite a los equipos desarrollar cada módulo en diferentes lenguajes y tecnologías según sea necesario (Akerle et al., 2024). La creación de sistemas basados en esta estricta separación confiere a las aplicaciones una resiliencia inherente, evitando que toda la plataforma colapse ante un único fallo, y también permite un escalado dinámico que asigna recursos en tiempo real únicamente a los servicios que experimentan picos de demanda.

2.2.3.6 *MLOps (Machine Learning Operations)*

Machine Learning Operations es un marco metodológico para la creación, el despliegue y la operación de sistemas de inteligencia artificial a gran escala, aplicando los principios de DevOps a todo el ciclo de vida de los modelos de Machine Learning, basado en flujos de trabajo de integración continua y entrega continua (CI/CD), este enfoque automatiza todo, desde la preparación de datos y el entrenamiento de algoritmos hasta el empaquetado y la publicación en entornos de producción mediante interfaces de programación de aplicaciones (Stryker & Mucci, s.f.). Su arquitectura operativa requiere un seguimiento riguroso del código y los conjuntos de datos a través de un repositorio central, lo que garantiza una reproducibilidad experimental precisa y una sólida gobernanza corporativa, además, la monitorización continua permite la detección temprana de anomalías, como la disminución de la precisión y el sesgo, lo que activa ciclos de reentrenamiento para corregir los modelos.

2.2.3.7 *Diseño centrado en el usuario (UX/UI)*

El diseño centrado en el usuario es un proceso que pone la interacción natural por encima de la complejidad técnica. Esta metodología construye interfaces enfocadas en resolver las necesidades reales de las personas, evitando que quien la usa tenga que adaptarse forzosamente a la herramienta (Microsoft, 2024). Su éxito depende de estudiar el comportamiento humano frente a problemas concretos del mundo real, a partir de lo cual los desarrolladores dan forma a la arquitectura del software para que responda de manera intuitiva a lo que el usuario necesita. Para ello, se crean perfiles de usuario basados en datos reales y se incorpora validación continua mediante pruebas de usabilidad y retroalimentación directa, que guía el diseño de pantallas y funciones. Adoptar este desarrollo tecnológico a través de esta perspectiva transforma por completo la usabilidad del software, Las interfaces resultantes terminan siendo mucho más intuitivas, reduciendo de manera drástica la curva de aprendizaje y los errores de manipulación. Al eliminar estas barreras, las interacciones se vuelven más fluidas y naturales, lo que permite a los usuarios completar sus tareas de forma más rápida y precisa, mejorando la productividad del sistema en general.

2.2.3.8 *Validación clínica y pruebas de estrés*

La validación clínica y las pruebas de estrés operan en conjunto para garantizar la fiabilidad un sistema antes de su despliegue final. La primera fase expone la herramienta de inteligencia artificial a la dinámica real de los centros de salud. En este escenario, el algoritmo contrasta sus resultados con el diagnóstico de especialistas humanos y se va ajustando según la retroalimentación directa de los usuarios para asegurar su encaje adecuado en el trabajo diario (Skevas et al., 2024). Por otra parte, una vez superada la exactitud diagnóstica de los expertos, es indispensable validar la arquitectura subyacente. Para lograrlo, las pruebas de estrés simulan accesos masivos y simultáneos de múltiples usuarios con el fin de saturar la aplicación de forma controlada (Microsoft, 2025). Esta táctica expone rápidamente los cuellos de botella y permite revisar los tiempos de respuesta, asegurando que el software sea capaz de emitir resultados médicos de alta precisión y soportar grandes cargas operativas sin colapsar.

2.2.3.9 Gestión de calidad de datos

El monitoreo y mantenimiento de modelos busca que los algoritmos de aprendizaje automático mantengan su precisión en entornos de producción (Microsoft, 2025). Para ello, es necesario rastrear métricas de forma continua con el fin de detectar rápidamente problemas como la desviación de datos frente a información del mundo real, ya que un modelo que funcionaba bien durante el entrenamiento puede degradarse con el tiempo si las condiciones del entorno cambian. Al combinar alertas en tiempo real junto con registros automatizados de trazabilidad, los equipos pueden identificar de forma rápida qué versión del modelo está fallando y tomar acciones correctivas sin interrumpir el servicio. Además, las herramientas de interpretación que acompañan este proceso aportan transparencia al verificar cómo se procesa la información, lo que no solo facilita el cumplimiento de los estándares normativos, sino que también permite a los equipos técnicos entender mejor el comportamiento del modelo y ajustarlo cuando sea necesario.

2.2.3.10 Monitoreo y Mantenimiento de Modelos

El monitoreo y mantenimiento de modelos busca que los algoritmos de aprendizaje automático mantengan su precisión en entornos de producción (Microsoft, 2025). Para ello, es necesario rastrear métricas de forma continua con el fin de detectar rápidamente problemas como la deriva de datos frente a información del mundo real. Al integrar alertas en tiempo real junto con registros automatizados de linaje, los equipos pueden identificar de forma rápida qué versión del modelo está fallando. Además, las herramientas de interpretación que acompañan este proceso aportan transparencia al verificar cómo se procesa la información, lo que facilita el cumplimiento de los estándares normativos.

2.3 Normativa Legal

2.3.1 Ley N° 29733 - Ley de Protección de Datos Personales

La Ley N° 29733 regula la protección de los datos personales a nivel nacional, exigiendo a las entidades públicas y privadas cuidar la información ciudadana frente a cualquier riesgo de exposición. Esta obligación aplica para todos los formatos, tanto

los sistemas de procesamiento automatizado como los archivos físicos. La ley organiza el manejo de la información en torno a principios como la legalidad, el consentimiento previo, libre e informado, la limitación de la finalidad y la seguridad, buscando evitar la recopilación y el uso no autorizados de datos para fines indebidos. Su función principal es establecer los derechos de acceso, actualización, adición, rectificación, supresión y oposición, lo que permite a las personas ejercer un control absoluto sobre su propia información y solicitar la rectificación o supresión de registros (Ley 29733, 2011) . Además, esta ley establece la Agencia Nacional de Protección de Datos Personales como el organismo rector responsable de supervisar el cumplimiento de estas disposiciones, administrar el registro nacional de bases de datos e imponer sanciones administrativas por cualquier infracción que atente contra la privacidad o la confidencialidad de los ciudadanos.

2.3.2 *Decreto Supremo N° 003-2013-JUS (Reglamento de la Ley de Protección de Datos)*

El Decreto Supremo N° 003-2013-JUS reglamenta la Ley N° 29733 al definir sus procedimientos técnicos y administrativos específicos. Su función principal es aterrizar la normativa en herramientas operativas claras. El texto detalla los estrictos requisitos que debe cumplir el consentimiento válido, consentimiento previo, explícito e inequívoco basado en la libre voluntad y describe las medidas de seguridad lógicas, físicas y organizativas que los administradores de bases de datos deben implementar para prevenir el acceso no autorizado, la manipulación y la pérdida de datos (Ley 29733, 2011). Para lograrlo, este estandariza los procesos y plazos legales, permitiendo a los ciudadanos ejercer sus derechos con total celeridad, asimismo, la directiva habilita una vía de apelación administrativa directa diseñada para resolver rápidamente cualquier denegatoria frente a las solicitudes de los usuarios. Además, regula estrictamente el flujo transfronterizo de datos y su procesamiento a través de servicios técnicos subcontratados, clasificando las infracciones en categorías leves, graves y extremadamente graves, estableciendo así un riguroso sistema de monitoreo para garantizar la imposición de multas y medidas correctivas efectivas.

2.3.3 *Ley N° 31814 - Ley que promueve el uso de la Inteligencia Artificial en favor del desarrollo económico y social del país*

La Ley N° 31814 establece un marco regulatorio para facilitar la introducción de estas tecnologías emergentes en el proceso nacional de transformación digital, priorizando el estricto respeto al bienestar individual y los derechos humanos, su estructura operativa central designa a la Oficina de Gobierno y Transformación Digital de la Presidencia del Consejo de Ministros como el principal organismo tecnológico responsable de dirigir, evaluar y supervisar el ecosistema tecnológico a nivel nacional (Ley 31814, 2023). Para asegurar una implementación confiable, la ley exige que el diseño de algoritmos se base en la ética, la privacidad y la transparencia. Esto incluye la obligación de aplicar medidas de seguridad orientadas a la gestión de riesgos, a través de las cuales el Estado busca formar profesionales especializados y construir una infraestructura de datos públicos sólida. El objetivo central es que la inteligencia artificial impulse sectores como la salud, la educación y la economía de forma responsable, asegurando el avance tecnológico sin afectar los derechos ciudadanos.

2.3.4 *Ley N° 30096 - Ley de Delitos Informáticos*

La Ley N.º 30096 regula los delitos informáticos con el fin de proteger la infraestructura tecnológica y los derechos fundamentales de los usuarios, estableciendo sanciones específicas para los ilícitos cometidos mediante tecnologías de la información. Entre sus puntos principales, sanciona el acceso no autorizado a bases de datos y la interrupción intencional de la infraestructura digital. Además, la ley agrupa delitos de distinta gravedad, que van desde la interceptación de comunicaciones y el fraude electrónico, hasta la suplantación de identidad, extorsión económica y el chantaje sexual (Ley N.º 30096, 2013). Para garantizar una lucha eficaz contra el cibercrimen, la ley refuerza significativamente las penas cuando participan organizaciones criminales, cuando se abusa del poder o cuando se ve afectada la seguridad nacional, e incluso la fabricación y distribución de software malicioso diseñado para facilitar estas infracciones es punible. Al estandarizar estos actos delictivos y exigir una estrecha cooperación entre organismos, la ley protege la infraestructura tecnológica del país y garantiza que los ataques digitales contra la propiedad, la privacidad y la seguridad pública sean castigados severamente.

2.3.5 *Ley N° 30024 - Ley que crea el Registro Nacional de Historias Clínicas Electrónicas*

La Ley N° 30024 tiene como objetivo establecer una infraestructura técnica profesional para la atención médica, con el fin de organizar, mantener e intercambiar la información médica de los pacientes a nivel nacional. Su estructura consiste en una base de datos central, propiedad del Ministerio de Salud y administrada por este, operada a través de la Plataforma Nacional de Interoperabilidad (PIDE), que permite a los profesionales de la salud autorizados acceder a los expedientes y garantizar la continuidad de la atención (Ley 30024, 2013). Esta ley exige estrictamente la implementación de firmas digitales y mecanismos de verificación de identidad proporcionados directamente por la Oficina Nacional de Identidad y Registro Civil (RENIEC), otorgando así a estos registros digitales el mismo valor legal y validez que los documentos manuscritos, el principio fundamental de esta ley es que los datos médicos son propiedad exclusiva del paciente, su confidencialidad debe protegerse estrictamente y los pacientes tienen autoridad absoluta para acceder a sus propios expedientes, permitir que los profesionales de la salud los consulten y controlar qué profesionales acceden a su información personal.

2.3.6 *Ley N° 30421 - Ley Marco de Telesalud*

La Ley N° 30421 establece las directrices generales para la implementación y el desarrollo de la telemedicina mediante las tecnologías de la información y la comunicación (TIC). Su principio fundamental es considerar la telemedicina como una estrategia crucial para democratizar el sistema de salud, asegurando que las áreas rurales y quienes tienen acceso restringido a servicios médicos obtengan atención adecuada para la promoción de la salud, prevención, diagnóstico, recuperación y rehabilitación. Para facilitar esta integración, la Ley asigna al Ministerio de Salud como el ente coordinador responsable de la formulación de políticas en esta área y establece el Comité Nacional de Telemedicina (Konatel) para fomentar la mejora continua y supervisar su ejecución (Ley 30421, 2016). Asimismo, este marco requiere asegurar la interoperabilidad entre instituciones, implementar rigurosas medidas de seguridad para el intercambio de información clínica y la financiación de estos servicios por parte de las compañías de seguros.

3 Estado del Arte

3.1 Introducción

La detección temprana de patologías retinianas es uno de los desafíos más importantes para los sistemas de salud actuales. A nivel global, el glaucoma y la retinopatía diabética afectan a millones de personas y comparten una característica clínica de alto riesgo: no muestran síntomas en sus etapas iniciales, lo que reduce las oportunidades de intervención oportuna (WHO, 2024). Esta situación se agrava por la escasez de especialistas y la insostenibilidad del diagnóstico basado únicamente en el análisis visual humano. En el contexto peruano, el panorama es especialmente preocupante: el 73.5% de la demanda nacional de atención oftalmológica se concentra en Lima Metropolitana, con tiempos de espera que superan los 120 días para acceder a un especialista (Defensoría del Pueblo, 2025), y solo el 37.3% de los pacientes programados para tratamiento láser en el INO recibieron atención en el período evaluado por la CGR (2024). Esta combinación de alta demanda, falta de especialistas y ausencia de herramientas tecnológicas de apoyo al diagnóstico configura un escenario que hace urgente la innovación clínica en el sector oftalmológico.

Ante esta realidad, la relevancia de desarrollar soluciones basadas en inteligencia artificial es clara. Las Redes Neuronales Convolucionales (CNN) han demostrado ser capaces de igualar e incluso superar la precisión diagnóstica humana en la identificación de patologías retinianas, y desde 2018 los primeros sistemas autónomos de IA han recibido aprobación regulatoria a nivel internacional (IAPB, 2026). Las pérdidas de productividad derivadas de la discapacidad visual alcanzan los 173,000 millones de dólares anuales (WHO, 2024), y el mercado global de soluciones tecnológicas para la retinopatía diabética se proyecta crecer de 9,100 a 17,000 millones de dólares entre 2023 y 2033 (Nova One Advisor, 2024), lo que refleja tanto la magnitud del problema como el potencial de impacto de estas soluciones.

Frente a esta problemática, la comunidad científica ha propuesto diversas soluciones orientadas a la automatización del diagnóstico retiniano. Estudios como los de Ejaz et al. (2024) y Shamrat et al. (2024) mostraron que arquitecturas como DenseNet121 y DRNet13 alcanzan precisiones de hasta 97.45% en la detección de múltiples enfermedades retinianas. Mamyrbayev et al. (2025) y Rahim et al. (2026) evidenciaron que los enfoques híbridos CNN-RNN y el ajuste de hiperparámetros elevan el rendimiento diagnóstico hasta el 99.63% de sensibilidad, mientras que Altuve et al. (2025) e Infante Cueva & Cruzado Benites (2024)

confirmaron la efectividad del Transfer Learning con precisiones superiores al 97%. En el plano de la implementación, Moreno et al. (2024), Ticlavilca et al. (2024) y Moreno y Ticlavilca (2025) aportaron marcos de despliegue en la nube con AWS y arquitecturas API REST, y Kumar et al. (2026) proveyeron evidencia técnica sobre el uso de repositorios estandarizados como APTOS 2019 para la validación clínica de los modelos. Sin embargo, la mayoría de estas investigaciones carece de una implementación integral orientada a entornos clínicos reales, dejando abierta la necesidad de un sistema web escalable adaptado al contexto de Lima Metropolitana.

Con el propósito de identificar, analizar y sintetizar el estado actual del conocimiento científico en torno a este problema, el presente capítulo desarrolla una revisión sistemática de la literatura siguiendo la metodología de Kitchenham y Charters (2007), organizada en dos grandes secciones. En la Metodología de Búsqueda (sección 2.5) se describe el proceso estructurado de revisión, articulado en tres fases: la Planificación de la Revisión, que define las preguntas de investigación, palabras clave y criterios de selección y exclusión; la Conducción de la Revisión, que documenta el proceso de búsqueda y filtrado en bases de datos científicas; y la Documentación de la Revisión, que presenta estadísticas sobre los artículos seleccionados por año, cuartil y base de datos. En el Análisis de Resultados (sección 2.6) se consolidan los hallazgos a través de la Matriz de Artículos Seleccionados, el Resumen de Artículos organizado por pregunta de investigación, la Discusión comparativa de los enfoques identificados y las Conclusiones del capítulo.


3.2 Metodología de Búsqueda

3.2.1 Fases o Etapas de la Búsqueda

Para la elaboración del presente estado del arte se adoptó la metodología de revisión sistemática de literatura propuesta por Kitchenham y Charters (2007), estructurada en tres fases secuenciales que guían el proceso desde la planificación hasta la documentación de los hallazgos.

Figura 14

Etapas de una búsqueda



Como se muestra en la Figura 14, la metodología de revisión sistemática de Kitchenham y Charters (2007) organiza el proceso de búsqueda en tres fases secuenciales e interdependientes. La primera es la Fase de Planificación de la Revisión (sección 2.5.2), en la que se establece el protocolo de búsqueda mediante la formulación de las preguntas de investigación, la definición de palabras clave y el establecimiento de los criterios de selección y exclusión que determinan qué artículos son pertinentes para el estudio. La segunda es la Fase de Conducción de la Revisión (sección 2.5.3), en la que se ejecuta la búsqueda en las bases de datos científicas seleccionadas aplicando las cadenas de búsqueda definidas en la fase anterior, y se lleva a cabo el filtrado progresivo de los artículos hasta obtener el conjunto final de estudios. La tercera es la Fase de Documentación de la Revisión (sección 2.5.4), en la que se registran y presentan los resultados del proceso de búsqueda, organizando los artículos según su año de publicación, cuartil de indexación y base de datos de procedencia, lo que permite mostrar la calidad y representatividad del corpus bibliográfico utilizado.

3.2.2 Fase: Planificación de la Revisión

3.2.2.1 Preguntas de Investigación

A fin de orientar la búsqueda hacia la evidencia científica más relevante y definir con precisión el alcance temático y tecnológico de la revisión, se formularon las siguientes preguntas de investigación:

Tabla 12

Preguntas de investigación

#	Acrónimo	Pregunta de Investigación
1	P1	¿Pregunta de Investigación 1? Ejemplo: ¿Qué arquitecturas de Redes Neuronales Convolucionales y técnicas de Deep Learning han sido

		implementadas para la detección automatizada de patologías retinianas?
2	P2	¿Pregunta de Investigación 2? Ejemplo: ¿Cuáles son las variables predictivas (características visuales) extraídas de imágenes de fondo de ojo que utilizan los modelos de Deep Learning para la clasificación de patologías retinianas?
3	P3	¿Pregunta de Investigación 3? Ejemplo: ¿Cuáles son las métricas de desempeño clínico y computacional que se utilizan para evaluar la efectividad de los modelos de Redes Neuronales Convolucionales en oftalmología?
4	P4	¿Pregunta de Investigación 4? Ejemplo: ¿Qué procesos de validación técnica y conjuntos de datos estandarizados se identifican en el entrenamiento y evaluación de modelos de Deep Learning para la detección de patologías retinianas?
5	P5	¿Pregunta de Investigación 5? Ejemplo: ¿Qué infraestructuras tecnológicas se emplean para la integración de modelos predictivos visuales como Sistemas de Soporte al Diagnóstico (CAD) en entornos clínicos?

3.2.2.2 Palabras claves

A partir de las preguntas de investigación formuladas, se identificaron las siguientes palabras clave que conforman las cadenas de búsqueda empleadas en las bases de datos científicas:

Tabla 13

Palabras claves

#	Pregunta de Investigación	Palabras claves
1	P1: ¿Qué arquitecturas de Redes Neuronales	[arquitecturas, Redes Neuronales Convolucionales, CNN, técnicas de Deep Learning] + [detección automatizada,

	Convolucionales y técnicas de Deep Learning han sido implementadas para la detección automatizada de patologías retinianas?	implementación] + [patologías retinianas, enfermedades oculares]
2	P2: ¿Cuáles son las variables predictivas (características visuales) extraídas de imágenes de fondo de ojo que utilizan los modelos de Deep Learning para la clasificación de patologías retinianas?	[variables predictivas, características visuales, biomarcadores] + [extracción, clasificación] + [imágenes de fondo de ojo, fundus images, retinografías]
3	P3: ¿Cuáles son las métricas de desempeño clínico y computacional que se utilizan para evaluar la efectividad de los modelos de Redes Neuronales Convolucionales en oftalmología?	[métricas de desempeño, evaluación, efectividad, exactitud, tiempo de inferencia] + [clínico, computacional] + [modelos CNN, oftalmología]
4	P4: ¿Qué procesos de validación técnica y conjuntos de datos estandarizados se identifican en el entrenamiento y evaluación de modelos de Deep Learning para la detección de	[procesos de validación, validación técnica, validación cruzada] + [conjuntos de datos estandarizados, datasets] + [entrenamiento, evaluación de modelos]

	patologías retinianas?	
5	P5: ¿Qué infraestructuras tecnológicas se emplean para la integración de modelos predictivos visuales como Sistemas de Soporte al Diagnóstico (CAD) en entornos clínicos?	[infraestructuras tecnológicas, integración, despliegue cloud] + [modelos predictivos visuales, Sistemas de Soporte al Diagnóstico, sistemas CAD] + [entornos clínicos, atención primaria]

3.2.2.3 Criterios de Selección y Exclusión

Con el propósito de garantizar la calidad y pertinencia del corpus bibliográfico seleccionado, se establecieron los siguientes criterios de inclusión y exclusión que orientaron el proceso de filtrado de artículos científicos:

Tabla 14

Criterios de selección

#	Criterios
1	Antigüedad de Artículos: Máximo 3 años de antigüedad (2023 - a la fecha)
2	Idioma: Inglés (opcional) o español
3	Tipo de Artículo: Artículo de Journal (revista científica)
4	Tipo de Revista: Indexada en Scopus o Web of Science
5	Quartil: Q1 o Q2
6	Aporte temático: El artículo debe abordar al menos uno de los siguientes ejes vinculados a las preguntas de investigación: (a) arquitecturas CNN/Deep Learning para detección de patologías retinianas, (b) extracción de biomarcadores/características visuales en fundus images, (c) métricas de desempeño clínico-computacional, (d) validación técnica y datasets estandarizados, o (e) infraestructura tecnológica para sistemas CAD en entornos clínicos

Tabla 15

Criterios de exclusión


#	Criterios de Exclusión
1	Tipo de Publicación: Conferencias, Actas de Congresos, Editoriales, Resúmenes (abstracts), Cartas al editor
2	Tipo de Artículo: Revisión de Literatura (Literature Review)
3	Tipo de Artículo: Revisión Sistemática (Systematic Review) o Meta-análisis
4	Tipo de Documento: Tesis, Libros o capítulos de libro
5	Antigüedad: Artículos publicados antes de 2023
6	Indexación: Revistas no indexadas en Scopus/Web of Science, o indexadas en Q3/Q4/sin cuartil

3.2.3 Fase: Conducción de la Revisión

A continuación se detalla el proceso de búsqueda, filtrado y selección llevado a cabo durante la revisión de la literatura, cuyo flujo metodológico se sintetiza en el siguiente diagrama:

Figura 15

Diagrama del proceso de revisión bibliográfica



Como resultado de la búsqueda en la base de datos SCOPUS, aplicando los criterios de selección y exclusión establecidos (antigüedad 2024–2026, idioma inglés, artículo de Journal indexado, cuartil Q1 o Q2, y tipo de aporte), se obtuvieron 57 artículos potencialmente elegibles. De estos, se descartaron 17: X por no cumplir los criterios formales de selección y X por no estar suficientemente relacionados con las preguntas de investigación o presentar un aporte débil para responderlas. Como resultado final, se

seleccionaron 40 investigaciones que cumplieron con los criterios establecidos (Ver Tabla 14).

Tabla 16

Artículos potencialmente elegibles y seleccionados


Base de Datos	Nº de artículos elegibles	Nº de artículos seleccionados
SCOPUS	57	40
Web of Science	X	X
Google Scholar	X	X
TOTAL	57	40

3.2.4 Fase: Documentación de la Revisión

Una vez concluida la revisión sistemática, se elaboraron estadísticas descriptivas sobre los artículos seleccionados con el fin de mostrar la calidad, actualidad y relevancia de la literatura obtenida, permitiendo identificar patrones y tendencias en la producción científica reciente, tal como se presenta en las siguientes figuras:

Figura 16


Distribución de artículos por año de publicación y base de datos



Como se muestra en la Figura 16, la distribución temporal de los artículos seleccionados refleja una producción científica reciente y en crecimiento, concentrándose la mayor cantidad de estudios en 2025 con 23 artículos, seguido por 2024 con 14 artículos y 2026 con 3 artículos que, al pertenecer a un año en curso, muestran el dinamismo del campo de estudio. Esta distribución confirma que la literatura incorporada en esta revisión responde a los avances más recientes en la materia, garantizando la pertinencia de los hallazgos obtenidos.

Figura 17

Distribución de artículos por cuartil de indexación y base de datos



Como se muestra en la Figura 17, la distribución de los artículos según su cuartil de indexación refleja un alto estándar de calidad académica, concentrándose la mayoría en Q1 con 32 artículos, seguido por Q2 con 8 artículos, sin registrarse artículos en Q3 ni Q4. Esta distribución muestra que la revisión se apoya en literatura científica de alto impacto internacional, lo que garantiza el rigor de los hallazgos obtenidos.

3.3 Análisis de Resultados

3.3.1 Matriz de Artículos Seleccionados

Tabla 17

Relación de los artículos analizados por categoría

Pregunta de Investigación	#	Título del Artículo	Autor	Año de Publicación	País de la Revista	Nombre de la Revista	Quartil
¿Qué arquitecturas de Redes Neuronales Convolucionales y técnicas de Deep Learning han sido implementadas para la detección automatizada de patologías retinianas?	1	Deep learning-based CNN for multiclassification of ocular diseases using transfer learning	G Divya Deepak y Subraya Krishna Bhat	2024	Reino Unido	Computer Methods in Biomechanics and Biomedical Engineering: Imaging & Visualization	Q2
	2	Deep learning-based classification of eye diseases using Convolutional Neural Network for OCT images	Mohamed Elkholy y Marwa A. Marzouk.	2024	Suiza	Frontiers in Computer Science	Q2
	3	Hybrid Neural Architectures Combining Convolutional and Recurrent	Orken Mamyrbayev, Sergii Pavlov, Oleksandr Poplavskyi, Kymbat Momynzhano	2025	Kazajistán	Engineering, Technology & Applied Science Research	Q2

	Networks for the Early Detection of Retinal Pathologies	va, Yulii Saldan, Ardan Zhanegiz, Sholpan Zhumagulova y Nurdaulet Zhumazhan.				
4	An advanced deep neural network for fundus image analysis and enhancing diabetic retinopathy detection	F. M. Javed Mehedi Shamrat, Rashiduzzaman Shakil, Sharmin, Nazmul Hoque ovy, Bonna Akter, Md Zunayed Ahmed, Kawsar Ahmed, Francis M. Bui, y Mohammad Ali Moni.	2024	Canadá	Healthcare Analytics	Q1
5	A Self-Supervised Hybrid CNN with Uncertainty-Aware Referral for	Neelapala Anil Kumar, D. Madhusudan, Iacovos Ioannou, G. S. Pradeep	2026	India	Biomedical Signal Processing and Control	Q1

		Diabetic Retinopathy Screening	Ghantasala y Vasos Vassiliou.				
	6	Novel Deep Learning Model for Glaucoma Detection Using Fusion of Fundus and Optical Coherence Tomography Images	Saad Islam, Ravinesh C. Deo, Prabal Datta Barua, Jeffrey Soar y U. Rajendra Acharya.	2025	Australia	Sensors	Q1
	7	Detection of Diabetic Retinopathy Using a Multi-Decision Inception-ResNet-Blended Hybrid Model	Santosh Kumar Henge, Nikhil Reddy Viraati, Musaed Alhussein, Ajay Shriram Kushwaha, Khursheed Aurangzeb y Ravleen Singh.	2025	Estados Unidos	IEEE Access	Q1
	8	Artificial intelligence based glaucoma and diabetic	Isaac Arias-Serrano, Paolo A. Velásquez-López, Laura N. Avila-	2024	Reino Unido	F1000Research	Q1

		retinopathy detection using MATLAB - retrained AlexNet convolutional neural network	Briones, Fanny C. Laurido-Mora, Fernando Villalba-Meneses, Andrés Tirado-Espin, Jonathan Cruz-Varela y Diego Almeida-Galárraga.				
¿Cuáles son las variables predictivas (características visuales) extraídas de imágenes de fondo de ojo que utilizan los modelos de Deep	9	Deep Learning-Based Interpretable Framework for Simultaneous Segmentation of Retinal Multi-lesions and Multi-categorical Disease Classification	Omer Iqbal, Waqas Jadoon, Iftikhar Ahmed Khan, Mehtab Afzal y Afnan Aldhahri.	2025	Suiza	International Journal of Computational Intelligence Systems.	Q1

Learning para la clasificación de patologías retinianas?	10	Enhancing diabetic retinopathy detection through federated convolutional neural networks: Exploring different stages of progression	Alanazi, Saad; Alanazi, Rayan.	2025	Egipto	Alexandria Engineering Journal (AEJ).	Q1
	11	Implementing and evaluating a fully functional AI-enabled model for chronic eye disease screening in a real clinical environment	Skevas, Christos; Pérez de Olaguer, Nicolás; Lleó, Albert; Thiwa, David; Schroeter, Ulrike; Valente Lopes, Inês; Mautone, Luca; Linke, Stephan J.; Spitzer, Martin Stephan; Yap, Daniel; Xiao, Di.	2024	Reino Unido	BMC Ophthalmology	Q2

12	A deep learning framework for the early detection of multi-retinal diseases	Ejaz, Sara; Baig, Raheel; Ashraf, Zeeshan; Alnfiai, Mrim M.; Alnahari, Mona Mohammed; Alotaibi, Reemiah Muneer.	2024	Estados Unidos	PLOS ONE	Q1
13	Diabetic retinopathy detection using ensembled transfer learning based thrice CNN with SVM classifier	Thomas, Neetha Merin; Jerome, S. Albert.	2024	Holanda	Multimedia Tools and Applications	Q1
14	Fundus image classification using feature concatenation for early diagnosis of retinal disease	Ejaz, Sara; Zia, Hafiz U; Majeed, Fiaz; Shafique, Umair; Carvajal Altamiranda, Stefania; Lipari,	2025	Reino Unido	DIGITAL HEALTH	Q2

			Vivian; Ashraf, Imran.				
	15	Independent Evaluation of RETFound Foundation Model's Performance on Optic Nerve Analysis Using Fundus Photography	Maggie S. Chen, Rohith Ravindranath, Robert Chang, Yukun Zhou, Pearse A. Keane y Sophia Y. Wang.	2025	Estados Unidos	Ophthalmology Science	Q1
	16	Retinal Disease Diagnosis Using Deep Learning on Ultra-Wide-Field Fundus Images.	Nguyen, Toan Duc; Le, Duc-Tai; Bum, Junghyun; Kim, Seongho; Song, Su Jeong; Choo, Hyunseung.	2024	Suiza	Diagnostics	Q2
¿Cuáles son las métricas de desempeño clínico y computacional que se	17	A Lightweight CNN for Multiclass Retinal Disease Screening with	Arjun Kumar Bose Arnob, Muhammad Hasibur Rashid Chayon, Fahmid Al Farid, Mohd	2025	Suiza	Journal of Imaging	Q1

utilizan para evaluar la efectividad de los modelos de Redes Neuronales Convolucionales en oftalmología?		Explainable AI	Nizam Husen y Firoz Ahmed.				
	18	Assessing Endoscopic Response in Locally Advanced Rectal Cancer Treated with Total Neoadjuvant Therapy: Development and Validation of a Highly Accurate Convolutional Neural Network	Hannah Williams, Hannah M Thompson, Christina Lee, Aneesh Rangnekar, Jorge T Gomez, Maria Widmar, Iris Wei, Emmanouil P Pappou, Garrett M Nash, Martin R Weiser, Philip B Paty, J. Joshua Smith, Harini Veeraraghavan y Julio Garcia-Aguilar.	2024	Estados Unidos	Annals of Surgical Oncology	Q1
	19	Customized U-Net architecture for automated optic disc segmentation	Ayoub Skouta, Abdelali Elmoufidi, Said Jai-Andalousi y	2026	Suiza	Discover Artificial Intelligence	Q1

		in retinal fundus images	Ouail Ouchetto.				
	20	Data and image processing for intelligent glaucoma detection and optic disc segmentation using deep convolutional neural network architecture	Mohammed Thakir Mahmood y Osman Nuri Ucan.	2025	Países Bajos	Discover Computing	Q2
	21	Automated retinal disease classification using deep learning and AlexNet with statistical models analysis	El-Sayed M. Elkenawy, Nima Khodadadi, Khaled Sh. Gaber, Ehsan Khodadadi, Amel Ali Alhussan, Doaa Sami Khafaga y Marwa M. Eid.	2026	Estados Unidos	PLOS ONE	Q1
	22	Code-Free Deep Learning	Daniel Milad, Fares Antaki, David	2025	Estados Unidos	Ophthalmology Science	Q1

	Glaucoma Detection on Color Fundus Images	Mikhail, Andrew Farah, Jonathan El-Khoury, Samir Touma, Georges M. Durr, Taylor Nayman, Clément Payout, Pearse A. Keane y Renaud Duval.				
23	HyReti-Net hybrid retinal diseases classification and diagnosis network using optical coherence tomography	Jikun Yang, Chaoliang Hsu, Jing Wang, Bin Wu, Yuanyuan Lu, Yuxi Ding, Zhenbo Zhao, Kaili Tang, Feng Lu y Liwei Ma.	2025	Suiza	Frontiers in Medicine	Q1
24	Revolutionizing diabetic eye disease detection: retinal image analysis with cutting-edge	Banumathy D, Swathi Angamuthu, Prasanalakshmi Balaji y Mousmi Ajay Chaurasia.	2024	Reino Unido	PeerJ Computer Science	Q1

		deep learning techniques					
¿Qué procesos de validación técnica y conjuntos de datos estandarizados se identifican en el entrenamiento y evaluación de modelos de Deep Learning para la detección de patologías retinianas?	25	Benchmarking deep models on retinal fundus disease diagnosis and a large-scale dataset	Xue Xia, Ying Li, Guobei Xiao, Kun Zhan, Jinhua Yan, Chao Cai, Yuming Fang y Guofu Huang.	2024	Países Bajos	Signal Processing: Image Communication	Q1
	26	MultiEYE: Dataset and Benchmark for OCT-Enhanced Retinal Disease Recognition from Fundus Images	Lehan Wang, Chubin Ou, Chongchong Qi, Lin An, Mei Jin, Xiangbin Kong y Xiaomeng Li.	2025	Estados Unidos	IEEE Transactions on Medical Imaging	Q1
	27	Diabetic Retinopathy Assessment through Multitask Learning Approach on Heterogeneous Fundus	Hongkang Wu, Kai Jin, Yiyang Jing, Wenyue Shen, Yih Chung Tham, Xiangji Pan, Victor Koh, Andrzej Grzybowski y Juan Ye.	2025	Estados Unidos	Ophthalmology Science	Q1

		Image Datasets					
	28	A hybrid deep learning framework for early detection of diabetic retinopathy using retinal fundus images	Mishmala Sushith, A. Sathiya, V. Kalaipoonguz hali y V. Sathya.	2025	Reino Unido	Scientific Reports	Q1
	29	Automated detection of nine infantile fundus diseases and conditions in retinal images using a deep learning system	Yaling Liu, Hai Xie, Xinyu Zhao, Jiannan Tang, Zhen Yu, Zhenquan Wu, Ruyin Tian, Yi Chen, Miaohong Chen, Dimitrios P. Ntentakis, Yueshanyi Du, Tingyi Chen, Yarou Hu, Sifan Zhang, Baiying Lei y Guoming Zhang	2024	Reino Unido	EPMA Journal	Q1

30	Development of a generative deep learning model to improve epiretinal membrane detection in fundus photography	Joon Yul Choi, Ik Hee Ryu, Jin Kuk Kim, In Sik Lee y Tae Keun Yoo.	2024	Reino Unido	BMC Medical Informatics and Decision Making	Q1
31	A robust ensemble-based deep learning framework for automated retinal disease detection	Goldy Verma, Rania M. Ghoniem, Sheifali Gupta, Salil Bharany, Jaibir Singh, Ateeq Ur Rehman y Belayneh Matebie Taye.	2025	Reino Unido	Health Informatics Journal	Q2
32	Validation of Deep Learning–Based Automatic Retinal Layer Segmentation Algorithms for Age-Related	Souvick Mukherjee, Tharindu De Silva, Cameron Duic, Gopal Jayakar, Tiarnan D.L. Keenan, Alisa T.	2025	Estados Unidos	Ophthalmology Science	Q1

		Macular Degeneration with 2 Spectral-Domain OCT Devices	Thavikulwat, Emily Chew y Catherine Cukras.				
¿Qué infraestructuras tecnológicas se emplean para la integración de modelos predictivos visuales como Sistemas de Soporte al Diagnóstico (CAD) en entornos clínicos?	33	A Low Complexity Efficient Deep Learning Model for Automated Retinal Disease Diagnosis.	Sadia Sultana Chowa, Md. Rahad Islam Bhuiyan, Israt Jahan Payel, Asif Karim, Inam Ullah Khan, Sidratul Montaha, Md. Zahid Hasan, Mirjam Jonkman y Sami Azam.	2025	Suiza	Journal of Healthcare Informatics Research	Q1
	34	Transforming Non-Digital, Clinical Workflows to Detect and Track Vision-Threatening Diabetic Retinopathy via a Digital Platform Integrating	Peranut Chotcomwon gse, Paisan Ruamviboons uk, Chaiwat Karavapitayak ul, Koblarp Thongthong, Anyarak Amornpetchsa thaporn, Methaphon Chainakul, Malee	2025	Alemania	Ophthalmology and Therapy	Q1

	Artificial Intelligence: Implementation Research.	Triprachanath , Eckachai Lerdpanyawat tananukul, Niracha Arjkongharn, Varis Ruamviboons uk, Nattaporn Vongsa, Pawin Pakaymaskul, Turean Waiwaree, Hathaiphan Ruampunpong, Richa Tiwari y Viroj Tangcharoensathien.				
35	Implementing a Common Data Model in Ophthalmology: Mapping Structured Electronic Health Record Ophthalmic Examination Data to	Justin C. Quon, Christopher P. Long, William Halfpenny, Amy Chuang, Cindy X. Cai, Sally L. Baxter, Vamsi Daketi, Amanda Schmitz, Neil Bahroos,	2025	Estados Unidos	Ophthalmology Science	Q1

	Standard Vocabularies	Benjamin Y. Xu y Brian C. Toy.				
36	Graph-enhanced deep learning for diabetic retinopathy diagnosis: A quality-aware and uncertainty-driven approach.	Zarin Akter, Jawad Ibn Ahad, Md. Mutasim Farhan y Riasat Khan.	2025	Estados Unidos	PLOS Computational Biology	Q1
37	A roadmap to implementing machine learning in healthcare: from concept to practice.	Adam Paul Yan, Lin Lawrence Guo, Jiro Inoue, Santiago Eduardo Arciniegas, Emily Vettese, Agata Wolochacz, Nicole Crellin-Parsons, Brandon Purves, Steven Wallace, Azaz Patel, Medhat	2025	Suiza	Frontiers in Digital Health	Q1

		Roshdi, Karim Jessa, Bren Cardiff y Lillian Sung.				
38	Interactive computer- aided diagnosis on medical image using large language models.	Sheng Wang, Zihao Zhao, Xi Ouyang, Tianming Liu, Qian Wang y Dinggang Shen.	2024	Reino Unido	Communicat ions Engineering	Q1
39	Improving diabetic retinopathy screening using artificial intelligence: design, evaluation and before- and-after study of a custom development.	Imanol Pinto, Álvaro Olazarán, David Jurío, Borja De la Osa, Miguel Sainz, Aritz Oscosz, Jerónimo Ballaz, Javier Gorricho, Mikel Galar y José Andonegui.	2025	Suiza	Frontiers in Digital Health	Q1
40	Real-World Evaluation of AI-Driven Diabetic	Mona Duggal, Anshul Chauhan, Vishali Gupta,	2025	Canadá	JMIR Medical Informatics	Q1

		Retinopathy Screening in Public Health Settings: Validation and Implementati on Study	Ankita Kankaria, Deepmala Budhija, Priyanka Verma, Vaibhav Miglani, Preeti Syal, Gagandeep Kaur, Lakshay Kumar, Naveen Mutyala, Rishabh Bezbaruah, Nayanshi Sood, Ashleigh Kernohan, Geeta Menon y Luke Vale				
--	--	--	---	--	--	--	--

3.3.2 Resumen de Artículos Seleccionados

3.3.2.1 P1: ¿Qué arquitecturas de Redes Neuronales Convolucionales y técnicas de Deep Learning han sido implementadas para la detección automatizada de patologías retinianas?

Según Deepak y Bhat (2024), el uso de un modelo optimizado de redes neuronales convolucionales para la multclasificación de enfermedades oculares, aplicando Transfer Learning sobre arquitecturas preentrenadas como SqueezeNet, Darknet-53 y EfficientNet-b0. El estudio surge ante la necesidad de diagnosticar con alta precisión múltiples anomalías oculares de forma simultánea, en un contexto donde

la investigación sobre el impacto de hiperparámetros como el tamaño del lote y los optimizadores en el rendimiento del modelo era aún insuficiente. Para la recolección de imágenes se emplearon cámaras comerciales de fondo de ojo de las marcas Kowa, Canon y Zeiss, distribuidas en múltiples centros médicos. El dataset utilizado fue ODIR (Ocular Disease Intelligent Recognition), con imágenes de fondo de ojo como variables predictoras y los diagnósticos clínicos (normal, catarata y glaucoma) como variable objetivo; el conjunto abarcó 5000 pacientes, de los cuales 4000 (80%) se destinaron al entrenamiento y 1000 (20%) a las pruebas, con clases balanceadas. Para controlar el sobreajuste, la validación combinó una división aleatoria estricta con validación cruzada leave-one-out. Entre las arquitecturas que se evaluaron, DarkNet-53 junto con el optimizador SGDM fue la que mejor respondió, alcanzando una exactitud del 99.40%, una precisión del 99.39%, una sensibilidad del 99.40% y una especificidad del 99.69%. Los autores reconocen que el estudio tendría un mayor alcance si incluyera la subclasificación de enfermedades y patologías como la degeneración macular asociada a la edad y la retinopatía diabética. En cuanto a la crítica, los resultados son sobresalientes en términos numéricos, pero la falta de validación en un entorno clínico real resulta ser una limitación importante, sobre todo considerando que esta investigación está dirigida a un sistema de triaje en condiciones reales.

De manera similar, Elkholy y Marzouk (2024) parten del problema del diagnóstico tardío de enfermedades retinianas, donde la evaluación manual no solo consume tiempo considerable sino que también es propensa a errores que pueden derivar en pérdida permanente de la visión. Para abordarlo, desarrollaron un modelo CNN basado en VGG16 con transfer learning y fine-tuning, incorporando además un preprocesamiento mediante el algoritmo Retinex multiescala y desenfoque gaussiano. Las imágenes usadas corresponden a Tomografía de Coherencia Óptica (OCT), obtenidas de un dataset público de Kaggle compuesto por 35,468 imágenes. Las características extraídas de estas imágenes fueron la variable predictora, mientras que la variable objetivo abarcó cuatro clases balanceadas de 8,867 imágenes cada una: retina normal, Edema Macular Diabético, Membrana Neovascular Coroidea y Drusas; con 1,000 imágenes destinadas a pruebas y el resto al entrenamiento. La validación se apoyó en curvas ROC y el análisis de verdaderos

y falsos positivos, obteniendo una precisión del 97% tras aplicar el ajuste fino. En cuanto a sus limitaciones, el modelo presentó un problema inicial de subajuste que demandó mayor tiempo de entrenamiento, y no incluye la clasificación de urgencia clínica de los casos detectados. Como crítica propia, considero que si bien la exactitud del 97% es sobresaliente y el uso de imágenes OCT permite visualizar detalles transversales internos que una cámara normal no capta, la dependencia exclusiva de este tipo de imágenes limita la escalabilidad operativa de mi aplicación web, ya que los tomógrafos OCT son equipos mucho más costosos y de menor accesibilidad en los consultorios de atención primaria de Lima Metropolitana en comparación con los retinógrafos tradicionales.

Por su parte, Mamyrbayev et al. (2025) proponen una arquitectura híbrida que combina Redes Neuronales Convolucionales (CNN) con Redes Recurrentes (LSTM), fusionando características de píxeles con descriptores anatómicos y geométricos como la distancia disco-fóvea y la curvatura de vasos. El estudio surge porque las técnicas tradicionales no manejan bien la variabilidad de las imágenes retinianas, y las CNN por sí solas no capturan las relaciones geométricas de alto nivel que son clave para el diagnóstico. Las imágenes usadas son retinografías a color tomadas bajo distintas condiciones de iluminación y ruido. El dataset combinó la base pública DIARETDB1 (130 imágenes, de las cuales 110 muestran signos de retinopatía diabética y 20 son normales) con una colección privada de 100 imágenes adicionales; los píxeles y vectores geométricos fueron las variables predictoras, y la variable objetivo fueron etiquetas binarias (sano vs enfermo), con una división de 80% para entrenamiento y 20% para validación. La validación incluyó evaluación comparativa frente a ResNet50 y métodos clásicos, respaldada por pruebas t pareadas ($p < 0.01$). El modelo híbrido alcanzó una exactitud del 97%, sensibilidad del 96%, especificidad del 98% y F1-score de 0.97. Como limitación, errores en la extracción de puntos anatómicos clave como el disco óptico pueden afectar la precisión del modelo de forma encadenada. En cuanto a la crítica, depender de un preprocesamiento tan específico podría generar cuellos de botella en situaciones reales con imágenes de baja calidad, lo que complicaría la automatización en tiempo real que necesita la plataforma web de esta investigación.

Del mismo modo, Shamrat et al. (2024) abordan el problema del diagnóstico de la retinopatía diabética (RD), cuyo análisis manual es tedioso y propenso a errores, lo que dificulta la detección temprana necesaria para prevenir la pérdida permanente de visión. Como aporte, presentan DRNet13, un modelo de CNN diseñado para automatizar la clasificación en distintas etapas de la enfermedad. Las imágenes usadas son retinografías tomadas en el Aravind Eye Hospital en India. El dataset original de 3,662 imágenes fue ampliado a 7,500 mediante técnicas de aumento de datos para balancear la muestra. Los rasgos extraídos de las retinografías fueron la variable predictora, y la variable objetivo agrupó cinco clases: Sin RD, Leve, Moderada, Severa y Proliferativa, con 1,500 imágenes por clase, divididas en 60% para entrenamiento, 20% para validación y 20% para pruebas. La validación incluyó matrices de confusión, curvas ROC y comparación contra 15 arquitecturas preentrenadas. DRNet13 alcanzó una exactitud de validación del 97%, exactitud de prueba del 96% y un AUC de 0.99. Entre sus limitaciones, mostró errores de clasificación entre fases con síntomas visuales parecidos, y su uso general podría verse afectado por la variedad del dataset. En cuanto a la crítica, si bien la validación con retinografías respalda la viabilidad tecnológica de la aplicación web para centros de atención primaria en Lima Metropolitana, el balanceo artificial del dataset no refleja la distribución real de pacientes en consultorios locales, por lo que se necesitará un fine-tuning con datos demográficos peruanos para garantizar que el sistema funcione bien en la práctica.

Por otro lado, Kumar et al. (2026) proponen una arquitectura híbrida y ligera que fusiona MobileNet, EfficientNet y atención residual para la detección de retinopatía diabética, incorporando un módulo de derivación basado en incertidumbre mediante MC-Dropout y mapas Grad-CAM. El estudio parte de que el diagnóstico manual es lento y variable, y que los modelos actuales no cuentan con mecanismos para medir la incertidumbre de forma segura en entornos con pocos recursos. Las imágenes usadas son fotografías a color del fondo de ojo tomadas en entornos clínicos reales. El dataset unificó APTOS 2019 y Messidor (4,862 retinografías etiquetadas) con 60,000 imágenes sin etiquetar para preentrenamiento, usando los cinco niveles de severidad como variable objetivo y una división de 80/10/10% mediante validación cruzada. La validación incluyó separación estricta a nivel de

paciente, revisiones de equidad por calidad de imagen y 30 pases de inferencia estocástica. Los resultados mostraron una exactitud del 97.8%, un macro F1-score del 98.1% y un AUC del 99.2%, y además se comprobó que derivar el 10% de casos con mayor incertidumbre captura el 75% de los errores. Como limitaciones, los autores señalan el carácter retrospectivo del estudio y la falta de evaluaciones frente a sesgos demográficos como sexo o etnia. En cuanto a la crítica, el mecanismo de derivación por incertidumbre es muy útil para el triaje que plantea esta investigación, aunque usar múltiples redes y 30 pases estocásticos va a requerir una buena optimización de recursos en la nube para que la latencia de la plataforma web no se vea afectada.

De igual forma, Islam et al. (2025) abordan el problema del diagnóstico tardío del glaucoma, una enfermedad que no muestra síntomas en sus etapas iniciales y que necesita herramientas automatizadas y objetivas para evitar la ceguera irreversible, dado que los exámenes clínicos tradicionales no son suficientes para detectarla a tiempo. Como aporte, presentan un modelo de aprendizaje profundo de doble rama que fusiona características de nivel medio extraídas mediante una red ResNet-18 y una CNN personalizada. Los instrumentos de recolección fueron fotografías de fondo de ojo y escaneos OCT emparejados por paciente, recolectados en el Bangladesh Eye Hospital. El dataset privado se compuso de 416 imágenes de 208 ojos. La variable predictora fueron las representaciones estructurales combinadas de ambos modelos, y la variable objetivo clasificó los ojos en normales (108) y con glaucoma (100). Para el entrenamiento, 100 ojos conformaron el conjunto de prueba fijo y 108 se destinaron al entrenamiento, separando el 10% para validación. La validación se ejecutó mediante curvas ROC y validación cruzada estratificada de cinco pliegues. El modelo de fusión bimodal alcanzó un 92% de exactitud, 92% de sensibilidad, 92% de especificidad y un AUC de 0.95. Entre sus limitaciones, el estudio señala el uso de un dataset geográficamente limitado, el análisis de cortes OCT en 2D en lugar de volúmenes 3D y la falta de interpretabilidad visual del modelo. Como crítica propia, la necesidad de procesar escaneos OCT en paralelo con retinografías reduce drásticamente su aplicabilidad real, ya que los tomógrafos OCT son equipos de alto costo y nula disponibilidad en la atención primaria de Lima Metropolitana. Por eso, nuestra solución orientada exclusivamente al análisis

de retinografías garantiza una implementación más escalable en el sistema de salud público local.

Por otro lado Henge et al. (2025) presentan un modelo híbrido denominado Multi-Decision Inception-ResNet-Blended Hybrid Model (BHM), diseñado para detectar y clasificar las cinco etapas de la retinopatía diabética (RD): No-DR, Leve, Moderada, Severa y Proliferativa. El estudio responde a la dificultad de detectar la RD en etapas tempranas debido a la sutileza de sus síntomas, ya que el diagnóstico tardío puede derivar en pérdida severa de la visión. Las imágenes usadas provienen de los datasets públicos EyePACS y APTOS, combinando imágenes a color y en escala de grises redimensionadas a $312 \times 312 \times 3$ como variables predictoras, y la etapa de RD clasificada en cinco categorías como variable objetivo, con una división de 70-80% para entrenamiento, 10-15% para validación y 10-15% para prueba. El modelo emplea 172 capas, donde 86 procesan imágenes a color y 86 en escala de grises, usando transfer learning con optimizadores Adam y SGD según la etapa de entrenamiento. La validación comparó el modelo frente a algoritmos como Naive Bayes, Regresión Logística, Random Forest, SVM y XGBoost, usando la prueba chi-cuadrado como mecanismo de refinamiento. Los resultados mostraron una precisión del 98.1%, un F1-score de 98.1% y una prueba chi-cuadrado de 97.8%, superando a todos los modelos comparados. Como limitaciones, destacan la alta demanda computacional, posibles problemas de latencia en tiempo real y la falta de validación en datasets externos. En cuanto a la crítica, el artículo no detalla el número de imágenes por clase ni el proceso de balanceo del dataset, aspectos clave en clasificación multiclase; además, la arquitectura de 172 capas añade complejidad sin un análisis que justifique su ventaja frente a modelos más ligeros.

Por su parte, Arias-Serrano et al. (2024) presentan un modelo basado en AlexNet reentrenada mediante Transfer Learning en MATLAB, complementado con mapas Grad-CAM y comparado frente a ResNet50 y GoogLeNet para la multclasificación de glaucoma y retinopatía diabética. El estudio surge ante la dependencia del diagnóstico oftalmológico de evaluaciones manuales que exigen especialistas costosos y largos tiempos de espera. Las imágenes usadas son retinografías a color en formato RGB. El dataset unificó cinco repositorios públicos (LAG, APTOS, HRF, ODIR y sjchoi86-HRF), sumando 9,860 imágenes ajustadas a 227×227

píxeles como variables predictoras, con tres clases objetivo (sano, sospecha de glaucoma y retinopatía), divididas en 70% para entrenamiento y 30% para validación. La validación combinó inferencia visual mediante Grad-CAM para confirmar el aprendizaje de características clínicas relevantes, como la relación copa-disco, con un análisis por épocas para descartar sobreajuste. AlexNet alcanzó una exactitud del 93.24%, con una sensibilidad del 99.30% para retinopatía y del 75.80% para glaucoma, entrenándose en solo 15 minutos frente a las 10 horas que necesitó ResNet50. Los autores reconocen que la herramienta exige dominio del entorno MATLAB y no cuenta con una interfaz accesible para usuarios no especializados. En cuanto a la crítica, si bien arquitecturas ligeras como AlexNet logran alta precisión con pocos recursos, su desarrollo en MATLAB limita la portabilidad e integración con infraestructuras cloud modernas; por ello, en esta investigación se tomará ese enfoque y se trasladará a frameworks como TensorFlow y Keras, cuya compatibilidad con entornos de despliegue en la nube se adapta mejor a los objetivos de la plataforma web.

Tras revisar la literatura científica sobre la detección automatizada de patologías retinianas, se identificaron los estudios más relevantes que responden a la primera pregunta de investigación. Para organizar y comparar esta información, se presenta un resumen de los artículos revisados en la Tabla 18:

Tabla 18

Resumen de Artículos

Cita Bibliográfica en APA 7	Aporte	Variables	Modelo	Métricas y Resultados
Deepak y Bhat (2024)	Optimización de CNNs mediante transfer learning.	Imágenes de fondo de ojo (Normal, catarata, glaucoma).	DarkNet-53	Accuracy - 99.4 %
Elkholy y Marzouk (2024)	Clasificación con	Características de imágenes OCT.	VGG16	Accuracy - 97 %

	preprocesamiento o multiescala.			
Mamyrbayev et al. (2025)	Fusión de características de píxeles con descriptores anatómicos y geométricos.	Píxeles, distancia disco-fóvea, curvatura de vasos.	CNN (ResNet50) + LSTM Partición: 80/20%.	Accuracy - 97 %, F1-score - 0.97
Shamrat et al. (2024)	Arquitectura profunda para clasificación de RD.	Características de retinografías aumentadas.	DRNet13	Accuracy - 96 %, AUC - 99 %
Kumar et al. (2026)	Arquitectura híbrida ligera con módulo de derivación (MC-Dropout) y Grad-CAM.	Imágenes de fondo de ojo.	MobileNet + EfficientNet	Accuracy - 97.8 %, AUC - 99.2 %
Islam et al. (2025)	Fusión bimodal de retinografías y OCT.	Representaciones estructurales combinadas.	ResNet-18 + CNN	Accuracy - 92 %, AUC - 95 %
Henge et al. (2025)	Procesamiento paralelo de imágenes duales.	Imágenes a color y blanco/negro.	Inception-ResNet	Accuracy - 98.1 %
Arias-Serrano et al. (2024)	Triaje automatizado de bajo costo computacional.	Patrones visuales RGB.	AlexNet	Accuracy - 93.2 %

3.3.2.2 P2: *¿Cuáles son las variables predictivas (características visuales) extraídas de imágenes de fondo de ojo que utilizan los modelos de Deep Learning para la clasificación de patologías retinianas?*

De acuerdo con Iqbal et al. (2025), el problema del diagnóstico tardío de enfermedades retinianas y las limitaciones de los modelos tradicionales de "caja negra", que carecen de interpretabilidad clínica y sufren por el desbalance de clases. Como aporte, desarrollaron un marco de aprendizaje profundo interpretable y ligero, integrando mecanismos de atención y convoluciones separables para la segmentación de múltiples lesiones y clasificación multiclase simultánea. Los instrumentos de recolección fueron retinografías de múltiples repositorios públicos: ODIR, RFMID e IDRID. El modelo extrae características espaciales orientadas a biomarcadores anatómicos como la mácula, vasos sanguíneos, disco y copa óptica, además de anomalías como hemorragias, exudados, microaneurismas y drusas. La variable objetivo categorizó desde la severidad de las lesiones hasta la presencia de múltiples enfermedades, clasificando hasta 30 condiciones en RFMID. Se procesaron 3,200 imágenes de RFMID, 10,000 de ODIR y 597 de IDRID, balanceadas mediante SMOTE. La validación incluyó curvas ROC, métricas de intersección y mapas de calor Grad-CAM. El modelo alcanzó un AUC y exactitud del 96% en clasificación y un AUPR del 71.08% en segmentación. Entre sus limitaciones, el aumento artificial de datos puede alterar la disposición espacial de las lesiones y la resolución visual puede degradarse sin un preprocesamiento óptimo. En cuanto a la crítica, que el modelo resalte variables anatómicas mediante mapas de calor resuelve el problema de interpretabilidad. Esto demuestra que un sistema automatizado no solo puede emitir un diagnóstico, sino también justificarlo visualmente ante el médico, lo que aumenta la confianza clínica en los resultados obtenidos a partir de retinografías convencionales.

Mientras tanto, Alanazi y Alanazi (2025) abordan el problema de la dependencia de la evaluación manual de imágenes retinianas, que restringe la flexibilidad, accesibilidad y precisión en el diagnóstico de la retinopatía diabética, una de las principales causas mundiales de pérdida de visión. Como aporte, presentan una red neuronal convolucional federada (FedCNN) que entrena el modelo colaborativamente entre múltiples instituciones protegiendo la privacidad del

paciente, complementada con SMOTE para balancear clases y el filtro Weinmed para reducir ruido. Los instrumentos de recolección fueron retinografías a color de alta resolución del dataset EyePACS de Kaggle, compuesto por 3,662 imágenes. Mediante su módulo VGG-19, el modelo extrae patrones visuales que incluyen signos tempranos como microaneurismas, exudados y hemorragias, así como biomarcadores avanzados como edema macular, neovascularización y hemorragia vítrea. La variable objetivo categorizó la enfermedad en cinco niveles: Sin RD (1805), Leve (370), Moderada (999), Severa (193) y Proliferativa (295). La validación se realizó en conjuntos de prueba independientes mediante curvas ROC y matrices de desempeño. El modelo alcanzó una exactitud del 98.5%, precisión del 98.2% y F1-score del 98.5%. Entre sus limitaciones, el aprendizaje federado exige una infraestructura de comunicación robusta, lo que puede generar problemas de latencia, consumo de ancho de banda y altos requisitos computacionales. En cuanto a la crítica, aunque la arquitectura descentralizada sería inviable para las postas médicas de Lima Metropolitana, que el modelo detecte microaneurismas y exudados usando solo retinografías estándar valida el núcleo tecnológico de nuestra aplicación web.

A su vez Skevas et al. (2024) abordan el problema de que la selección tradicional de enfermedades oculares crónicas depende en gran medida de la inspección manual, un proceso que consume tiempo, requiere muchos recursos y donde cada especialista puede llegar a conclusiones distintas y al error humano. Como aporte, implementaron y evaluaron una solución integrada de hardware y software que usa inteligencia artificial para el filtrado automatizado de retinopatía diabética, degeneración macular asociada a la edad y glaucoma en un entorno clínico real. El instrumento de recolección fue una cámara retiniana digital (DRS Plus) operada por personal de enfermería. El dataset de prueba en el hospital se compuso de 231 pacientes de etnia caucásica, aunque los algoritmos fueron entrenados previamente con miles de imágenes, como las 32,828 usadas para el modelo de glaucoma. Los modelos analizan características visuales de fotografías a color centradas en la mácula; para glaucoma, el algoritmo se concentra en la configuración de la cabeza del nervio óptico sin requerir medición de presión intraocular, mientras que para RD y AMD rastrea patrones lesionales e identifica biomarcadores que en ocasiones se superponen con anomalías como defectos del epitelio pigmentario, nevos

coroideos y membranas epirretinianas. La variable objetivo fue una clasificación de derivación para las tres patologías. La validación confrontó las predicciones de la IA contra la auditoría de un oftalmólogo experto, alcanzando una sensibilidad del 100% para RD, 90.91% para AMD y 93.26% para glaucoma. Entre sus limitaciones, el estudio reconoce una muestra reducida, la restricción a una sola etnia y la ausencia de modalidades como OCT. Como crítica propia, limitarse a pacientes caucásicos evidencia una debilidad global de los algoritmos de IA. Para que el sistema funcione, los modelos deberán calibrarse con imágenes de la población local, evitando falsos diagnósticos por las variaciones en la pigmentación retiniana peruana.

Por otro lado, Ejaz et al. (2024) abordan el lento y falible análisis manual de retinografías. Como aporte, proponen una CNN de 12 capas para detectar múltiples enfermedades simultáneamente. Se emplearon retinografías a color de los datasets RFMID y RFMID 2.0. El modelo extrae biomarcadores anatómicos como el disco y copa óptica, vasos, fovea y mácula, además de lesiones como exudados, hemorragias y microaneurismas. La variable objetivo definió cuatro clases: Retinopatía Diabética, Opacidad de Medios, Excavación del Disco y paciente sano. Las 1,908 imágenes originales se balancearon sintéticamente a 9,442, divididas en 70% entrenamiento, 10% validación y 20% pruebas. La validación se basó en matrices de confusión y pérdida de entropía cruzada, alcanzando una exactitud general del 88.72%. Entre sus limitaciones destacan el desbalance original de clases y el sobreajuste al usar redes de mayor profundidad. Como crítica propia, si bien este estudio respalda la viabilidad de usar retinografías para nuestra aplicación web en Lima Metropolitana, depender demasiado del aumento de datos para balancear clases puede ser un problema. El algoritmo tendrá que aprender a trabajar con pacientes reales sin que los datos sintéticos terminen distorsionando las lesiones que debe detectar.

Asimismo, Thomas y Jerome (2024) proponen un sistema CAD para la detección automática de retinopatía diabética (DR) a partir de imágenes de fondo de ojo, respondiendo al problema de la detección tardía que puede derivar en ceguera irreversible ante la escasez de especialistas y el alto volumen de pacientes diabéticos. Las imágenes usadas provienen de las bases de datos públicas Messidor

(1,200 imágenes) y EyePACs (88,702 imágenes), complementadas con un dataset clínico del Hospital Ocular Chaithanya de Kerala, sumando cerca de 24,000 imágenes de fondo de ojo. Las variables predictoras fueron características de textura extraídas mediante la Matriz de Co-ocurrencia en Escala de Grises (GLCM), como contraste, correlación, energía y homogeneidad, calculadas sobre vasos sanguíneos segmentados con el método EPFCMC; la variable objetivo fue la clasificación entre retina normal y DR en sus etapas leve, moderada y severa. El conjunto se dividió en 24,000 imágenes para entrenamiento, 12,000 para validación y 12,000 para prueba. La validación incluyó un estudio comparativo entre modelos Inception, ResNet y MobileNet, evaluando exactitud, precisión, recall, F1-score, índice Jaccard, MCC y Kappa de Cohen. El modelo ETL con triple CNN y SVM alcanzó una exactitud del 98.94%, precisión de 98.99%, recall de 99.78% y F1-score de 99.38%, superando a todos los métodos comparados. Entre sus limitaciones, la segmentación EPFCMC tiene dificultades con vasos delgados e irregulares, y la exactitud de validación (78.41%) es notoriamente inferior a la de entrenamiento, lo que sugiere sobreajuste. En cuanto a la crítica, esa brecha entre entrenamiento y validación es una señal de alerta que los autores no abordan de forma suficiente; además, incluir solo 20 imágenes clínicas propias resulta poco representativo y la falta de validación externa limita la confianza en la capacidad del modelo para generalizar.

Por su parte, Ejaz et al. (2025) presentan un sistema de clasificación de enfermedades retinianas basado en una arquitectura CNN híbrida con fusión de características mediante Análisis de Correlación Canónica (CCA), buscando resolver la limitación de los modelos CNN simples que no capturan bien la complejidad visual en imágenes de fondo de ojo con bajo contraste y ruido. Las imágenes usadas provienen de los datasets públicos RFMiD y RFMiD 2.0, disponibles en Kaggle, con cuatro clases: retinopatía diabética (471 imágenes), neblina de medios (334 imágenes), cupping del disco óptico (172 imágenes) y ojo sano (931 imágenes), sumando 1,908 imágenes en total. Las variables predictoras son características visuales extraídas en paralelo por dos modelos CNN, uno de 12 capas y otro de 20 capas, que capturan patrones de bajo y alto nivel como bordes, texturas y formas asociadas a lesiones retinianas; la variable objetivo es la categoría de enfermedad. Tras el aumento de datos, el conjunto se dividió en 70%

entrenamiento, 20% prueba y 10% validación. La validación evaluó ocho clasificadores de aprendizaje automático sobre el vector fusionado por CCA, usando métricas de exactitud, sensibilidad, precisión, recall, F1-score y MCC. El clasificador de ensamble (SVM + regresión logística + árbol de decisión) alcanzó la mayor exactitud con 93.39%, precisión de 93.41%, recall de 93.38% y F1-score de 92.61%, superando al clasificador Naïve Bayes (75.27%) y a estudios previos con el mismo dataset (89.10%). Los autores reconocen que no incorporaron mejora de contraste ni manejo de ruido en el preprocesamiento, y que el dataset es pequeño y está desequilibrado. Desde una mirada crítica, no incluir preprocesamiento de contraste en imágenes médicas donde la calidad es clave podría afectar el rendimiento real del sistema; además, usar solo 172 imágenes de ODC sigue siendo una muestra reducida para representar adecuadamente esa patología.

Del mismo modo, Chen et al. (2025) proponen un sistema para predecir métricas del nervio óptico usando el modelo fundacional RETFound como extractor de características a partir de fotografías de fondo de ojo, con el fin de estimar el cociente copa-disco (CDR) y el grosor de la capa de fibras nerviosas retinianas (RNFL). El estudio responde a la limitada disponibilidad de la OCT en entornos de bajos recursos, buscando extraer métricas estructurales del nervio óptico desde imágenes de fondo de ojo más accesibles como herramienta de detección de glaucoma. Las imágenes usadas son fotografías de fondo de ojo de 45 grados tomadas con equipos Carl Zeiss Meditec FF450 y escaneos OCT con Zeiss Cirrus 5000, obtenidos del Byers Eye Institute de Stanford entre 2014 y 2021. El dataset comprende 776 pares fondo de ojo-OCT de 463 pacientes; las variables predictoras son vectores de 128 características extraídas por RETFound de imágenes ajustadas a 224×224 , y las variables objetivo son el CDR, el grosor promedio de RNFL, por cuadrantes y por horas del reloj, con una división de 80/20 por paciente. La validación usó validación cruzada de cinco pliegues para ajuste de hiperparámetros y evaluación final con R^2 , MAE y RMSE, comparando contra VGG16 y ViT. El modelo RETFound+Ridge alcanzó $R^2=0.961$ para RNFL y RETFound+Lasso $R^2=0.898$ para CDR, superando a ViT ($R^2=0.731$) y VGG16 ($R^2=0.600$); en tareas multioutput el desempeño fue menor, con $R^2=0.811$ para cuadrantes y $R^2=0.583$ para horas del reloj. Entre sus limitaciones destacan el origen de un solo centro del dataset, la sobrerrepresentación de pacientes con patología y posibles sesgos raciales

por la composición del conjunto de entrenamiento de RETFound. En cuanto a la crítica, usar regresores lineales sobre características congeladas limita el análisis; explorar fine-tuning o regresores no lineales habría dado una evaluación más completa del potencial real del modelo.

De igual forma, Nguyen et al. (2024) presentan un sistema automatizado para clasificar enfermedades retinianas a partir de imágenes de fondo de ojo de campo ultra-amplio (UFI), con el fin de apoyar la detección de patologías como la retinopatía diabética, la degeneración macular, la membrana epirretiniana y la oclusión venosa retiniana en contextos donde escasean los especialistas. Las imágenes usadas provienen de un dataset propio del Hospital Kangbuk Samsung de Corea del Sur, compuesto por 4,697 imágenes UFI (2,600×2,048 píxeles) tomadas entre 2006 y 2019 y anonimizadas bajo aprobación del IRB. Los patrones de lesiones, hemorragias y estructuras como el disco óptico, la mácula y la fovea fueron las variables predictoras, mientras que la variable objetivo fue la clasificación binaria normal/anormal. El dataset se dividió en 4,226 imágenes para entrenamiento y 471 para prueba, y con técnicas de aumento de datos se expandió a más de 21,000 imágenes. La validación comparó cinco arquitecturas (ResNet152, Vision Transformer, InceptionResNetV2, RegNet y ConVNext) bajo tres condiciones: datos sin procesar, con aumento, y con el sistema completo que incluye mejora de brillo, ecualización de histograma y transfer learning desde ImageNet, evaluando AUC, F1-score, Kappa y exactitud. ResNet152 obtuvo el mejor desempeño con un AUC del 96.47% (IC 95%: 0.931-0.974), una exactitud del 89.17%, un F1-score del 89.09% y un Kappa del 75.61%. Entre las limitaciones, los autores señalan la falta de documentación sistemática de la fase exploratoria y la ausencia de estrategias de tratamiento. En cuanto a la crítica, el uso de un dataset privado limita la posibilidad de reproducir los resultados, y la clasificación binaria representa una simplificación clínica importante que no considera la presencia simultánea de varias patologías en una misma imagen.

Tras revisar la literatura científica sobre la detección automatizada de patologías retinianas, se identificaron los estudios más relevantes que responden a la segunda pregunta de investigación. Para organizar y comparar esta información, se presenta un resumen de los artículos revisados en la Tabla 19:

Tabla 19

Resumen de Artículos

Cita Bibliográfica en APA 7	Aporte	Variables	Modelo	Métricas y Resultados
Iqbal et al. (2025)	Segmentación y clasificación multiclase simultánea.	Mácula, vasos, disco/copa, lesiones.	CNN + Grad-CAM	Accuracy - 96 %, AUC - 96 %
Alanazi y Alanazi (2025)	Entrenamiento colaborativo preservando privacidad.	Microaneurismas, exudados, edema macular.	FedCNN (VGG-19)	Accuracy - 98.5 %, F1-score - 98.5 %
Skevas et al. (2024)	Cribado automatizado en entorno clínico real.	Cabeza del nervio óptico, lesiones maculares.	EfficientNet	Sensitivity (RD) - 100 %, Sensitivity (Glaucoma) - 93.2 %
Ejaz et al. (2024)	Detección temprana de múltiples patologías.	Disco, copa, fovea, vasos, exudados.	CNN (12 capas)	Accuracy general - 88.7 %, Accuracy ODC - 94.6 %
Thomas y Jerome (2024)	Sistema CAD para detección automatizada de DR.	Textura GLCM de vasos sanguíneos.	Triple CNN + SVM	Accuracy - 98.9 %, F1-score - 99.3 %
Ejaz et al. (2025)	Arquitectura CNN híbrida paralela con fusión CCA.	Características visuales de bajo y alto nivel.	CNN dual + Ensamble	Accuracy - 93.3 %, F1-score - 92.6 %

Chen et al. (2025)	Uso del modelo fundacional RETFound como extractor sin reentrenamiento.	Características latentes de retinografías.	RETFound (ViT) + Regresión	R ² (RNFL) - 0.961, R ² (CDR) - 0.898
Nguyen et al. (2024)	Clasificación binaria en imágenes UFI con mapas de calor.	Patrones de lesiones y estructuras en UFI.	ResNet152	Accuracy - 89.1 %, AUC - 96.4 %

3.3.2.3 P3: *¿Cuáles son las métricas de desempeño clínico y computacional que se utilizan para evaluar la efectividad de los modelos de Redes Neuronales Convolucionales en oftalmología?*

Según Arnob et al. (2025), proponen una Red Neuronal Convolucional liviana con mecanismos de atención para la detección multiclase de diez enfermedades retinianas a partir de imágenes de fondo de ojo, incorporando técnicas de IA explicable mediante Grad-CAM y Grad-CAM++. El estudio responde a tres problemas concretos: el desbalance de clases, los altos costos computacionales de los modelos convencionales y la falta de transparencia en el razonamiento de los modelos de aprendizaje profundo, barreras que dificultan su adopción clínica. Las imágenes usadas provienen de un dataset de 5,335 fotografías de fondo de ojo obtenidas de dos hospitales en Bangladesh, anotadas por profesionales de salud y tomadas con cámaras Topcon. Las variables predictoras son las imágenes ajustadas a 150×150 píxeles, y la variable objetivo es la clase de enfermedad entre diez categorías (Retinopatía Diabética, Glaucoma, Cicatriz Macular, entre otras); el desbalance fue corregido con SMOTE, resultando en 15,090 imágenes balanceadas, divididas en 70% entrenamiento, 15% validación y 15% prueba. La validación comparó el modelo contra cinco arquitecturas base (VGG16, ResNet50, InceptionV3, MobileNetV2 y EfficientNetB0) bajo condiciones controladas. Los resultados muestran una exactitud del 87.9%, precisión macro de 0.882, recall macro de 0.879 y F1-score macro de 0.880, superando en un 58% de reducción de

error al mejor modelo base; ocho de las diez clases alcanzaron tasas de verdaderos positivos superiores al 95%. Entre sus limitaciones, el estudio se restringe a un único conjunto nacional, no evalúa la severidad de la enfermedad y no incluye datos clínicos adicionales. En cuanto a la crítica, la comparación con los modelos base no es del todo justa al limitarlos a 150×150 píxeles con capas congeladas, lo que reduce artificialmente su rendimiento; además, aplicar SMOTE en el espacio de imagen aplanada puede generar artefactos en las muestras sintéticas.

Asimismo, Williams et al. (2024) desarrollan y validan una CNN para evaluar la respuesta endoscópica del cáncer de recto localmente avanzado tratado con terapia neoadyuvante total (TNT), distinguiendo imágenes con tumor de aquellas sin tumor, incluyendo casos de recurrencia local. El problema central es que la evaluación endoscópica es subjetiva y depende del operador, con una precisión de entre 65–85%, lo que afecta decisiones críticas como la preservación del órgano frente a la resección quirúrgica. Las imágenes usadas son endoscópicas retrospectivas obtenidas con endoscopio flexible Olympus (CF-Q160S) de pacientes con cáncer de recto estadio II/III tratados entre 2012 y 2020 en el Memorial Sloan Kettering Cancer Center. Las variables predictoras son las imágenes ajustadas a 224×224 píxeles y la variable objetivo es la clasificación binaria Tumor/No Tumor; el dataset comprende 2,717 imágenes de 288 pacientes, divididas en entrenamiento/validación (1,785 imágenes) y dos conjuntos de prueba: principal (785 imágenes) y recurrencia local (147 imágenes). La validación fue doble: interna mediante AUROC y externa comparando el modelo con 16 cirujanos de distintos niveles usando 119 imágenes. Los resultados muestran AUROC de 0.99 en entrenamiento, 0.98 en prueba principal (exactitud 91%, sensibilidad 94%, especificidad 88%) y 0.92 en recurrencia local, aunque con baja sensibilidad en este último (0.63). Entre sus limitaciones están el tamaño reducido del conjunto de recurrencia local, la falta de variable temporal y la ausencia de datos radiológicos. En cuanto a la crítica, el modelo muestra su mayor debilidad precisamente en el escenario más crítico, lo que sugiere que la sensibilidad debería ser el indicador prioritario por encima del AUROC global.

Por su parte, Skouta et al. (2026) proponen un framework de segmentación automática del disco óptico basado en una arquitectura U-Net personalizada para

superar las limitaciones de generalización entre bases de datos de los enfoques convencionales. El problema es la variabilidad morfológica del disco óptico según etnia, edad y patología, junto con la presencia de vasos y atrofia peripapilar que dificulta su delimitación precisa. Las imágenes provienen de siete bases de datos públicas tomadas con equipos especializados: IDRiD con cámara Kowa VX-10 Alpha, REFUGE con Zeiss Visucam 500 y Canon CR-2, DRISHTI-GS con Zeiss FF450 Plus, PAPILA con Topcon TRC-NW400, DRIVE con Canon CR5, DIARETDB1 y E-optha EX. Las variables predictoras son imágenes fundus RGB a 576×560 píxeles y la variable objetivo es la máscara binaria del disco óptico; IDRiD (516 imágenes, ampliadas a 1,275) se usó para entrenamiento con una división 90/10, mientras los demás datasets se reservaron para evaluar la generalización. La validación fue cuantitativa en IDRiD, DRISHTI-GS y REFUGE, y cualitativa en los demás, con un estudio de ablación bajo protocolo unificado. Los resultados muestran un Dice de 0.9728, IoU de 0.9473 y exactitud de 0.9989 en IDRiD; Dice de 0.9667 en DRISHTI-GS y 0.9615 en REFUGE, con una inferencia de 49–63 ms por imagen. Entre sus limitaciones, varios datasets externos no tienen anotaciones cuantitativas y el estudio no aborda la segmentación de la copa óptica. En cuanto a la crítica, entrenar únicamente en IDRiD introduce un sesgo hacia retinopatía diabética india, lo que limita su validez para poblaciones con glaucoma de distinta demografía.

Del mismo modo, Mahmood y Ucan (2025) proponen un sistema DCNN para la detección de glaucoma y segmentación del disco óptico en imágenes fundus, combinando una arquitectura DCNN para clasificación y VGG-19 encoder-decoder para segmentación simultánea. El problema es que los métodos diagnósticos actuales del glaucoma son subjetivos, consumen tiempo y presentan alta variabilidad entre observadores, mientras los métodos clásicos de segmentación fallan ante variaciones de iluminación y vasos solapados. Las imágenes provienen de REFUGE (Zeiss Visucam 500 y Canon CR-2) y ORIGA (equipos clínicos en poblaciones asiáticas), ambas con anotaciones de oftalmólogos expertos. Las variables predictoras son imágenes preprocesadas con ecualización adaptativa de histograma y filtros Frangi, ajustadas a 512×512 píxeles, y la variable objetivo es la clasificación binaria glaucomatoso/no glaucomatoso y las máscaras de segmentación; se usaron 1,200 imágenes con una división 70/15/15. La validación

usó validación cruzada de cinco pliegues con exactitud, precisión, recall, F1-score, AUC-ROC, Dice e IoU, comparando contra CNN-SVM, ViT y U-Net mediante pruebas t pareadas ($p < 0.05$). Los resultados muestran una exactitud del 98.69%, F1-score de 96.84%, AUC-ROC de 97.63%, Dice de 0.91, IoU de 0.88 y un tiempo de inferencia de 0.75 segundos por imagen. Entre sus limitaciones están una tasa de falsos positivos del 7.5% en copas ópticas grandes, dificultades con imágenes de bajo contraste y la falta de datos clínicos complementarios como la presión intraocular. En cuanto a la crítica, una exactitud cercana al 99% resulta poco convincente dado el dataset reducido de solo 1,200 imágenes de poblaciones acotadas, sin garantía de que el modelo funcione bien en escenarios clínicos más diversos.

De igual forma, Elkenawy et al. (2026) proponen un framework de deep learning para la clasificación automatizada de enfermedades retinianas, respondiendo al problema de la dependencia manual en el diagnóstico de Retinopatía Diabética, Cataratas y Glaucoma. Las imágenes usadas provienen de las bases de datos públicas IDRiD, Oculus Recognition y HRF. El dataset comprende 4,200 imágenes divididas en cuatro clases (Normal, Retinopatía Diabética, Catarata y Glaucoma), con las características visuales de las imágenes como variables predictoras y la categoría diagnóstica como variable objetivo, con una división de 80% para entrenamiento y 20% para prueba. La validación usó validación cruzada de 5 pliegues y análisis estadístico no paramétrico mediante la prueba de Wilcoxon. Se evaluaron cuatro arquitecturas CNN: Scratch Model, EfficientNet-B0, EfficientNet-B7 y AlexNet, usando exactitud, sensibilidad, especificidad, PPV, NPV, F1-score y tiempo de procesamiento. AlexNet obtuvo el mejor desempeño: exactitud 93.65%, sensibilidad 94.39%, especificidad 98.05%, PPV 93.65%, NPV 97.95% y F1-score 93.74%, con un tiempo de entrenamiento de cerca de 14 minutos; la validación cruzada arrojó un R^2 medio de 0.8891 ($DE=0.0160$). Además, se usó SHAP para interpretabilidad, identificando el disco óptico y la mácula como regiones clave. Entre sus limitaciones, el estudio no tiene validación externa y el dataset proviene de fuentes limitadas. En cuanto a la crítica, llama la atención que AlexNet, una arquitectura considerada obsoleta, supere a EfficientNet-B7; esto podría explicarse por el tamaño reducido del dataset, donde

modelos más simples tienden a generalizar mejor, lo que sugiere que los resultados podrían no reproducirse con mayor cantidad de datos.

De igual manera, Milad et al. (2025) abordan la falta de herramientas de detección accesibles para el glaucoma, proponiendo un modelo de deep learning sin código (CFDL) desarrollado mediante Google Cloud Vertex AI, orientado a que clínicos sin experiencia en programación puedan construir modelos diagnósticos. Las imágenes usadas provienen del dataset Rotterdam EyePACS AIROGS, con imágenes de 500 centros de detección en Estados Unidos con diversidad étnica documentada; la variable predictora fueron las características visuales del nervio óptico y la variable objetivo la clasificación binaria entre glaucoma referible (RG) y no referible (NRG). El dataset original comprendía 101,442 imágenes; tras corregir el desbalance de clases se usaron 9,810 imágenes (3,270 RG y 6,540 NRG) con una división automática 80/10/10. La validación se realizó internamente y en dos datasets externos: REFUGE (400 imágenes) y GAMMA (100 imágenes), a tres umbrales de confianza (0.1, 0.3 y 0.5), usando AuPRC, sensibilidad, AUC, PPV, especificidad, exactitud y F1-score. El modelo alcanzó AuPRC=0.988, SE@95SP=95% y exactitud=91% en el dataset interno; en REFUGE obtuvo AUC=0.960 y SE@95SP=83%, y en GAMMA AUC=0.994 y SE@95SP=98%, superando en algunos casos a los modelos de referencia. Entre sus limitaciones, el acceso al conjunto de prueba oficial de AIROGS fue denegado, lo que impide una comparación completa con modelos expertos, y no se controló la separación a nivel de paciente, lo que puede inflar las métricas internas. En cuanto a la crítica, si bien la propuesta es innovadora en términos de accesibilidad, el costo en la nube y las restricciones institucionales limitan su uso real en entornos de pocos recursos, contradiciendo parcialmente su premisa de democratización.

Por otro lado, Yang et al. (2025) presentan HyReti-Net, una red híbrida dual para la clasificación de enfermedades retinianas, respondiendo al problema de que las CNN convencionales extraen principalmente características locales mientras que los Vision Transformers requieren grandes volúmenes de datos y carecen de sesgo inductivo local. El modelo integra una rama CNN basada en ResNet-50 y una rama Swin Transformer, unidas mediante un Feature Fusion Module (FFM) con un bloque de concatenación residual y un bloque de atención de canal mejorada. Las

imágenes usadas provienen de tomografía de coherencia óptica (OCT) de tres datasets públicos: OCT-2017 (48,574 imágenes, 4 clases), OCT-2014 (3,231 imágenes, 3 clases) y OCT-C8 (24,000 imágenes, 8 clases); las variables predictoras son las características morfológicas de las capas retinianas y la variable objetivo es la categoría diagnóstica, con una división 7:2:1. La validación incluyó validación cruzada de 3 pliegues en los tres datasets, un estudio de ablación con ocho esquemas arquitectónicos y mapas Grad-CAM para verificar que el modelo se enfocaba en las regiones correctas. HyReti-Net alcanzó exactitudes de 99.06%, 99.44% y 98.76% en OCT-2017, OCT-2014 y OCT-C8 respectivamente, superando a HTCNet, WaveNet-SF y MSLI-Net en todos los datasets. Entre sus limitaciones, el modelo fue evaluado solo en datasets públicos sin validación clínica y no se reportan métricas computacionales como tiempo de inferencia o número de parámetros. En cuanto a la crítica, esta omisión es relevante para un modelo de uso clínico real; con ocho categorías diagnósticas, conocer el tiempo de inferencia y el consumo de memoria es necesario para evaluar su viabilidad en entornos hospitalarios.

De modo similar, Banumathy et al. (2024) proponen un framework de aprendizaje profundo multi-tarea para la detección automatizada de glaucoma, respondiendo al problema de la dependencia en ingeniería manual de características y el desbalance de clases en datasets biomédicos. Como aporte, introducen una función de pérdida mixta que combina focal loss y correntropy loss (FC-loss), junto con un módulo de aprendizaje multi-tarea (MTL) que incorpora características del nervio óptico extraídas de imágenes OCT. Las imágenes provienen de tres datasets públicos: ACRIMA, con imágenes capturadas con cámara retinal Topcon TRC y clasificadas por especialistas; ORIGA, con 650 imágenes de 3,280 individuos malayos anotadas con CDR; y REFUGE, con 1,200 imágenes para clasificación y segmentación del disco óptico. La variable predictora son las características visuales del disco y nervio óptico, y la variable objetivo es la clasificación binaria glaucoma/normal. El artículo no especifica la división exacta por dataset, pero se aplicó preprocesamiento con recorte a 224×224 píxeles y aumento de datos. La validación evaluó cuatro arquitecturas CNN: AlexNet, VGGNet, Xception e InceptionResNetv2, combinadas con el módulo MTL, usando exactitud, recall, AUC y F1-score, además del tiempo de inferencia por imagen.

InceptionResNetv2+MTL alcanzó exactitud del 100%, recall=1.00, AUC=1.00 y F1=1.00 en los tres datasets; el tiempo de inferencia varió entre pocos milisegundos para AlexNet y hasta 120 ms para ResNetv2. Entre sus limitaciones, el estudio usa solo imágenes de alta calidad y la diversidad étnica es restringida. En cuanto a la crítica, una exactitud del 100% en tres datasets genera dudas razonables sobre sobreajuste, especialmente sin validación cruzada rigurosa ni separación a nivel de paciente, lo que afecta la credibilidad de los resultados para su uso clínico real.

Tras revisar la literatura científica sobre la detección automatizada de patologías retinianas, se identificaron los estudios más relevantes que responden a la segunda pregunta de investigación. Para organizar y comparar esta información, se presenta un resumen de los artículos revisados en la Tabla 20:

Tabla 20

Resumen de Artículos

Cita Bibliográfica en APA 7	Aporte	Variables	Modelo	Métricas y Resultados
Arnob et al. (2025)	CNN ligera con IA explicable (Grad-CAM) y balanceo SMOTE.	Imágenes de fondo de ojo (10 patologías).	CNN ligera + Atención	Accuracy - 87.9 %, F1-score - 88.0 %
Williams et al. (2024)	Evaluación automatizada de respuesta endoscópica posquimioterapia.	Imágenes endoscópicas (tumor vs. sin tumor).	ResNet-50	Accuracy - 91 %, AUROC - 98 %
Skouta et al. (2026)	Arquitectura U-Net personalizada para segmentación del disco óptico con validación cruzada en 6 bases de datos.	Contornos del disco óptico en retinografías.	U-Net personalizada	Accuracy - 99.8 %, Dice - 0.972, IoU - 0.947

Mahmood y Ucan (2025)	Sistema optimizado para detección de glaucoma y segmentación de disco óptico simultánea en tiempo real.	Imágenes de fondo de ojo (glaucoma vs. sano).	DCNN (VGG-19)	Accuracy - 98.6 %, AUC - 97.6 %, Dice - 0.91
Elkenawy et al. (2026)	Clasificación automatizada de cuatro enfermedades retinianas con análisis de interpretabilidad SHAP.	Imágenes de fondo de ojo (disco óptico y mácula).	AlexNet	Accuracy - 93.6 %, Specificity - 98.0 %, F1-score - 93.7 %.
Milad et al. (2025)	Detección de glaucoma empleando aprendizaje profundo sin código (CFDL) accesible para clínicos.	Fotografías de fondo de ojo del polo posterior.	CFDL (Google Cloud Vertex AI).	Accuracy - 91 %, AuPRC - 0.988, SE@95SP - 95 %.
Yang et al. (2025)	Arquitectura híbrida de doble rama con módulo de fusión de características multiescala.	Imágenes OCT (características locales y globales).	HyReti-Net (ResNet-50 + Swin Transformer).	Accuracy - 99.4 %
D et al. (2024)	Marco de aprendizaje multitarea con	Fotografías de fondo de ojo.	VNet + InceptionRes Netv2.	Accuracy - 100 %

	función de pérdida mixta (focal y correntropía).			
--	--	--	--	--

3.3.2.4 P4: *¿Qué procesos de validación técnica y conjuntos de datos estandarizados se identifican en el entrenamiento y evaluación de modelos de Deep Learning para la detección de patologías retinianas?*

Tal como señalan Xia et al. (2024), el dataset EDDFS (Eye Disease Diagnosis and Fundus Synthesis) junto con la red TJNet, una arquitectura híbrida que combina encoders Transformer con CNN para el diagnóstico automatizado de enfermedades retinianas con anotaciones multi-etiqueta. El estudio responde a la escasez de datos públicos de alta calidad con etiquetas multi-enfermedad simultáneas, lo que dificulta el entrenamiento de modelos generalizables. Las imágenes fueron tomadas con cinco cámaras digitales de fondo de ojo en colaboración con el Primer Hospital de Nanchang, anotadas por cinco expertos en tres rondas supervisadas por un oftalmólogo senior. El dataset contiene 28,877 imágenes de siete patologías (DR, AMD, glaucoma, miopía patológica, RVO, fotocoagulación láser e hipertensión retiniana) más imágenes normales; las variables predictoras son las características visuales de cada imagen y la variable objetivo es la etiqueta de enfermedad, con una división Split1 (6:4) para clasificación multi-etiqueta y Split2 (6:1:3) para mono-etiqueta. La validación comparó TJNet contra siete arquitecturas estándar bajo las mismas condiciones, con estudios de ablación y evaluación en datasets externos (APTOS2019, DRD, ODIR). TJNet alcanzó un F1 de 0.8482, AUC de 0.9688 y Kappa de 0.7819 en clasificación mono-etiqueta, superando a todos los modelos comparados. Entre sus limitaciones, el desbalance de clases y el origen en un único hospital chino restringen la generalización. En cuanto a la crítica, la falta de validación cruzada y de validación clínica prospectiva debilita la solidez estadística, y el bajo rendimiento en hipertensión retiniana muestra que ciertas patologías necesitan módulos especializados aún no contemplados.

De la misma manera, Wang et al. (2025) proponen el dataset MultiEYE y el método OCT-CoDA, estableciendo el primer benchmark multimodal multi-clase que entrena modelos de diagnóstico retiniano con imágenes de fondo de ojo y OCT no

emparejadas por paciente, requiriendo solo fotografías de fondo de ojo durante la inferencia. El problema es que los métodos multimodales existentes exigen datos emparejados a nivel de paciente, lo que resulta poco práctico dado que las cámaras fundus son cinco veces más frecuentes que los dispositivos OCT. Las imágenes provienen de 13 datasets públicos de fondo de ojo y 4 de OCT, complementados con datos de un hospital chino, con anotaciones revisadas por dos oftalmólogos y arbitradas por especialistas con más de 15 años de experiencia. MultiEYE contiene 58,036 fotografías de fondo de ojo y 45,923 cortes B de OCT en nueve clases (normal, dAMD, CSC, DR, glaucoma, MEM, miopía, RVO y wAMD); las variables predictoras son características extraídas por encoders de imagen y la variable objetivo es la clase de enfermedad, con una división 6:2:2 por identidad de paciente. La validación comparó OCT-CoDA contra cuatro modelos base usando ocho métricas, con estudios de ablación y evaluación en el dataset emparejado MMC-AMD. OCT-CoDA con backbone FLAIR mejoró el P-R F1 en 4.28% frente al modelo base y en 3.23% frente a FDDM; en MMC-AMD alcanzó 94.86% de P-R F1. Entre sus limitaciones, el modelo no maneja enfermedades no vistas en entrenamiento y el rendimiento en clases minoritarias como CSC (43.64% F1) sigue siendo bajo. En cuanto a la crítica, la evaluación de robustez ante variaciones de dispositivo es insuficiente y la dependencia de modelos de lenguaje preentrenados introduce incertidumbre no cuantificada en el proceso de destilación.

De igual modo, Wu et al. (2025) desarrollan DRAMA (Diabetic Retinopathy Analysis Model Assistant), un sistema multitarea basado en EfficientNet-B2 que ejecuta 11 tareas diagnósticas simultáneas sobre imágenes de tres dispositivos distintos, siendo el primer modelo en cubrir el proceso clínico completo de diagnóstico de DR en entornos heterogéneos. El problema es que los modelos existentes se entrenan en un único dispositivo y abordan solo una fase diagnóstica, limitando su uso real. Las imágenes provienen de tres equipos: cámara TRC-NW8 (50° FOV), sistema UWF Optos (200°) y cámara portátil Mocular Medical (60°), anotadas por dos oftalmólogos con arbitraje de un especialista ante discrepancias. El dataset comprende 1,500 imágenes de 957 pacientes divididas en tres subdatasets (CFP, UWF, PC); las variables predictoras son características extraídas por EfficientNet-B2 preentrenado en ImageNet, y las variables objetivo son 11 etiquetas diagnósticas (tipo, calidad, lateralidad, lesiones, gradación DR y CI-

DME), con una división 8:1:1. La validación comparó tres CNN bajo las mismas métricas, con validación externa en cuatro centros independientes, visualización Grad-CAM y comparación humano-máquina sobre 126 imágenes. Los resultados muestran 91.60% en detección de lesiones, 80.15% en gradación DR (AUC 0.93) y 90.91% frente al 83.64% del especialista, procesando el conjunto completo en 86 ms. Entre sus limitaciones, el dataset reducido eleva los falsos negativos y la gradación cae a 68.16% en validación externa. En cuanto a la crítica, la falta de validación cruzada debilita la solidez estadística y excluir variables clínicas como glucemia y HbA1c impide reflejar la complejidad diagnóstica real.

Por otro lado, Sushith et al. (2025) proponen TAHDL (Temporal Aware Hybrid Deep Learning), un framework híbrido que integra CNN multi-escala, LSTM y mecanismos de atención para capturar características espaciales y dependencias temporales entre escaneos retinianos sucesivos, orientado a la detección temprana y monitoreo de la progresión de DR. El problema es que las CNN convencionales procesan imágenes de forma estática ignorando la naturaleza progresiva de la enfermedad, lo que limita la distinción entre estadios. Las imágenes provienen de tres datasets públicos de Kaggle: DRIVE, con datos anotados para segmentación de vasculatura; Kaggle DR, con etiquetas de severidad asignadas por oftalmólogos; y EyePACS, con etiquetas verificadas por especialistas en retina; el artículo no describe las condiciones originales de captura, lo que representa una limitación metodológica no reconocida. DRIVE contiene 40 imágenes ampliadas a 200 mediante aumento de datos (80/20); Kaggle DR tiene 35,126 imágenes en cinco clases (80/20); y EyePACS 104,000 imágenes en cinco clases (80/20); las variables predictoras son características espacio-temporales y las objetivo los grados de DR. La validación comparó TAHDL contra ocho modelos bajo los mismos hiperparámetros, usando precisión, recall, F1, especificidad y exactitud. Los resultados muestran 97.50% en DRIVE, 94.04% en Kaggle DR y 96.9% en EyePACS, superando al ViT en cerca de 2%. Entre sus limitaciones, el modelo requiere GPU de alta gama, carece de interpretabilidad clínica y no fue validado en entornos reales. En cuanto a la crítica, ampliar 40 imágenes a 200 para reportar 97.50% genera dudas de sobreajuste, y los F1 superiores a 0.99 sugieren posibles fugas de información entre particiones sin validación cruzada.

Igualmente, Liu et al. (2024) presentan el Sistema Inteligente de Diagnóstico Retiniano Infantil (IRIDS), una herramienta de Deep Learning para detectar automáticamente nueve enfermedades del fondo de ojo en lactantes, respondiendo a la escasez de oftalmólogos especializados en zonas con pocos recursos. El problema central es que condiciones como ROP, retinoblastoma, retinitis pigmentosa y coloboma de coroides son difíciles de diagnosticar a tiempo, con riesgo de complicaciones irreversibles. Las imágenes fueron tomadas con cámaras pediátricas de fondo de ojo, incluyendo sistemas de campo amplio como RetCam, en cuatro hospitales de China entre 2004 y 2021, con control de calidad por dos oftalmólogos y resolución de discrepancias por un especialista senior. El dataset comprende 7,697 imágenes de 1,089 lactantes; las variables predictoras son características morfológicas retinianas y la variable objetivo es la categoría diagnóstica entre nueve clases, con una división de 80% entrenamiento y 20% prueba. La validación usó validación cruzada de cinco pliegues con bootstrapping para intervalos de confianza al 95%, más comparación directa con cuatro oftalmólogos sobre 450 imágenes adicionales. IRIDS (ResNet-18 + MaxViT + módulo de atención) alcanzó una exactitud de 96.45%, AUC de 99.51% y F1 de 95.03%, superando a todos los modelos base y a los oftalmólogos evaluados. Entre sus limitaciones, el dataset proviene solo de individuos chinos, no cubre todas las enfermedades infantiles posibles y no está disponible públicamente. En cuanto a la crítica, la exclusividad étnica limita la generalización a otras poblaciones, y la falta de datos públicos dificulta la reproducibilidad independiente, aspecto clave antes de considerar cualquier implementación clínica real.

También, Choi et al. (2024) abordan la detección insuficiente de la membrana epirretiniana (ERM) mediante fotografía de fondo de ojo a color (CFP), condición cuya transparencia la hace difícil de identificar visualmente y que ha sido poco estudiada con inteligencia artificial. El aporte es un modelo generativo basado en StyleGAN2 que sintetiza imágenes CFP con características patológicas de ERM para aumentar los datos de entrenamiento, combinado con un clasificador EfficientNetB0. Las imágenes fueron tomadas en el centro oftalmológico B&VIIT Eye Center de Seúl entre enero de 2015 y diciembre de 2022; para validación externa se usaron los datasets públicos RFMiD y JSIEC. El dataset comprende 1,552 imágenes (1,250 sanas y 302 con ERM); las variables predictoras son

características visuales de la mácula y la variable objetivo es la presencia o ausencia de ERM, con una división de 80% entrenamiento y 20% validación interna, más RFMiD (695 imágenes) y JSIEC (64 imágenes) como sets externos. La validación incluyó evaluación interna, dos validaciones externas independientes, comparación estadística entre modelos ($p < 0.05$) y mapas Grad-CAM para verificar la focalización en la región macular. El modelo alcanzó AUC de 0.926 en validación interna, 0.951 en RFMiD y 0.914 en JSIEC, con sensibilidad de 92.0% y especificidad de 80.8%. Entre sus limitaciones están la baja resolución de las imágenes generadas (256×256 píxeles), el origen unicéntrico asiático y el tamaño reducido de casos ERM en los sets externos. En cuanto a la crítica, las validaciones externas cuentan con apenas 26 casos de ERM cada una, lo que es insuficiente para conclusiones clínicas sólidas; se necesitan estudios multicéntricos con mayor representación antes de considerar su uso clínico real.

Además, Verma et al. (2025) proponen ResEfficientNetB3, un modelo ensemble que integra EfficientNetB3 y ResNet50 con ajuste fino para la clasificación automatizada de enfermedades retinianas, buscando superar las limitaciones de generalización de modelos individuales. El problema es que los métodos tradicionales dependen de especialistas y son propensos a variabilidad entre observadores, mientras que modelos de IA previos tienen dificultades para generalizarse a múltiples datasets y entornos clínicos. Las imágenes provienen de cámaras de fondo de ojo a color de múltiples centros, consolidadas en dos datasets de Kaggle: el Dataset 1 con 4,217 imágenes en cuatro clases (catarata, retinopatía diabética, glaucoma y normal) y el Dataset 2 con 8,230 imágenes en ocho clases; las variables predictoras son características visuales del fondo de ojo y la variable objetivo es la clase diagnóstica, con una división de 80/10/10% con muestreo estratificado. La validación fue multidimensional: evaluación en conjunto de prueba independiente, validación cruzada de cinco pliegues y validación cruzada entre datasets logrando 94.5% y 95.8% de exactitud. ResEfficientNetB3 alcanzó 99.0% de exactitud en Dataset 1 y 98.2% en Dataset 2, superando a EfficientNetB3 (94.0%) y ResNet50 (91.0%) individualmente, con precisión, recall y F1 de 0.99 en todas las clases. Entre sus limitaciones están el uso exclusivo de imágenes de fondo sin otras modalidades, la procedencia de datasets Kaggle que pueden no reflejar la heterogeneidad clínica real y la falta de evaluación computacional. En

cuanto a la crítica, los resultados cercanos al 99% en datasets balanceados generan dudas sobre sobreajuste; en entornos reales con imágenes de menor calidad y clases desbalanceadas, este rendimiento podría reducirse de forma considerable.

Al mismo modo, Mukherjee et al. (2025) abordan la dependencia de dispositivo en algoritmos de segmentación de capas retinianas, es decir, la incapacidad de generalizar a equipos OCT distintos del usado en el entrenamiento, lo que limita su uso en estudios sobre degeneración macular asociada a la edad (DMRE). El aporte consiste en validar dos redes de segmentación, U-Net y DeepLabV3, entrenadas con imágenes de un dispositivo y evaluadas en otro sin reentrenamiento. Las imágenes provienen de dos equipos SD-OCT: Heidelberg Spectralis HRA+OCT para entrenamiento y Zeiss Cirrus SD-OCT para prueba, complementados con fotografías de fondo de ojo con cámara Topcon TRC-50DX para gradación de severidad AMD. El dataset proviene de un estudio longitudinal del NIH con participantes mayores de 50 años; se usaron 402 escaneos SD-OCT (201 Spectralis para entrenamiento y 201 Spectralis + 201 Cirrus para prueba); las variables predictoras son las características de los B-scans OCT y las variables objetivo son los límites de las capas ILM, EPR y membrana de Bruch. La validación incluyó MAE y MSE en píxeles, coeficientes Dice, mapas de espesor, estimaciones volumétricas, gráficos de Bland-Altman, comparación con dos anotadores independientes y contraste con adaptación de dominio mediante CycleGAN. El MAE para ILM fue 1.82 ± 0.24 píxeles y para EPR 2.46 ± 0.66 píxeles, con Dice de 0.87 ± 0.01 , comparable a la variabilidad entre anotadores; la adaptación con CycleGAN no mejoró los resultados. Entre sus limitaciones están el tamaño reducido de anotaciones en Cirrus y mayor dificultad en casos avanzados de DMRE. En cuanto a la crítica, el experimento es asimétrico ya que Spectralis ofrece mayor calidad; entrenar en Cirrus y probar en Spectralis habría fortalecido las conclusiones sobre la generalización bidireccional del modelo.

Tras revisar la literatura científica sobre la detección automatizada de patologías retinianas, se identificaron los estudios más relevantes que responden a la segunda pregunta de investigación. Para organizar y comparar esta información, se presenta un resumen de los artículos revisados en la Tabla 21:

Tabla 21

Resumen de Artículos

Cita Bibliográfica en APA 7	Aporte	Variables	Modelo	Métricas y Resultados
Xia et al. (2024)	Creación del dataset a gran escala EDDFS y red con co-atención y fusión cruzada para diagnóstico.	Imágenes de fondo de ojo (sanos y 7 trastornos oculares).	Transformer-jointed CNN (TJNet).	AUC - 96.8 %, F1-score - 84.8 %
Wang et al. (2025)	Destilación de conocimiento asistida por OCT (OCT-CoDA) usando datos multimodales no emparejados.	Fotografías de fondo de ojo y conceptos de síntomas generados por LLM.	OCT-CoDA (Modelo VLM base FLAIR/CLIP).	Accuracy - 79.3 %, P-R F1 - 62.0 %
Wu et al. (2025)	Sistema DRAMA de aprendizaje multitarea (multitask learning) sobre datasets heterogéneos.	Imágenes de fondo de ojo multifuente (CFP, UWF, PC).	EfficientNet-B2	Accuracy (lesiones) - 91.6 %, AUC > 95 %
Sushith et al. (2025)	Arquitectura híbrida con mecanismo de atención para extraer dependencias espacio-temporales.	Características espaciales y temporales en retinografías.	CNN + LSTM + Atención (TAHDL)	Accuracy - 97.5 %, F1-score - 97.7 %

Liu et al. (2024)	Sistema IRIDS (CNN + Transformers) para diagnóstico automatizado de nueve patologías de fondo de ojo infantiles.	Imágenes de fondo de ojos infantiles (sanos y 8 enfermedades/con condiciones).	IRIDS (ResNet-18 + MaxViT)	Accuracy - 96.4 %, AUC - 99.5 %
Choi et al. (2024)	Modelo generativo para mejorar la detección de membrana epirretiniana (ERM) mediante aumento de datos.	Fotografías a color de fondo de ojo (ERM vs. retina sana).	EfficientNetB0 + StyleGAN2	AUC (interno) - 92.6 %, AUC (externo) - 95.1 %
Verma et al. (2025)	Framework de ensamble profundo para la clasificación automatizada multiclase de enfermedades retinianas.	Imágenes de fondo de ojo (Catarata, retinopatía diabética, glaucoma, normal).	ResEfficientNetB3 (EfficientNetB3 + ResNet50).	Accuracy - 99.0 % (Dataset 1) y 98.2 % (Dataset 2).
Mukherjee et al. (2025)	Validación de algoritmos de segmentación automática de capas retinianas a través de múltiples dispositivos SD-OCT.	B-scans de OCT (segmentación de capas ILM, RPE y BM).	U-Net y DeepLabV3.	MAE (ILM) - 1.82 píxeles, MAE (RPE) - 2.46 píxeles, Dice - 0.87.

3.3.2.5 P5: ¿Qué infraestructuras tecnológicas se emplean para la integración de modelos predictivos visuales como Sistemas de Soporte al Diagnóstico (CAD) en entornos clínicos?

Según Chowa et al. (2025), proponen OCCT (Optimized Compact Convolutional Transformer), un modelo ligero derivado de una arquitectura CCT ajustada mediante un estudio de ablación de siete variables, orientado a la clasificación automatizada de enfermedades retinianas en imágenes OCT. El problema es la necesidad de diagnósticos eficientes en entornos con recursos computacionales limitados, donde los modelos transformadores convencionales son costosos y los datasets suelen estar desbalanceados. Las imágenes provienen del dataset público UCSD de Zhang Lab, con 108,312 imágenes OCT de cuatro clases (CNV, DME, Drusen y Normal) como variables predictoras y el diagnóstico retiniano como variable objetivo; mediante DCGAN se amplió el dataset a 130,649 imágenes, con una división de 70% entrenamiento y 30% prueba. La validación incluyó matrices de confusión y validación cruzada K-fold (k=10), comparando OCCT frente a ViT, Swin Transformer y ocho modelos de transfer learning. El modelo alcanzó una exactitud del 97.09%, F1-score del 96.87% y sensibilidad del 97.48%, con solo 0.24M parámetros y 32 minutos de entrenamiento. Entre sus limitaciones, el estudio no evalúa el rendimiento en entornos hospitalarios reales ni con patologías fuera del dataset. En cuanto a la crítica, si bien la eficiencia computacional es notable, la arquitectura propuesta no contempla integración con sistemas de historia clínica electrónica ni protocolos de interoperabilidad, lo que representa una brecha importante para su adopción como sistema CAD en contextos clínicos reales como Lima Metropolitana.

Del mismo modo, Chotcomwongse et al. (2025) proponen una plataforma digital basada en la nube implementada en un hospital comunitario de Tailandia, diseñada para digitalizar el flujo de trabajo de tamizaje de retinopatía diabética (DR) e integrarlo con un modelo de IA para la detección automatizada de casos referibles. El problema es la existencia de programas de tamizaje no digitales y desconectados de los sistemas hospitalarios, lo que impide medir indicadores como la adherencia a la referencia. Las imágenes fueron tomadas con una cámara Topcon TRC-NW400 y centralizadas en la plataforma web propia. El dataset incluyó 708 pacientes en la

modalidad IA y 746 en la modalidad manual; las fotografías retinianas fueron las variables predictoras y el diagnóstico de DR referible la variable objetivo. El modelo usado fue ARDA (basado en Inception-v4), preentrenado con más de 1,600,000 fotografías de cuatro países, sin partición propia dado el diseño prospectivo del estudio. La validación se realizó mediante revisión remota por un especialista en retina, con una concordancia IA-especialista del 88%. Los resultados mostraron que la IA detectó más casos referibles (31.2% vs 24.0%, $p=0.003$) y más verdaderos positivos (64.2% vs 9.5%, $p<0.001$), con una adherencia a referencia del 89.1%. Entre sus limitaciones, el estudio no fue un ensayo controlado aleatorizado y carece de adjudicación externa como estándar de oro. En cuanto a la crítica, el artículo ilustra de forma concreta cómo una infraestructura en la nube puede transformar flujos clínicos no digitales, aunque no aborda con suficiente profundidad los desafíos de integración con historias clínicas electrónicas en contextos de recursos limitados como Lima Metropolitana.

Por otro lado, Quon et al. (2025) presentan un análisis sistemático de las brechas de cobertura del modelo de datos común OMOP CDM para datos de exámenes oftalmológicos en dos implementaciones del sistema Cerner Millennium: la versión predeterminada y una implementación local de la Universidad del Sur de California. El problema es que las implementaciones dispares de historias clínicas electrónicas en oftalmología generan datos heterogéneos con poca interoperabilidad, lo que dificulta la integración de sistemas CAD en entornos multicéntricos. Los datos se extrajeron de los módulos de examen ocular de Cerner y se mapearon al vocabulario OMOP mediante las herramientas Athena y USAGI. El dataset comprende 409 elementos del módulo predeterminado y 947 del módulo local, clasificados en ocho categorías; los elementos de Cerner fueron las variables de entrada y el tipo de mapeo resultante la variable de resultado; al ser un estudio de mapeo exhaustivo, no aplica partición de entrenamiento/prueba. La validación fue iterativa, realizada por un estudiante de medicina, un residente y un oftalmólogo certificado, con análisis descriptivo y cualitativo. Los resultados muestran que apenas el 25% y el 18% de los elementos tienen representación exacta en OMOP, siendo agudeza visual (95% sin mapeo exacto) y examen motor sensorial (95%) las categorías más deficitarias. Entre sus limitaciones, el estudio se restringe a Cerner y al contexto norteamericano. En cuanto a la crítica, el trabajo evidencia una barrera

técnica concreta para el despliegue de sistemas CAD, pero su aplicabilidad directa a Perú es limitada dado que los sistemas locales raramente están alineados a estándares como OMOP o SNOMED.

Asimismo, Akter et al. (2025) proponen GCN-FE, un modelo que integra redes de deep learning preentrenadas para la extracción de características con redes convolucionales de grafos (GCN), incorporando módulos de evaluación de calidad de imagen y estimación de incertidumbre mediante Monte Carlo Dropout, orientado a la clasificación multiclase de retinopatía diabética. El problema es la dependencia de métodos convencionales en preprocesamiento extensivo que degrada la autenticidad de las imágenes y limita la generalización en entornos reales. Las imágenes provienen de tres datasets públicos: APTOS2019 (3,662 imágenes), Messidor-2 (1,748) y EyePACS (35,126); los vectores de características extraídos fueron las variables predictoras y los cinco niveles de severidad de DR la variable objetivo, con una división de 70% entrenamiento, 15% validación y 15% prueba. La validación incluyó análisis de ablación, comparación con métodos del estado del arte y validación externa en EyePACS con fine-tuning, usando exactitud, F1-score, AUROC, AUPR y Kappa de Cohen. Con MobileViT, el modelo alcanzó 98.45% de exactitud y 98.06% de Kappa en APTOS2019; con DenseNet-169, 94.90% en Messidor-2 y 97.38% en EyePACS. Entre sus limitaciones, el entrenamiento se realizó sobre datasets con aumento artificial y no se exploran enfoques de ensamble ni modelos de lenguaje visual. En cuanto a la crítica, la estimación de incertidumbre es valiosa para sistemas CAD, pero el modelo requiere una GPU de alta gama y no plantea una estrategia de despliegue para entornos con infraestructura limitada, lo que reduce su transferibilidad a consultorios de Lima Metropolitana.

De manera similar, Yan et al. (2025) presentan PREDICT, un programa institucional de despliegue clínico de modelos de machine learning basado en una arquitectura MLOps end-to-end sobre Microsoft Azure, que integra infraestructura de datos, orquestación de pipelines, monitoreo continuo y rutas de atención estructuradas. El problema es que la adopción de ML en entornos clínicos ha sido lenta por barreras en la identificación de casos de uso, gestión de datos EHR y la integración en flujos clínicos reales. Los datos provienen del repositorio SEDAR

del Hospital for Sick Children de Toronto, estructurado en 18 tablas relacionales con actualización diaria mediante batch, flujos HL7 y APIs FHIR. Las variables predictoras son características clínicas del EHR como medicamentos, diagnósticos, laboratorios y signos vitales, y la variable objetivo varía según el caso de uso; al tratarse de un reporte institucional multiproyecto, cada proyecto define su propio dataset de forma independiente, por lo que la cantidad de datos y partición entrenamiento/prueba no aplican como valor único. La validación incluyó pruebas en producción, monitoreo de deriva mediante Jensen-Shannon divergence y análisis de equidad por subpoblaciones; los resultados reportan PPV entre 0.306 y 0.542 y sensibilidad entre 0.19 y 0.79 según el umbral usado. Entre sus limitaciones, SEDAR está ajustado a una sola institución con poca escalabilidad multiinstitucional, no aborda implicaciones éticas del ML clínico y no publica resultados clínicos de implementación. En cuanto a la crítica, su dependencia del ecosistema Azure y de una infraestructura centralizada de alto costo lo hace difícil de replicar en contextos de salud pública con recursos limitados, donde la plataforma de esta investigación necesitará soluciones más ligeras y adaptables.

De igual forma, Wang et al. (2024) presentan ChatCAD, un framework que integra modelos de lenguaje de gran escala (LLMs) con redes de diagnóstico asistido por computadora (CAD) para el análisis interactivo de imágenes médicas, combinando clasificación, segmentación de lesiones y generación de reportes radiológicos en lenguaje natural. El problema es que los LLMs no pueden interpretar imágenes médicas directamente, mientras que los sistemas CAD tradicionales generan salidas técnicas difíciles de entender para los pacientes. Los instrumentos de recolección fueron MIMIC-CXR, con radiografías de tórax y reportes en texto libre, y CheXpert para entrenamiento del clasificador; las variables predictoras son imágenes de rayos X y las variables objetivo son etiquetas de clasificación para cinco patologías; MIMIC-CXR fue usado para entrenamiento de R2GenCMN y su conjunto oficial de prueba aportó 300 casos seleccionados aleatoriamente, mientras que CheXpert aportó 224,316 radiografías de 65,240 pacientes para entrenamiento del clasificador PCAM. La validación comparó ChatCAD contra R2GenCMN, CvT2DistilGPT2 y PCAM usando precisión, recall y F1-score, complementada con evaluación cualitativa por expertos clínicos mediante escala Likert de 5 puntos sobre concisión y pertinencia. Los resultados muestran una mejora de 16.42 puntos porcentuales en

F1-score frente al estado del arte con ChatGPT, pertinencia clínica de 3.84 ± 0.65 frente a 3.58 ± 0.64 de reportes humanos, y GPT-4 obtuvo el mejor F1 promedio de 0.613. Entre sus limitaciones están la falta de fluidez en los reportes generados y la ausencia de la queja principal del paciente por falta de datos. En cuanto a la crítica, la dependencia de APIs externas como ChatGPT plantea serias preocupaciones de privacidad clínica que el estudio reconoce pero no resuelve, y la falta de validación formal con profesionales debilita su aplicabilidad en entornos hospitalarios reales.

Además, Pinto et al. (2025) presentan NaIA-RD, un dispositivo médico de IA desarrollado a medida e integrado en el Sistema de Información Hospitalaria del Hospital Universitario de Navarra, España, para apoyar el tamizaje de retinopatía diabética (RD). El problema surge porque ningún dispositivo con marca CE cumplía los requisitos del programa de tamizaje ya establecido. Los instrumentos de recolección fueron registros electrónicos de salud anonimizados e imágenes de fondo de ojo no midriáticas almacenadas en un servidor PACS, más un Gold Standard etiquetado por tres oftalmólogos. El dataset integra fuentes privadas y públicas: dataset privado de RD (17,336 entrenamiento / 8,592 validación), EyePACS (77,787 entrenamiento / 10,906 prueba), APTOS (1,831), Messidor-2 (872), IDRiD (413) y OIA-DDR (3,759 para prueba externa); el Gold Standard privado comprende 489 ojos con prevalencia del 18% de casos referibles. Las variables predictoras son imágenes de fondo de ojo en campo central y nasal, y la variable objetivo es la categoría referible-RD, no referible o no gradable. La validación se realizó mediante un estudio prospectivo antes y después con 19,828 pacientes pre-implementación y 22,962 post-implementación, comparando NaIA-RD contra el consenso de oftalmólogos y médicos generales. Los resultados muestran sensibilidad del 92.5%, especificidad del 92.4% ($\kappa=0.818$), AUC de 0.957 en OIA-DDR y una reducción potencial de carga de visualización de 4.27 veces en modo autónomo. Entre sus limitaciones están la ausencia de grupo control aleatorizado, la evaluación solo a nivel de ojo y no de imagen individual, y la falta de análisis de sesgos por subgrupos. En cuanto a la crítica, la ausencia de un ensayo controlado aleatorizado impide atribuir causalmente las mejoras al sistema, y su desarrollo institucional limita su replicabilidad en hospitales con menos recursos.

Por último, Duggal et al. (2025) presentan la evaluación e implementación en entornos reales de algoritmos de IA basados en la nube para el tamizaje de retinopatía diabética en centros de salud pública de India. El problema es la escasez de especialistas y la baja escalabilidad del tamizaje manual en contextos de bajos recursos. Las imágenes fueron tomadas por optometristas capacitados con una cámara no midriática portátil de bajo costo (3Netra Classic) en dos campos, registrando los datos en REDCap. El dataset incluyó 1,099 imágenes de 250 pacientes en la fase de validación y 1,372 imágenes de 343 pacientes en la fase de implementación; las variables predictoras fueron gradabilidad de imagen, presencia y grado de DR, edema macular diabético y DR referible, y la variable objetivo fue la clasificación binaria de DR. Al tratarse de algoritmos comerciales pre-entrenados, el estudio no reporta partición propia de entrenamiento/prueba, sino que usa la totalidad de las imágenes como conjunto de validación externa. La validación fue prospectiva en dos fases: tres algoritmos comerciales fueron comparados contra graduación humana doble enmascarada con resolución por experto senior ($\kappa=0.85$), y el mejor (AI-3) fue integrado a la cámara y monitoreado mensualmente. En la fase de implementación, AI-3 alcanzó una sensibilidad del 99.6% y VPN del 98.3% para DR, con especificidad del 64.7%; para DR referible, sensibilidad del 78.9% y especificidad del 98.1%. Entre sus limitaciones están el uso de una sola cámara y un único algoritmo, baja adherencia a derivaciones (14%) y monitoreo post-estudio de solo tres meses. En cuanto a la crítica, la arquitectura depende completamente de conectividad a internet y servidores externos, lo que la hace vulnerable en zonas rurales; además, la caída de especificidad entre fases muestra la necesidad de ciclos de reentrenamiento local antes de cualquier despliegue definitivo.

Tras revisar la literatura científica sobre la detección automatizada de patologías retinianas, se identificaron los estudios más relevantes que responden a la segunda pregunta de investigación. Para organizar y comparar esta información, se presenta un resumen de los artículos revisados en la Tabla 22:

Tabla 22

Resumen de Artículos

Cita Bibliográfica en APA 7	Aporte	Variables	Modelo	Métricas y Resultados
Chowa et al. (2025)	Desarrollo de un modelo ligero (OCCT) optimizado con aumento de datos mediante DCGAN para resolver el desbalance de clases.	Imágenes de tomografía de coherencia óptica (OCT) para 4 clases (CNV, DME, Drusen, Normal).	OCCT (Optimized Compact Convolutional Transformer)	Accuracy - 97.09 %, F1-score - 96.87 %, Specificity - 99.02 %
Chotcomwongse et al. (2025)	Plataforma digital en la nube que integra IA para detección y rastreo clínico de retinopatía diabética.	Fotografías de retina (severidad y edema macular).	ARDA (Inception-v4).	Verdaderos positivos - 64.2% , Adherencia clínica - 89.1% , Falsos negativos - 1.1%.
Quon et al. (2025)	Evaluación de brechas mapeando datos oftalmológicos de registros médicos electrónicos al modelo común OMOP.	Elementos estructurados del examen oftalmológico (agudeza visual, refracción, sensorimotor).	OMOP CDM (SNOMED, LOINC) / USAGI.	Mapeos exactos - 25 % (Cerner por defecto) y 18 % (módulo Cerner local).
Akter et al. (2025)	Arquitectura mejorada por grafos con evaluación de calidad y estimación de incertidumbre.	Imágenes de fondo de ojo para clasificar 5 niveles de severidad de retinopatía diabética.	MobileViT + GCN / DenseNet-169 + GCN.	Accuracy (MobileViT) - 98.45 %, Accuracy (DenseNet-169) - 94.90 %.

Yan et al. (2025)	Hoja de ruta (programa PREDICT) y arquitectura MLOps para implementar modelos de ML clínico.	Datos estructurados de historias clínicas electrónicas (diagnósticos, medicación, laboratorio).	Framework MLOps (Azure ML).	Evaluación operativa mediante umbrales (ej. Sensibilidad - 0.75, PPV - 0.312).
Wang et al. (2024)	Framework ChatCAD que integra redes CAD con modelos de lenguaje grandes (LLMs) para generar reportes interactivos.	Radiografías de tórax y salidas de modelos CAD traducidas a texto.	ChatCAD (Redes CAD + ChatGPT / GPT-4).	F1-score (GPT-4) - 0.613, F1-score (ChatGPT) - 0.605.
Pinto et al. (2025)	Desarrollo clínico del sistema personalizado NaIA-RD que integra clasificación de retinopatía y calidad de imagen.	Imágenes de fondo de ojo (campo, severidad de DR y gradabilidad).	NaIA-RD (Ensamble de 3 CNNs ResNet34).	AUC - 97.9 %, Sensibilidad - 92.5 %, Especificidad - 92.4 %.
Duggal et al. (2025)	Evaluación e implementación en el mundo real de algoritmos de IA comerciales para el tamizaje de retinopatía diabética en centros de salud pública usando cámaras de fondo de	Imágenes de fondo de ojo no midriáticas, calidad de imagen, grado de retinopatía diabética, edema macular diabético, retinopatía referible.	Algoritmos comerciales de IA basados en la nube (se implementó el modelo AI-3).	Sensitivity - 99.6 %, Specificity - 64.7 %, PPV - 87.4 %, NPV - 98.3 %.

	ojo portátiles de bajo costo.			
--	-------------------------------	--	--	--

3.3.3 Discusión

3.3.3.1 P1: *¿Qué arquitecturas de Redes Neuronales Convolucionales y técnicas de Deep Learning han sido implementadas para la detección automatizada de patologías retinianas?*

Los estudios revisados para esta pregunta comparten un denominador común: el uso de Transfer Learning sobre arquitecturas CNN preentrenadas para alcanzar métricas de desempeño elevadas en la clasificación de patologías retinianas. Deepak y Bhat (2024), Arias-Serrano et al. (2024) y Kumar et al. (2026) coinciden en aplicar fine-tuning sobre modelos base, DarkNet-53, AlexNet y MobileNet+EfficientNet respectivamente, mientras que Shamrat et al. (2024) proponen una arquitectura propia y ligera (DRNet13), obteniendo exactitudes que van del 93.2% al 99.4%, lo que muestra que el reentrenamiento sobre arquitecturas preentrenadas es la estrategia dominante en este campo. Esta similitud refleja un consenso metodológico consolidado en la literatura reciente.

Sin embargo, hay diferencias notables en el enfoque arquitectónico adoptado. Un primer grupo, Deepak y Bhat (2024), Shamrat et al. (2024) y Arias-Serrano et al. (2024), trabaja con arquitecturas simples de una sola red orientadas a la extracción directa de características, priorizando la eficiencia computacional y la rapidez de entrenamiento; AlexNet, por ejemplo, entrenó en solo 15 minutos. Un segundo grupo, Mamyrbayev et al. (2025), Islam et al. (2025), Henge et al. (2025) y Kumar et al. (2026), apuesta por arquitecturas híbridas que fusionan CNN con LSTM, Inception-ResNet o módulos de incertidumbre mediante MC-Dropout, buscando capturar relaciones geométricas o temporales que las CNN estándar no logran modelar con suficiente profundidad. Esta diferencia revela una tensión entre la viabilidad computacional y la sofisticación diagnóstica.

Una diferencia relevante se observa en el tipo de imagen usado: la mayoría trabaja con retinografías a color del fondo de ojo (Deepak y Bhat, 2024; Mamyrbayev et al., 2025; Shamrat et al., 2024; Arias-Serrano et al., 2024; Kumar et al., 2026), lo

que respalda la viabilidad de una plataforma web orientada a retinógrafos convencionales en Lima Metropolitana. En contraste, Elkholy y Marzouk (2024) e Islam et al. (2025) usan imágenes OCT o fusión retinografía-OCT, lo que mejora la exactitud diagnóstica pero reduce la escalabilidad operativa, dado el alto costo y la baja disponibilidad de los tomógrafos OCT en la atención primaria peruana.

Un vacío compartido por la mayoría de los estudios es la falta de validación en entornos clínicos reales con datos demográficamente representativos. Deepak y Bhat (2024), Henge et al. (2025) y Elkholy y Marzouk (2024) obtienen resultados sobresalientes en datasets públicos, pero no reportan pruebas prospectivas en consultorios ni ajustan sus modelos a características poblacionales específicas. Además, varios artículos, como Shamrat et al. (2024) y Mamyrbayev et al. (2025), usan técnicas de aumento de datos que no reflejan la distribución real de pacientes, lo que limita la confianza en la generalización de sus resultados. Este vacío es precisamente el que justifica la propuesta de esta investigación: desarrollar un sistema CAD ajustado con datos de la población peruana.

En cuanto a las aplicaciones prácticas, Kumar et al. (2026) incorporan un mecanismo de derivación basado en incertidumbre (MC-Dropout) que resulta especialmente útil para el triaje clínico automatizado, ya que permite identificar los casos de mayor riesgo diagnóstico. Arias-Serrano et al. (2024) ofrecen la alternativa de menor costo computacional mediante AlexNet reentrenada, aunque su dependencia de MATLAB limita la portabilidad; trasladar este enfoque a frameworks como TensorFlow o Keras, compatibles con infraestructuras cloud, representa una oportunidad concreta para esta investigación.

3.3.3.2 P2: *¿Cuáles son las variables predictivas (características visuales) extraídas de imágenes de fondo de ojo que utilizan los modelos de Deep Learning para la clasificación de patologías retinianas?*

Los estudios revisados para esta pregunta coinciden en identificar un conjunto de biomarcadores retinianos como variables predictoras esenciales: la mácula, el disco óptico, la copa óptica, los vasos sanguíneos y la fovea aparecen de forma recurrente en los modelos de Iqbal et al. (2025), Ejaz et al. (2024), Thomas y Jerome (2024) y Skevas et al. (2024). Del mismo modo, las lesiones patológicas, como

microaneurismas, exudados, hemorragias, edema macular y neovascularización, son señaladas como biomarcadores dinámicos de progresión en Alanazi y Alanazi (2025), Ejaz et al. (2024) y Skevas et al. (2024). Esta coincidencia sugiere que existe un consenso en la literatura sobre cuáles son las regiones anatómicas y las lesiones más relevantes para el diagnóstico automatizado de patologías retinianas.

Una diferencia notable se da en la profundidad de la extracción de características. Iqbal et al. (2025) y Ejaz et al. (2025) extraen características de bajo y alto nivel mediante arquitecturas paralelas con fusión CCA, logrando mayor riqueza representacional aunque a costa de mayor complejidad computacional. En contraste, Thomas y Jerome (2024) usan descriptores de textura clásicos (GLCM) sobre vasos segmentados, combinándolos con una triple CNN y SVM; si bien este enfoque alcanza un F1-score del 99.38%, la brecha entre la exactitud de entrenamiento y la de validación (78.41%) representa una limitación metodológica de Thomas y Jerome (2024), ya que evidencia un problema de sobreajuste que los propios autores no abordan con suficiente profundidad. Chen et al. (2025), por su parte, adoptan una estrategia distinta: usan el modelo fundacional RETFound como extractor de características sin reentrenamiento, estimando métricas clínicas como el CDR y el grosor de RNFL con un $R^2=0.961$, lo que representa una aproximación orientada a la cuantificación de indicadores clínicos más allá de la clasificación binaria.

Un vacío común en este bloque de estudios es la poca atención a la calidad de la imagen de entrada como variable del proceso. Solo Alanazi y Alanazi (2025) incorporan un filtro de reducción de ruido (Weinmed) como parte del preprocesamiento. Ejaz et al. (2025) reconocen no haber incluido mejora de contraste, lo que constituye una restricción del modelo, ya que puede afectar el rendimiento en imágenes clínicas con baja iluminación o ruido, frecuentes en equipos de retinografía de bajo costo disponibles en centros de atención primaria de Lima Metropolitana. Este vacío es importante para esta investigación, que deberá incorporar un módulo robusto de preprocesamiento.

En términos de aplicabilidad práctica, el trabajo de Iqbal et al. (2025) es especialmente relevante porque muestra que un sistema automatizado puede no solo emitir un diagnóstico, sino también justificarlo visualmente ante el médico

mediante mapas Grad-CAM, lo que aumenta la confianza clínica. Nguyen et al. (2024) aportan evidencia sobre el uso de imágenes de campo ultra-amplio (UFI), que permiten detectar lesiones periféricas invisibles en retinografías convencionales, aunque su clasificación binaria no refleja la coexistencia de múltiples patologías en un mismo paciente. Skevas et al. (2024) destacan por haber validado el sistema en un entorno hospitalario real con personal de enfermería, lo que acerca sus hallazgos a las condiciones operativas de una plataforma de tamizaje real.

3.3.3.3 P3: ¿Cuáles son las métricas de desempeño clínico y computacional que se utilizan para evaluar la efectividad de los modelos de Redes Neuronales Convolucionales en oftalmología?

Los estudios revisados para esta pregunta coinciden en un conjunto común de métricas de evaluación: exactitud, F1-score, sensibilidad, especificidad y AUC-ROC son reportadas de forma consistente en Arnob et al. (2025), Mahmood y Ucan (2025), Elkenawy et al. (2026), Yang et al. (2025) y Milad et al. (2025). Esta uniformidad refleja un estándar implícito en la comunidad científica para evaluar modelos de clasificación en imágenes médicas. Además, estudios como Skouta et al. (2026) incorporan métricas de segmentación, Dice, IoU y MAE en píxeles, que permiten medir la precisión espacial de la detección más allá de la clasificación categórica.

Sin embargo, hay diferencias importantes en el rigor metodológico de la validación. Mahmood y Ucan (2025) y Elkenawy et al. (2026) aplican validación cruzada de cinco pliegues, lo que da mayor solidez estadística a sus resultados; en contraste, Yang et al. (2025) no reportan métricas computacionales como tiempo de inferencia o número de parámetros, lo que constituye una limitación importante para su aplicación en entornos clínicos en tiempo real. Banumathy et al. (2024) reportan una exactitud del 100% en tres datasets simultáneos, lo que representa una limitación metodológica de su estudio, ya que genera dudas fundadas sobre sobreajuste ante la falta de validación cruzada rigurosa. Williams et al. (2024), en cambio, ofrecen una validación más sólida al comparar el modelo directamente contra 16 cirujanos de distintos niveles de experiencia, mostrando que el AUROC

puede ocultar debilidades clínicas reales: el modelo muestra baja sensibilidad (0.63) precisamente en el escenario más crítico, el recrecimiento local.

Un vacío relevante en este bloque es la poca atención a la equidad diagnóstica por subpoblaciones. Solo Milad et al. (2025) usan un dataset con diversidad étnica documentada (Rotterdam EyePACS AIROGS, con muestras de 500 centros), mientras que la mayoría trabaja con datasets de una sola institución o etnia, lo que limita la generalización de sus métricas a contextos como Lima Metropolitana, donde las características de pigmentación retiniana de la población mestiza peruana difieren de las poblaciones europeas y asiáticas predominantes en los datasets disponibles. Esta brecha refuerza la necesidad de una fase de calibración local en la propuesta de esta investigación.

Desde la perspectiva práctica, el trabajo de Milad et al. (2025) destaca por usar SE@95SP como métrica de referencia, es decir, sensibilidad al 95% de especificidad, una forma de reporte más alineada con los requisitos clínicos reales de un programa de tamizaje, donde perder casos referibles es inaceptable. Skouta et al. (2026) aportan evidencia sobre la generalización entre bases de datos heterogéneas mediante U-Net personalizada, con tiempos de inferencia de 49-63 ms por imagen, un referente de eficiencia computacional relevante para el diseño del backend de la plataforma web de esta investigación.

3.3.3.4 P4: *¿Qué procesos de validación técnica y conjuntos de datos estandarizados se identifican en el entrenamiento y evaluación de modelos de Deep Learning para la detección de patologías retinianas?*

Los estudios revisados sobre fuentes de datos y protocolos de validación comparten el uso de datasets públicos estandarizados como punto de partida, siendo APTOS, EyePACS, DRIVE y Messidor los más usados en Sushith et al. (2025), Verma et al. (2025) y Choi et al. (2024). Esta preferencia por datos abiertos facilita la reproducibilidad y la comparación entre modelos, aunque implica asumir que las condiciones de captura de dichos datasets son representativas del entorno clínico objetivo. Xia et al. (2024) y Wang et al. (2025) destacan por contribuir con datasets propios de gran escala, EDDFS con 28,877 imágenes y MultiEYE con más de 100,000, anotados bajo protocolos rigurosos supervisados por oftalmólogos

expertos, estableciendo nuevos estándares para la evaluación multi-etiqueta y multimodal.

Las diferencias más importantes entre los estudios se dan en el nivel de sofisticación del proceso de validación. Liu et al. (2024) y Mukherjee et al. (2025) aplican validación cruzada de cinco pliegues con bootstrapping e intervalos de confianza al 95%, lo que representa el estándar más riguroso del bloque. En el otro extremo, Wu et al. (2025) y Sushith et al. (2025) usan validación simple con partición fija, lo que constituye una limitación metodológica de ambos estudios, ya que reduce la confianza en la estabilidad de sus resultados. Verma et al. (2025) introducen validación cruzada entre datasets, alcanzando 94.5% y 95.8% de exactitud, una estrategia especialmente útil para evaluar la capacidad de generalización a nuevos contextos clínicos. Wang et al. (2025), a través del método OCT-CoDA, abordan el problema de los datos no emparejados entre modalidades, lo que representa una contribución relevante para contextos donde no es posible obtener pares retinografía-OCT del mismo paciente.

Un vacío común en la mayoría de los estudios es la falta de validación prospectiva en entornos clínicos reales. Choi et al. (2024) trabajan con un dataset unicéntrico de origen asiático y solo 26 casos de ERM en los conjuntos de validación externa, lo que representa una restricción en términos de representatividad de los datos, ya que es insuficiente para sacar conclusiones clínicas sólidas. Sushith et al. (2025) amplían artificialmente 40 imágenes a 200 mediante aumento de datos para reportar un 97.50% de exactitud en DRIVE, lo que constituye una limitación en el proceso de entrenamiento, ya que genera sospechas fundadas de sobreajuste. Estos casos muestran una limitación sistemática: el uso de datasets pequeños o artificialmente balanceados puede inflar las métricas y dificultar la comparación objetiva entre modelos.

En términos de aplicabilidad práctica para esta investigación, el sistema DRAMA de Wu et al. (2025) aporta un referente valioso al ser el primer modelo validado en tres tipos de dispositivos distintos con una latencia de 86 ms para el conjunto completo, mostrando la viabilidad de sistemas multitarea en entornos heterogéneos. Liu et al. (2024) con IRIDS muestran la importancia de diseñar sistemas con anotaciones expertas para poblaciones específicas, un principio aplicable al diseño

de un sistema ajustado a la demografía peruana. Los hallazgos de este bloque refuerzan la necesidad de incorporar en esta investigación un protocolo de validación cruzada entre datasets y una evaluación en condiciones clínicas locales antes de cualquier despliegue.

3.3.3.5 P5: *¿Qué infraestructuras tecnológicas se emplean para la integración de modelos predictivos visuales como Sistemas de Soporte al Diagnóstico (CAD) en entornos clínicos?*

Los estudios revisados sobre arquitectura de despliegue e integración clínica de sistemas CAD coinciden en señalar la nube como la infraestructura tecnológica dominante para el despliegue de soluciones en entornos asistenciales. Chotcomwongse et al. (2025) y Yan et al. (2025) coinciden en que plataformas cloud, basadas en Microsoft Azure, Google Cloud o infraestructuras propias, permiten centralizar el procesamiento de imágenes, escalar los recursos según la demanda y facilitar la integración con sistemas de historia clínica electrónica. Del mismo modo, Duggal et al. (2025) confirman que los algoritmos de IA basados en la nube son viables incluso en centros de salud pública con pocos recursos, lo que refuerza el consenso sobre la nube como infraestructura dominante. Esta tendencia refleja un consenso en la literatura: la viabilidad técnica de un sistema CAD no depende solo del rendimiento del modelo, sino de su capacidad de integrarse de forma segura en el flujo de trabajo clínico existente.

Sin embargo, hay diferencias notables en el nivel de madurez de la integración clínica. Pinto et al. (2025) y Chotcomwongse et al. (2025) presentan sistemas desplegados de forma prospectiva en entornos reales con flujos de trabajo digitalizados, mientras que Chowa et al. (2025), Wang et al. (2024) y Akter et al. (2025) describen arquitecturas prometedoras que no han sido sometidas a validación operativa en entornos clínicos. Esta brecha entre el prototipo de laboratorio y la implementación real es un desafío recurrente en la literatura de sistemas CAD. Yan et al. (2025) con PREDICT ofrecen la hoja de ruta MLOps más detallada, incluyendo monitoreo de deriva, gestión de datos EHR y análisis de equidad, pero su dependencia del ecosistema Azure y de infraestructura centralizada de alto costo constituye una restricción de escalabilidad, ya que lo hace difícil de replicar en el sistema de salud público peruano.

Un vacío común en este bloque es la poca atención a los estándares de interoperabilidad en contextos de bajos recursos. Quon et al. (2025) muestran que apenas el 18-25% de los elementos del módulo oftalmológico de Cerner tienen representación exacta en el modelo OMOP CDM, lo que revela una barrera concreta para el intercambio de datos entre sistemas CAD e historias clínicas electrónicas en contextos donde los sistemas locales raramente están alineados a estándares como SNOMED o LOINC. En Lima Metropolitana, donde los sistemas de información de los centros de salud son heterogéneos y con poca interoperabilidad, esta brecha es especialmente relevante. El framework ChatCAD de Wang et al. (2024), si bien es innovador en la generación de reportes en lenguaje natural, no aborda las implicaciones de privacidad derivadas del uso de APIs externas como ChatGPT, lo que representa una limitación normativa, ya que supone un problema de cumplimiento crítico para cualquier sistema que procese datos de salud en el Perú.

Desde la perspectiva de la aplicabilidad práctica para esta investigación, NaIA-RD de Pinto et al. (2025) representa el referente más completo: un sistema desarrollado a medida, integrado al HIS hospitalario, validado de forma prospectiva con 22,962 pacientes y capaz de reducir la carga de visualización por oftalmólogo en 4.27 veces. Su arquitectura de ensamble de tres CNNs ResNet34 con gestión de imagen no gradable es un modelo de diseño directamente adaptable al contexto de la plataforma web propuesta. Asimismo, el modelo OCCT de Chowa et al. (2025), con solo 0.24M parámetros y 32 minutos de entrenamiento, ofrece una referencia de eficiencia computacional útil para entornos con infraestructura limitada, aunque su falta de protocolos de integración con historias clínicas electrónicas constituye una restricción operativa para ser viable en la atención primaria peruana. Por su parte, Duggal et al. (2025) representan el referente más cercano al contexto de esta investigación: integraron el algoritmo AI-3 a una cámara no midriática portátil de bajo costo en centros de salud pública, alcanzando una sensibilidad del 99.6% y VPN del 98.3% para DR; sin embargo, su dependencia completa de conectividad a internet es una restricción operativa importante, y la caída de especificidad entre fases muestra la necesidad de ciclos de reentrenamiento local antes de cualquier despliegue definitivo, un principio directamente aplicable al diseño de la plataforma propuesta.

3.3.4 Conclusiones

En base a la literatura revisada, se identificó que para la detección automatizada de patologías retinianas las arquitecturas CNN con Transfer Learning son el enfoque dominante, siendo DarkNet-53, DRNet13, MobileNet+EfficientNet y AlexNet las más destacadas, con exactitudes que van del 93.2% al 99.4%. Las arquitecturas híbridas que fusionan CNN con LSTM o módulos de estimación de incertidumbre (MC-Dropout) representan la frontera tecnológica más avanzada para el triaje clínico automatizado. Sin embargo, el consenso metodológico se apoya principalmente en datasets genéricos y no ha sido validado de forma prospectiva en contextos latinoamericanos, lo que establece la necesidad de un fine-tuning con datos demográficos peruanos como eje central de esta investigación.

Se identificaron como variables predictivas más relevantes los biomarcadores anatómicos estructurales: mácula, disco óptico, copa óptica, fovea y vasos sanguíneos, y las lesiones patológicas dinámicas: microaneurismas, exudados, hemorragias y edema macular. La literatura muestra que estos biomarcadores pueden extraerse de forma confiable a partir de retinografías convencionales del fondo de ojo, lo que respalda la viabilidad tecnológica de una plataforma web orientada a retinógrafos de bajo costo. La incorporación de mapas Grad-CAM para la justificación visual del diagnóstico se identifica como una característica deseable para aumentar la confianza clínica en los resultados del sistema propuesto.

En relación a las métricas de desempeño, la revisión muestra que el conjunto estándar de exactitud, F1-score, sensibilidad, especificidad y AUC-ROC es ampliamente usado, pero tiene limitaciones cuando se aplica de forma aislada en contextos clínicos. La sensibilidad a alta especificidad (SE@95SP) y el tiempo de inferencia se perfilan como indicadores más adecuados para un sistema de tamizaje, donde perder un caso referible tiene consecuencias clínicas irreversibles. La escasa representación de poblaciones con características demográficas similares a la peruana en los datasets de evaluación es una limitación importante que deberá abordarse mediante una fase de validación local antes del despliegue de la plataforma.

Respecto a los procesos de validación técnica y datasets estandarizados, se concluye que APTOS, EyePACS y Messidor son los conjuntos de referencia más usados, aunque su capacidad de representar la variabilidad clínica real de Lima Metropolitana

es limitada. La validación cruzada de cinco pliegues con separación a nivel de paciente representa el estándar metodológico más robusto identificado. La validación prospectiva en entornos clínicos reales sigue siendo un vacío generalizado en la literatura, que esta investigación busca reducir mediante una evaluación controlada con imágenes de centros de atención primaria locales.

En cuanto a las infraestructuras tecnológicas para la integración CAD, la arquitectura en nube con módulos de interoperabilidad, gestión de calidad de imagen y monitoreo continuo del modelo emerge como el estándar de despliegue clínico más maduro, respaldado por los sistemas NaIA-RD y PREDICT, con evidencia de viabilidad incluso en centros de salud pública con pocos recursos. La integración con historias clínicas electrónicas bajo estándares abiertos, el diseño de interfaces accesibles para personal no especializado y la incorporación de ciclos de reentrenamiento local son condiciones necesarias para la adopción real del sistema en el contexto de salud pública peruana.

En términos generales, la revisión de la literatura confirma que existe una base tecnológica sólida y reproducible para el desarrollo de un sistema CAD basado en CNN para la detección automatizada de patologías retinianas a partir de retinografías convencionales. Los hallazgos más relevantes, las arquitecturas híbridas con Transfer Learning y módulos de incertidumbre, los biomarcadores visuales validados, las métricas orientadas al tamizaje clínico, los protocolos de validación cruzada multi-dataset y las infraestructuras cloud con integración de historias clínicas electrónicas, proveen los fundamentos metodológicos y tecnológicos que guiarán el diseño de la plataforma web propuesta. El vacío principal identificado es la ausencia de sistemas validados en la realidad clínica peruana, lo que constituye la contribución central y diferencial de esta tesis.

Conclusiones

En el capítulo de definición del problema se concluye que la detección temprana de patologías retinianas en Lima Metropolitana presenta limitaciones importantes asociadas a la saturación de los servicios oftalmológicos, los tiempos prolongados de espera, la dependencia del análisis visual manual y la ausencia de herramientas tecnológicas de apoyo al diagnóstico. Esta situación aumenta el riesgo de diagnóstico tardío de enfermedades como la retinopatía diabética y el glaucoma, las cuales pueden causar pérdida irreversible de la visión si no se identifican a tiempo. Frente a ello, la propuesta de una aplicación web basada en Redes Neuronales Convolucionales se presenta como una alternativa viable para optimizar el triaje clínico, priorizar casos de alto riesgo y apoyar la toma de decisiones del especialista.

En el capítulo de marco teórico se concluye que los fundamentos de inteligencia artificial, Deep Learning, Redes Neuronales Convolucionales, procesamiento de imágenes médicas y sistemas CAD brindan una base técnica sólida para el desarrollo de una solución de soporte clínico orientada al análisis automatizado de retinografías. Asimismo, los estándares, frameworks, buenas prácticas y normativas revisadas permiten orientar el diseño de la aplicación hacia criterios de calidad, seguridad, interoperabilidad, privacidad de datos y escalabilidad. Por tanto, este capítulo muestra que integrar modelos CNN en una aplicación web clínica no solo es técnicamente posible, sino también pertinente para responder a las necesidades actuales del diagnóstico oftalmológico.

En el capítulo de estado del arte se concluye que las investigaciones recientes respaldan el uso de arquitecturas CNN y técnicas de Transfer Learning para la detección automatizada de enfermedades retinianas, debido a sus altos niveles de desempeño en métricas como exactitud, sensibilidad, especificidad, F1-score y AUC-ROC. Además, los estudios revisados muestran que el uso de datasets como APTOS, EyePACS y Messidor ha permitido entrenar y validar modelos con resultados prometedores. Sin embargo, también se identifica una brecha importante: la necesidad de validar estas soluciones en contextos clínicos locales y con datos representativos de la población peruana. Esto refuerza la relevancia de la presente investigación y justifica el desarrollo de una plataforma web adaptada a consultorios oftalmológicos de Lima Metropolitana.

En conclusión, el presente trabajo de investigación muestra la necesidad y viabilidad de desarrollar una aplicación web de soporte clínico basada en Redes Neuronales Convolucionales para la identificación automatizada de patologías retinianas. La problemática analizada deja claro que el modelo tradicional de evaluación oftalmológica resulta insuficiente frente a la alta demanda de atención, mientras que el marco teórico y el estado del arte confirman que la inteligencia artificial puede contribuir de forma significativa a mejorar la detección temprana. La solución propuesta no busca reemplazar el criterio médico, sino brindar una herramienta de apoyo que permita acelerar el triaje, reducir la carga del especialista, mejorar la gestión de resultados clínicos y contribuir a la prevención de ceguera irreversible en pacientes con riesgo de retinopatía diabética o glaucoma.

Referencias Bibliográficas

- Akerele, J. I., Uzoka, A., Ojukwu, P. U., & Olamijuwon, O. J. (2024). Improving healthcare application scalability through microservices architecture in the cloud. *International Journal of Scientific Research Updates*, 8(2), 100-109. https://www.researchgate.net/publication/386273829_Improving_healthcare_application_scalability_through_microservices_architecture_in_the_cloud
- Akter, Z., Ahad, J. I., Farhan, M. M., & Khan, R. (2025). Graph-enhanced deep learning for diabetic retinopathy diagnosis: A quality-aware and uncertainty-driven approach. *PLOS Computational Biology*, 21(12), e1013745. <https://journals.plos.org/ploscompbiol/article?id=10.1371/journal.pcbi.1013745>
- Alanazi, S., & Alanazi, R. (2025). Enhancing diabetic retinopathy detection through federated convolutional neural networks: Exploring different stages of progression. *Alexandria Engineering Journal*, 120, 215-228. <https://www.sciencedirect.com/science/article/pii/S1110016825001930>
- Amazon Web Services. (2026). ¿Qué es AWS? - Computación en la nube con Amazon Web Services. Recuperado de <https://aws.amazon.com/es/what-is-aws/>
- Angular. (s.f.). What is Angular? Recuperado de <https://angular.dev/overview>
- Arias-Serrano, I., Velásquez-López, P. A., Avila-Briones, L. N., Laurido-Mora, F. C., Villalba-Meneses, F., Tirado-Espin, A., Cruz-Varela, J., & Almeida-Galárraga, D. (2024). Artificial intelligence based glaucoma and diabetic retinopathy detection using MATLAB - retrained AlexNet convolutional neural network. *F1000Research*, 12, 14. <https://f1000research.com/articles/12-14/v2>
- Arnob, A. K. B., Chayon, M. H. R., Al Farid, F., Husen, M. N., & Ahmed, F. (2025). A Lightweight CNN for Multiclass Retinal Disease Screening with Explainable AI. *Journal of Imaging*, 11(8), 275. <https://www.mdpi.com/2313-433X/11/8/275>
- Banumathy, D., Angamuthu, S., Balaji, P., & Chaurasia, M. A. (2024). Revolutionizing diabetic eye disease detection: retinal image analysis with cutting-edge deep learning techniques. *PeerJ Computer Science*, 10, e2186. <https://peerj.com/articles/cs-2186/>

- Cao, M., Ramezani, R., Katakwar, V. K., Zhang, W., Boda, D., Wani, M., & Naeim, A. (2024). Developing remote patient monitoring infrastructure using commercially available cloud platforms. *Frontiers in Digital Health*, 6, 1399461. <https://pmc.ncbi.nlm.nih.gov/articles/PMC11576445/>
- Chandola, Y., Uniyal, V., Bachheti, Y., Lakhera, N., & Rawat, R. (2024). Data augmentation techniques applied to medical images. *International Journal of Research Publication and Reviews*, 5(7), 483-501. https://www.researchgate.net/publication/382869099_Data_Augmentation_Techniques_Applied_to_Medical_Images
- Chen, M. S., Ravindranath, R., Chang, R., Zhou, Y., Keane, P. A., & Wang, S. Y. (2025). Independent evaluation of RETFound foundation model's performance on optic nerve analysis using fundus photography. *Ophthalmology Science*, 5(3), Artículo 100720. <https://scopus.upc.elogim.com/pages/publications/86000366348?origin=resultslist>
- Choi, J. Y., Ryu, I. H., Kim, J. K., Lee, I. S., & Yoo, T. K. (2024). Development of a generative deep learning model to improve epiretinal membrane detection in fundus photography. *BMC Medical Informatics and Decision Making*, 24, 25. https://link.springer.com/article/10.1186/s12911-024-02431-4?utm_source=getftr&utm_medium=getftr&utm_campaign=getftr_pilot&getftr_integrator=scopus
- Chotcomwongse, P., Ruamviboonsuk, P., Karavapitayakul, C., Thongthong, K., Amornpetchsathaporn, A., Chainakul, M., Triprachanath, M., Lerdpanyawattananukul, E., Arjkongharn, N., Ruamviboonsuk, V., Vongsa, N., Pakaymaskul, P., Waiwaree, T., Ruampunpong, H., Tiwari, R., & Tangcharoensathien, V. (2025). Transforming non-digital, clinical workflows to detect and track vision-threatening diabetic retinopathy via a digital platform integrating artificial intelligence: Implementation research. *Ophthalmology and Therapy*, 14, 447–460. <https://pubmed.ncbi.nlm.nih.gov/39792334/>
- Chowa, S. S., Bhuiyan, M. R. I., Payel, I. J., Karim, A., Khan, I. U., Montaha, S., Hasan, M. Z., Jonkman, M., & Azam, S. (2025). A low complexity efficient deep learning model for automated retinal disease diagnosis. *Journal of Healthcare Informatics Research*,

- 9, 1–40. https://link.springer.com/article/10.1007/s41666-024-00182-5?utm_source=getftr&utm_medium=getftr&utm_campaign=getftr_pilot&getftr_integrator=scopus
- Clark, B. (s.f.). ¿Qué es Scikit-Learn (Sklearn)? IBM. Recuperado de <https://www.ibm.com/es-es/think/topics/scikit-learn>
- Comisión Europea. (2024, 25 de julio). Segundo Informe relativo a la aplicación del Reglamento General de Protección de Datos (COM(2024) 357 final). <https://eur-lex.europa.eu/legal-content/ES/TXT/HTML/?uri=CELEX:52024DC0357>
- Contraloría General de la República. (2024). Informe de Control Concurrente N° 017-2024-OCI/3759-SCC: Proceso de programación, ejecución y seguimiento en el servicio a pacientes que provienen del Departamento de Atención Especializada en Glaucoma del Instituto Nacional de Oftalmología. Órgano de Control Institucional. https://apps8.contraloria.gob.pe/SPIC/srvDownload/ViewPDF?CRES_CODIGO=2024CSI375900017&TIPOARCHIVO=ADJUNTO
- Defensoría del Pueblo. (2025). Informe Defensorial N° 243: Supervisión a los Institutos Especializados de Salud de Lima y Regiones. https://www.defensoria.gob.pe/wp-content/uploads/2025/05/INFORME_DEFENSORIAL_243.pdf
- Deepak, G. D., & Bhat, S. K. (2024). Deep learning-based CNN for multiclassification of ocular diseases using transfer learning. *Computer Methods in Biomechanics and Biomedical Engineering: Imaging & Visualization*, 12(1), 2335959. <https://scopus.upc.elogim.com/pages/publications/85189613961?origin=resultslst>
- Duggal, M., Chauhan, A., Gupta, V., Kankaria, A., Budhija, D., Verma, P., Miglani, V., Syal, P., Kaur, G., Kumar, L., Mutyala, N., Bezbaruah, R., Sood, N., Kernohan, A., Menon, G., & Vale, L. (2025). Real-World Evaluation of AI-Driven Diabetic Retinopathy Screening in Public Health Settings: Validation and Implementation Study. *JMIR Medical Informatics*, 13, e67529. <https://pubmed.ncbi.nlm.nih.gov/40925861/>
- Ejaz, S., Baig, R., Ashraf, Z., Alnfiai, M. M., Alnahari, M. M., & Alotaibi, R. M. (2024). A deep learning framework for the early detection of multi-retinal diseases. *PLOS*

ONE, 19(7), e0307317.

<https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0307317>

Ejaz, S., Zia, H. U., Majeed, F., Shafique, U., Carvajal Altamiranda, S., Lipari, V., & Ashraf, I. (2025). Fundus image classification using feature concatenation for early diagnosis of retinal disease. *Digital Health*, 11, 1-24. https://journals.sagepub.com/doi/epdf/10.1177/20552076251328120?src=getftr&utm_source=mendeley&getft_integrator=mendeley

Elkenawy, E. M., Khodadadi, N., Gaber, K. S., Khodadadi, E., Alhussan, A. A., Khafaga, D. S., & Eid, M. M. (2026). Automated retinal disease classification using deep learning and AlexNet with statistical models analysis. *PLOS One*, 21(1), e0338415. <https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0338415>

Elkholy, M., & Marzouk, M. A. (2024). Deep learning-based classification of eye diseases using Convolutional Neural Network for OCT images. *Frontiers in Computer Science*, 5, Artículo 1252295. https://www.researchgate.net/publication/377494287_Deep_learning-based_classification_of_eye_diseases_using_Convolutional_Neural_Network_for_OCT_images

Faiyazuddin, M., Rahman, S. J. Q., Anand, G., Siddiqui, R. K., Mehta, R., Khatib, M. N., Gaidhane, S., Zahiruddin, Q. S., Hussain, A., & Sah, R. (2025). The impact of artificial intelligence on healthcare: A comprehensive review of advancements in diagnostics, treatment, and operational efficiency. *Health Science Reports*, 8, e70312. <https://pmc.ncbi.nlm.nih.gov/articles/PMC11702416/>

Gift, N. (2025, 12 de mayo). Writing clean, testable, high quality code in Python. IBM Developer. Recuperado de <https://developer.ibm.com/articles/au-cleancode/>

Gim, N., Ferguson, A. N., Blazes, M., Lee, C. S., & Lee, A. Y. (2025). The march to harmonized imaging standards for retinal imaging. *Progress in Retinal and Eye Research*, 107, Artículo 101363. <https://scopus.upc.elogim.com/pages/publications/105007424802?origin=resultslist>

Gomstyn, A., & Jonker, A. (s.f.). What is data quality management? IBM Think. Recuperado de <https://www.ibm.com/think/topics/data-quality-management>

- Henge, S. K., Viraati, N. R., Alhussein, M., Kushwaha, A. S., Aurangzeb, K., & Singh, R. (2025). Detection of diabetic retinopathy using a multi-decision Inception-ResNet-blended hybrid model. IEEE Access, 13, 8992-9005. <https://ieeexplore.ieee.org/document/10820183>
- Heredia, R. (21 de octubre de 2025). ¿Eres diabético? El 30% de personas en el Perú sufrirían de ceguera por retinopatía diabética. Glaucoma Lima Center. <https://glaucomalimacenter.com/diabético-peru-ceguera-retinopatía-diabética/>
- IBM. (s.f.). Artificial intelligence in medicine. Recuperado el 3 de mayo de 2026, de <https://www.ibm.com/think/topics/artificial-intelligence-medicine>
- IBM. (s.f.). AI vs. machine learning vs. deep learning vs. neural networks. Recuperado el 3 de mayo de 2026, de <https://www.ibm.com/think/topics/ai-vs-machine-learning-vs-deep-learning-vs-neural-networks>
- Infante Cueva, W., & Cruzado Benites, P. M. S. (2024). Desarrollo de un sistema de diagnóstico en la detección temprana de cataratas utilizando redes neuronales convolucionales [Tesis de título profesional, Universidad Privada Antenor Orrego]. Repositorio de la Universidad Privada Antenor Orrego. <https://repositorio.upao.edu.pe/item/2f51ef45-e2d6-4b7f-9a94-2b818eb63b91>
- Instituto Nacional de Oftalmología. (2025). Memoria Institucional 2024. Ministerio de Salud del Perú (MINSA). <https://www.gob.pe/institucion/ino/informes-publicaciones/7436226-memoria-institucional-2024>
- International Agency for the Prevention of Blindness. (13 de abril de 2026). Science, Systems and Sight: Ending Preventable Blindness from Diabetes. IAPB. <https://www.iapb.org/blog/science-systems-and-sight-ending-preventable-blindness-from-diabetes/>
- International Organization for Standardization and International Electrotechnical Commission. (2022). Information security, cybersecurity and privacy protection - Information security management systems - Requirements (Norma ISO/IEC No. 27001:2022). <https://www.iso.org/standard/27001>
- International Organization for Standardization and International Electrotechnical Commission. (2023). Systems and software engineering - Systems and software

- Quality Requirements and Evaluation (SQuaRE) - Product quality model (Norma ISO/IEC No. 25010:2023). <https://www.iso.org/standard/78176.html>
- International Organization for Standardization, International Electrotechnical Commission and Institute of Electrical and Electronics Engineers. (2018). Systems and software engineering - Life cycle processes - Requirements engineering (Norma ISO/IEC/IEEE No. 29148:2018). <https://www.iso.org/standard/72089.html>
- International Organization for Standardization, International Electrotechnical Commission and Institute of Electrical and Electronics Engineers. (2026). Systems and software engineering - Software life cycle processes (Norma ISO/IEC/IEEE No. 12207:2026). <https://www.iso.org/standard/90219.html>
- Iqbal, O., Jadoon, W., Khan, I. A., Afzal, M., & Aldhahri, A. (2025). Deep learning-based interpretable framework for simultaneous segmentation of retinal multi-lesions and multi-categorical disease classification. *International Journal of Computational Intelligence Systems*, 18, Artículo 275. <https://scopus.upc.elogim.com/pages/publications/105020758630?origin=resultslst>
- Islam, S., et al. (2025). Novel Deep Learning Model for Glaucoma Detection Using Fusion of Fundus and Optical Coherence Tomography Images. *Sensors*, 25, 4337. <https://www.mdpi.com/1424-8220/25/14/4337>
- Jaimes, W. J., Arenas, W. J., Navarro, H. J., & Altuve, M. (2025). Detection of retinal diseases from OCT images using a VGG16 and transfer learning. *Discover Applied Sciences*, 7, 160. <https://scopus.upc.elogim.com/pages/publications/85218421065?origin=resultslst>
- Kamani, V. (2024). Cloud computing in healthcare. *Arkenea*. <https://arkenea.com/blog/cloud-computing-in-healthcare/>
- Kumar, N. A., Madhusudan, D., Ioannou, I., Pradeep Ghantasala, G. S., & Vassiliou, V. (2026). A self-supervised hybrid CNN with uncertainty-aware referral for diabetic retinopathy screening. *Biomedical Signal Processing and Control*, 116, 109482. https://www.researchgate.net/publication/399496734_A_Self-Supervised_Hybrid_CNN_with_Uncertainty-Aware_Referral_for_Diabetic_Retinopathy_Screening

- Latif, G., Alghazo, J., Khan, M. A., Ben Brahim, G., Fawagreh, K., & Mohammad, N. (2024). Deep convolutional neural network (CNN) model optimization techniques- Review for medical imaging. *AIMS Mathematics*, 9(8), 20539-20571. <https://www.aimspress.com/article/doi/10.3934/math.2024998>
- Ley 30096. (2013). Ley de delitos informáticos. Congreso de la República del Perú.
- Ley 29733. (2011). Ley de protección de datos personales. Congreso de la República del Perú.
- Ley 30421. (2016). Ley marco de telesalud. Congreso de la República del Perú.
- Ley 30024. (2013). Ley que crea el registro nacional de historias clínicas electrónicas. Congreso de la República del Perú.
- Ley 31814. (2023). Ley que promueve el uso de la inteligencia artificial en favor del desarrollo económico y social del país. Congreso de la República del Perú.
- Liu, Y., Xie, H., Zhao, X., Tang, J., Yu, Z., Wu, Z., Tian, R., Chen, Y., Chen, M., Ntentakis, D. P., Du, Y., Chen, T., Hu, Y., Zhang, S., Lei, B., & Zhang, G. (2024). Automated detection of nine infantile fundus diseases and conditions in retinal images using a deep learning system. *EPMA Journal*, 15, 39-51. <https://pmc.ncbi.nlm.nih.gov/articles/PMC10923762/>
- Mahmood, M. T., & Ucan, O. N. (2025). Data and image processing for intelligent glaucoma detection and optic disc segmentation using deep convolutional neural network architecture. *Discover Computing*, 28, 73. https://link.springer.com/article/10.1007/s10791-025-09587-1?utm_source=getftr&utm_medium=getftr&utm_campaign=getftr_pilot&getftr_integrator=scopus
- Mamyrbayev, O., Pavlov, S., Poplavskiy, O., Momynzhanova, K., Saldan, Y., Zhanegiz, A., Zhumagulova, S., & Zhumazhan, N. (2025). Hybrid Neural Architectures Combining Convolutional and Recurrent Networks for the Early Detection of Retinal Pathologies. *Engineering, Technology & Applied Science Research*, 15(4), 25150–25157. <https://scopus.upc.elogim.com/pages/publications/105013113627?origin=document-preview-flyout>

- MarketsandMarkets. (2025, 22 de octubre). Healthcare cloud computing: Transforming digital health infrastructure. <https://www.marketsandmarkets.com/ResearchInsight/healthcare-cloud-computing-regional-insights.asp>
- Microsoft. (s.f.). AI in health. Recuperado el 3 de mayo de 2026, de <https://www.microsoft.com/en-us/ai/health>
- Microsoft. (s.f.). Azure Health Data Services. Recuperado el 3 de mayo de 2026, de <https://azure.microsoft.com/en-us/products/health-data-services>
- Microsoft. (2024, 11 de junio). Key UI/UX design principles. Microsoft Learn. Recuperado de <https://learn.microsoft.com/en-us/dynamics365/guidance/develop/ui-ux-design-principles>
- Microsoft. (2025, 6 de octubre). MLOps model management with Azure Machine Learning. Microsoft Learn. Recuperado de <https://learn.microsoft.com/en-us/azure/machine-learning/concept-model-management-and-deployment?view=azureml-api-2>
- Microsoft. (2025, 7 de agosto). What is Azure Load Testing? Microsoft Learn. Recuperado de <https://learn.microsoft.com/en-us/azure/app-testing/load-testing/overview-what-is-azure-load-testing>
- Milad, D., Antaki, F., Mikhail, D., Farah, A., El-Khoury, J., Touma, S., Dury, G. M., Nayman, T., Playout, C., Keane, P. A., & Duval, R. (2025). Code-Free Deep Learning Glaucoma Detection on Color Fundus Images. *Ophthalmology Science*, 5(4), 100721. https://www.sciencedirect.com/science/article/pii/S2666914525000193?pes=vor&utm_source=scopus&getft_integrator=scopus
- Moreno Lozano, M. I., & Ticlavilca Inche, E. J. (2025). Solución móvil para la detección de Pterigión utilizando un modelo de clasificación basado en la arquitectura de CNN ResNext50 en imágenes del segmento anterior del ojo para el Centro Peruano del Pterigión [Tesis de título profesional, Universidad Peruana de Ciencias Aplicadas]. Repositorio Académico UPC. <https://repositorioacademico.upc.edu.pe/handle/10757/688399>

- Moreno-Lozano, M. I., Ticlavilca-Inche, E. J., Mauricio, D., & Oñate-Andino, A. (2024). A Performance Evaluation of Convolutional Neural Network Architectures for Pterygium Detection in Anterior Segment Eye Images. *Diagnostics*, 14(18), 2026. <https://www.mdpi.com/2075-4418/14/18/2026>
- Mukherjee, S., De Silva, T., Duic, C., Jayakar, G., Keenan, T. D. L., Thavikulwat, A. T., Chew, E., & Cukras, C. (2025). Validation of Deep Learning-Based Automatic Retinal Layer Segmentation Algorithms for Age-Related Macular Degeneration with 2 Spectral-Domain OCT Devices. *Ophthalmology*. American Academy of Ophthalmology. https://www.sciencedirect.com/science/article/pii/S2666914524002069?pes=vor&utm_source=scopus&getft_integrator=scopus
- National Eye Institute. (2025, 11 de septiembre). Diabetic retinopathy. <https://www.nei.nih.gov/eye-health-information/eye-conditions-and-diseases/diabetic-retinopathy>
- National Eye Institute. (2025, 26 de noviembre). Glaucoma. <https://www.nei.nih.gov/eye-health-information/eye-conditions-and-diseases/glaucoma>
- Nguyen, T. D., Le, D.-T., Bum, J., Kim, S., Song, S. J., & Choo, H. (2024). Retinal disease diagnosis using deep learning on ultra-wide-field fundus images. *Diagnostics*, 14(1), Artículo 105. <https://scopus.upc.elogim.com/pages/publications/85181949451?origin=resultslist>
- Nova One Advisor. (2024). Global Diabetic Retinopathy Market Size, Share, Forecast Report, 2024-2033. <https://www.novaoneadvisor.com/report/global-diabetic-retinopathy-market>
- Obiokafor, I. N., Ajonuma, M. E., & Aguboshim, F. C. (2025). Integrating Privacy by Design (PbD) in the system development life cycle for enhanced data protection. *World Journal of Advanced Research and Reviews*, 26(1), 1233-1240. https://www.researchgate.net/publication/391323032_Integrating_Privacy_by_Design_PbD_in_the_system_development_life_cycle_for_enhanced_data_protection

- Office of the National Coordinator for Health Information Technology. (s.f.). Health Level 7 (HL7) Fast Healthcare Interoperability Resources (FHIR). Recuperado el 3 de mayo de 2026, de <https://healthit.gov/interoperability/investments/fhir/>
- OpenCV team. (2026). About. OpenCV. Recuperado de <https://opencv.org/about/>
- Orlova, E. V. (2024). Artificial Intelligence-Based System for Retinal Disease Diagnosis. *Algorithms*, 17(7), 315. https://www.researchgate.net/publication/382381882_Artificial_Intelligence-Based_System_for_Retinal_Disease_Diagnosis
- Pinto, I., Olazarán, Á., Jurío, D., De la Osa, B., Sainz, M., Oscoz, A., Ballaz, J., Gorricho, J., Galar, M., & Andonegui, J. (2025). Improving diabetic retinopathy screening using artificial intelligence: design, evaluation and before-and-after study of a custom development. *Frontiers in Digital Health*, 7, 1547045. <https://www.frontiersin.org/journals/digital-health/articles/10.3389/fdgth.2025.1547045/full>
- Quon, J. C., Long, C. P., Halfpenny, W., Chuang, A., Cai, C. X., Baxter, S. L., Daketi, V., Schmitz, A., Bahroos, N., Xu, B. Y., & Toy, B. C. (2025). Implementing a common data model in ophthalmology: Mapping structured electronic health record ophthalmic examination data to standard vocabularies. *Ophthalmology Science*, 5(2), 100666. https://www.sciencedirect.com/science/article/pii/S2666914524002021?getft_integrator=scopus&pes=vor&utm_source=scopus
- Rahim, M. J., Al-Zuky, A. A. D., & Al-Obaidi, F. E. M. A. (2024). Glaucoma disease classification based on convolutional neural network architecture method. *Mustansiriyah Journal of Pure and Applied Sciences*. <https://mjpas.uomustansiriyah.edu.iq/index.php/mjpas/article/view/316>
- Raso, E., Nanni, F., Lestini, F., Bracciale, L., Panico, G., Bianchi, G., Orengo, G., Marrocco, G., & Loreti, P. (2025). Improving Vulnerability Management for Security-by-Design of Medical Devices. *Sensors*, 25(14), 4418. https://www.researchgate.net/publication/393764784_Improving_Vulnerability_Management_for_Security-by-Design_of_Medical_Devices

- RPP Noticias. (2026, 30 de enero). Perú se incorpora a la red internacional para la implementación segura de la IA en salud. Movimiento Salud. <https://rpp.pe/vital/salud/peru-se-incorpora-a-la-red-internacional-para-la-implementacion-segura-de-la-ia-en-salud-noticia-1673919>
- Schwaber, K., & Sutherland, J. (2020, noviembre). The 2020 Scrum Guide. Scrum Guides. <https://scrumguides.org/scrum-guide.html#transparency>
- Seinfeld, J., Ugarte, Ó., Amaro, C., & Dibós, M. J. (2026). Primer nivel de atención para lograr acceso oportuno y efectivo a los servicios de salud en el Perú (2026-2031) (Documento de Política). Consorcio de Investigación Económica y Social. <https://cies.org.pe/wp-content/uploads/2026/03/DP-Salud.pdf>
- Shamrat, F. M. J. M., Shakil, R., Sharmin, Hoque Ovy, N., Akter, B., Ahmed, M. Z., Ahmed, K., Bui, F. M., & Moni, M. A. (2024). An advanced deep neural network for fundus image analysis and enhancing diabetic retinopathy detection. *Healthcare Analytics*, 5, 100303. <https://www.sciencedirect.com/science/article/pii/S2772442524000054?via%3Dihub>
- Skevas, C., Pérez de Olaguer, N., Lleó, A., Thiwa, D., Schroeter, U., Lopes, I. V., Mautone, L., Linke, S. J., Spitzer, M. S., Yap, D., & Xiao, D. (2024). Implementing and evaluating a fully functional AI-enabled model for chronic eye disease screening in a real clinical environment. *BMC Ophthalmology*, 24, Artículo 51. <https://scopus.upc.elogim.com/pages/publications/85183720104?origin=resultlist>
- Skouta, A., Elmoufidi, A., Jai-Andaloussi, S., & Ouchetto, O. (2026). Customized U-Net architecture for automated optic disc segmentation in retinal fundus images. *Discover Artificial Intelligence*, 6, 140. https://link.springer.com/article/10.1007/s44163-025-00795-8?utm_source=getftr&utm_medium=getftr&utm_campaign=getftr_pilot&getftr_integrator=scopus
- Stryker, C., & Mucci, T. (s.f.). What is MLOps? IBM Think. Recuperado de <https://www.ibm.com/think/topics/mlops>

- Sushith, M., Sathiya, A., Kalaipoonguzhali, V., & Sathya, V. (2025). A hybrid deep learning framework for early detection of diabetic retinopathy using retinal fundus images. *Scientific Reports*, 15, 15166. <https://www.nature.com/articles/s41598-025-99309-w>
- TensorFlow. (2021, 24 de marzo). TensorFlow Core. Recuperado el 3 de mayo de 2026, de <https://www.tensorflow.org/guide?hl=es-419>
- TensorFlow. (2022, 10 de enero). Transferencia de aprendizaje y ajuste fino. https://www.tensorflow.org/guide/keras/transfer_learning?hl=es-419
- tiangolo. (2026). FastAPI [Software]. <https://fastapi.tiangolo.com>
- Ticlavilca-Inche, E. J., Moreno-Lozano, M. I., Castañeda, P., Wong-Durand, S., & Oñate-Andino, A. (2024). Mobile Application Based on Convolutional Neural Networks for Pterygium Detection in Anterior Segment Eye Images at Ophthalmological Medical Centers. *International Journal of Online and Biomedical Engineering (iJOE)*, 20(8). <https://online-journals.org/index.php/i-joe/article/view/48421/14973>
- Thomas, N. M., & Jerome, S. A. (2024). Diabetic retinopathy detection using ensembled transfer learning based thrice CNN with SVM classifier. *Multimedia Tools and Applications*, 83, 70089-70115. https://www.researchgate.net/publication/377808002_Diabetic_retinopathy_detection_using_ensembled_transfer_learning_based_thrice_CNN_with_SVM_classifier
- Verma, G., Ghoniem, R. M., Gupta, S., Bharany, S., Singh, J., Rehman, A. U., & Taye, B. M. (2025). A robust ensemble-based deep learning framework for automated retinal disease detection. *Health Informatics Journal*, 31(4), 1-28. https://journals.sagepub.com/doi/epdf/10.1177/14604582251396416?src=getft&utm_source=scopus&getft_integrator=scopus
- Wang, L., Ou, C., Qi, C., An, L., Jin, M., Kong, X., & Li, X. (2025). MultiEYE: Dataset and Benchmark for OCT-Enhanced Retinal Disease Recognition from Fundus Images. *IEEE Transactions on Medical Imaging*. arXiv. <https://arxiv.org/abs/2412.09402>
- Wang, S., Zhao, Z., Ouyang, X., Liu, T., Wang, Q., & Shen, D. (2024). Interactive computer-aided diagnosis on medical image using large language models. *Communications Engineering*, 3, 133. <https://www.nature.com/articles/s44172-024-00271-8>

- Williams, H., Thompson, H. M., Lee, C., Rangnekar, A., Gomez, J. T., Widmar, M., Wei, I., Pappou, E. P., Nash, G. M., Weiser, M. R., Paty, P. B., Smith, J. J., Veeraraghavan, H., & Garcia-Aguilar, J. (2024). Assessing Endoscopic Response in Locally Advanced Rectal Cancer Treated with Total Neoadjuvant Therapy: Development and Validation of a Highly Accurate Convolutional Neural Network. *Annals of Surgical Oncology*, 31(10), 6443-6451. <https://pmc.ncbi.nlm.nih.gov/articles/PMC11600550/>
- World Health Organization. (2024). Vision impairment and blindness: Global update. WHO Press. <https://www.who.int/news-room/fact-sheets/detail/blindness-and-visual-impairment>
- Wu, H., Jin, K., Jing, Y., Shen, W., Tham, Y. C., Pan, X., Koh, V., Grzybowski, A., & Ye, J. (2025). Diabetic Retinopathy Assessment through Multitask Learning Approach on Heterogeneous Fundus Image Datasets. *Ophthalmology*. American Academy of Ophthalmology. https://www.sciencedirect.com/science/article/pii/S2666914525000533?pes=vor&utm_source=scopus&getft_integrator=scopus
- Xia, X., Li, Y., Xiao, G., Zhan, K., Yan, J., Cai, C., Fang, Y., & Huang, G. (2024). Benchmarking deep models on retinal fundus disease diagnosis and a large-scale dataset. *Signal Processing: Image Communication*, 127, 117151. https://www.sciencedirect.com/science/article/pii/S0923596524000523?getft_integrator=scopus&pes=vor&utm_source=scopus
- Yan, A. P., Guo, L. L., Inoue, J., Arciniegas, S. E., Vettese, E., Wolochacz, A., Crellin-Parsons, N., Purves, B., Wallace, S., Patel, A., Roshdi, M., Jessa, K., Cardiff, B., & Sung, L. (2025). A roadmap to implementing machine learning in healthcare: From concept to practice. *Frontiers in Digital Health*, 7, 1462751. <https://www.frontiersin.org/journals/digital-health/articles/10.3389/fdgth.2025.1462751/full>
- Yang, J., Hsu, C., Wang, J., Wu, B., Lu, Y., Ding, Y., Zhao, Z., Tang, K., Lu, F., & Ma, L. (2025). HyReti-Net: hybrid retinal diseases classification and diagnosis network using optical coherence tomography. *Frontiers in Medicine*, 12, 1660920. <https://www.frontiersin.org/journals/medicine/articles/10.3389/fmed.2025.1660920/full>

Anexo(s)

- A. Anexo 01: Pila de Producto (Product Backlog)
- B. Anexo 02: Cronograma del Proyecto
- C. Anexo 03: Acta de Constitución del Proyecto (Project Charter)
- D. Anexo 04: Informe de Benchmarking
- E. Anexo 05: Informe de Similitud del Turnitin